

Electronic Commerce

Nhóm 18



Phạm Thị Thanh Hà
Lê Tiến Nghĩa
Bùi Quang Hưng
Phạm Hữu Chiến
Nguyễn Trung Hiếu

20216823
20216861
20216837
20216802
20216828

[Menu](#)

[About Us](#)

[@reallygreatsite](#)



[Menu](#)[About Us](#)[@reallygreatsite](#)

Nội dung

I. Khảo sát



II. Phân tích và thiết kế



III. Xây dựng hệ thống



IV. Tổng kết





Tổng quan



Khảo sát nghiệp vụ



Yêu cầu phân tích



Hệ thống dữ liệu



ERD hệ thống OLTP



[Menu](#)

[About Us](#)



I. Khảo sát



Tổng quan về E-commerce

Khái niệm

Thương mại điện tử, hay còn gọi là e-commerce, e-comm hay EC, là sự mua bán sản phẩm hay dịch vụ trên các hệ thống điện tử như Internet và các mạng máy tính.

Thực trạng

E-Commerce đã và đang trở thành lĩnh vực có ảnh hưởng cực kỳ quan trọng đến tăng trưởng kinh tế của các quốc gia. Thị trường đang có xu hướng tăng trưởng, đạt tổng giá trị 20,5 tỷ đô vào 2023.

Lợi ích

Hiểu rõ hơn về hành vi khách hàng
Tối ưu hóa quyết định kinh doanh
Cải thiện trải nghiệm khách hàng
Dự đoán xu hướng thị trường


[Menu](#)[About Us](#)[@reallygreatsite](#)

Tổng quan về Olist

Thành lập vào tháng 2 năm 2015 bởi Tiago Dalvi, là một công ty con của Solidarium, một công ty được thành lập vào năm 2007


Olist là một nền tảng e-commerce của Brazil kết nối các doanh nghiệp bán lẻ với khách hàng thông qua một marketplace trực tuyến

Olist cung cấp các dịch vụ toàn diện từ hỗ trợ đăng bán sản phẩm, quảng bá đến quản lý vận chuyển và xử lý đơn hàng.



[Menu](#)[About Us](#)[@reallygreatsite](#)

Canvas model



[Menu](#)[About Us](#)[@reallygreatsite](#)

Hệ thống sử dụng

Hệ thống quản lý khách hàng: Hệ thống giúp quản lý mối quan hệ với khách hàng, lưu trữ thông tin liên lạc, lịch sử mua hàng, phản hồi và đánh giá của khách hàng, cũng như hỗ trợ quá trình bán hàng và chăm sóc khách hàng.


Hệ thống quản lý sản phẩm: Lưu trữ và xử lý thông tin về sản phẩm như tên, mã, giá cả, tồn kho, và danh mục. Hệ thống này cho phép quản lý sản phẩm dễ dàng, hỗ trợ cập nhật nhanh chóng các thay đổi và tối ưu hóa danh mục sản phẩm

Hệ thống thanh toán: Xử lý các giao dịch thanh toán, bao gồm các phương thức thanh toán trực tuyến, ví điện tử, và các chương trình khuyến mãi. Hệ thống này đảm bảo quá trình thanh toán nhanh chóng, an toàn và đáng tin cậy

Hệ thống kho vận: Theo dõi và quản lý quá trình giao nhận từ người bán đến người mua. Hệ thống này giúp giảm thiểu chi phí vận hành và nâng cao hiệu quả chuỗi cung ứng.




Khảo sát nghiệp vụ mua hàng





Khảo sát nghiệp vụ giao hàng






[Menu](#)

[About Us](#)

[@reallygreatsite](#)

Data flow





Cây nghiệp vụ

[Menu](#)[About Us](#)[@reallygreatsite](#)

[Menu](#)[About Us](#)[@reallygreatsite](#)

Yêu cầu phân tích

Chủ điểm	Chỉ số	Khía cạnh
Khách hàng	Số lượng khách hàng, giá trị trung bình của khách hàng	Thời gian, khu vực, phân khúc khách hàng, địa điểm
Đơn hàng	Doanh thu, Số lượng đơn hàng, Tỷ lệ hủy đơn	Thời gian, địa điểm, ngành hàng, phân khúc khách hàng, hình thức thanh toán
Sản phẩm	Số lượng bán, điểm đánh giá trung bình, tỷ lệ hoàn trả	Ngành hàng, nhà cung cấp, kích thước sản phẩm
Giao hàng	Thời gian giao hàng, Tỷ lệ giao hàng thành công, chi phí vận chuyển	Địa điểm, kích thước sản phẩm, ngành hàng, trạng thái giao hàng, hình thức thanh toán




Cây phân tích yêu cầu





Cây phân tích nhu cầu





Cây phân tích dash board

Khách hàng

- Có bao nhiêu khách hàng theo từng thời gian (theo tháng, quý, năm)?
- Khu vực nào có số lượng khách hàng cao nhất?
- Khách hàng phân bố theo từng phân khúc như thế nào?
- Giá trị trung bình của một khách hàng trong các khu vực có xu hướng gì không?
- Giá trị trung bình của khách hàng theo phân khúc thay đổi như thế nào theo thời gian?

Đơn hàng

- Doanh thu theo từng ngành hàng là bao nhiêu?
- Doanh thu thay đổi theo thời gian (ngày, tháng, quý, năm) như thế nào?
- Khu vực nào đóng góp doanh thu cao nhất?
- Tỷ trọng đơn hàng theo từng hình thức thanh toán như thế nào?
- Số lượng đơn hàng theo từng ngành hàng và phân khúc khách hàng có sự phụ thuộc nào không?
- Tỷ lệ hủy đơn hàng có liên quan gì đến khu vực?
- Ngành hàng nào có tỷ lệ hủy đơn cao nhất?



Cây phân tích dash board

Sản phẩm

- Ngành hàng nào có số lượng sản phẩm bán cao nhất?
- Số lượng sản phẩm bán thay đổi như thế nào theo thời gian?
- Sản phẩm nào nhận được điểm đánh giá cao nhất/thấp nhất?
- Điểm đánh giá trung bình thay đổi như thế nào theo từng nhà cung cấp?
- Ngành hàng nào có tỷ lệ hoàn trả cao nhất?
- Kích thước sản phẩm (nhỏ, trung bình, lớn) có ảnh hưởng đến tỷ lệ hoàn trả không?

Giao hàng

- Thời gian giao hàng trung bình theo khu vực là bao nhiêu?
- Ngành hàng nào có thời gian giao hàng lâu nhất?
- Khu vực nào có tỷ lệ giao hàng thành công cao nhất?
- Tỷ lệ giao hàng thành công theo từng trạng thái giao hàng là bao nhiêu?
- Chi phí vận chuyển trung bình có liên quan gì đến kích thước sản phẩm không?
- Chi phí vận chuyển thay đổi như thế nào theo thời gian và khu vực?

Hệ thống dữ liệu


Nguồn dữ liệu

Kaggle.com
Sinh tự động



Số bảng

7



Kích thước

126.19 MB



Nội dung

Các đơn đặt hàng được thực hiện tại Cửa hàng Olist. Bộ dữ liệu có thông tin khoảng 100.000 đơn đặt hàng từ năm 2016 đến năm 2018.




Tên bộ dữ liệu

Brazilian E-Commerce Public Dataset by Olist




Số trường

52



Thời gian

2016-2018




Tần suất cập nhật dữ liệu

Thông tin tài khoản khách hàng: theo thời gian thực


• Thông tin giao dịch: ngay sau khi giao dịch được thực hiện




Tần suất cập nhật dữ liệu



Cấu trúc dữ liệu




Data taxonomy




1.olist_orders_dataset

- Kích thước: 17.65 MB, Khoảng 100,000 dòng, 8 thuộc tính
- Nội dung: Chứa thông tin về đơn hàng, bao gồm thời gian đặt hàng, trạng thái, và mã khách hàng.
- Các thuộc tính:
 - order_id: ID của đơn hàng (Duy nhất cho mỗi đơn hàng).
 - customer_id: ID của khách hàng (kết nối với bảng olist_customers_dataset).
 - order_status: Trạng thái đơn hàng (đã giao hàng, đang xử lý, hủy bỏ, v.v.).
 - order_purchase_timestamp: Thời gian khách hàng thực hiện giao dịch mua.
 - order_approved_at: Thời gian đơn hàng được xác nhận thanh toán.
 - order_delivered_carrier_date: Thời gian đơn hàng được giao cho hãng vận chuyển.
 - order_delivered_customer_date: Thời gian đơn hàng được giao đến khách hàng.
 - order_estimated_delivery_date: Ngày dự kiến giao hàng.




2. olist_order_items_dataset

- **Kích thước:** Khoảng 15.44 MB, 110,000 dòng, 7 thuộc tính
- **Nội dung:** Chứa thông tin về các sản phẩm trong mỗi đơn hàng, bao gồm số lượng, giá và mã sản phẩm.
- **Các thuộc tính:**
 - **order_id:** ID của đơn hàng (kết nối với bảng `olist_orders_dataset`).
 - **order_item_id:** ID của mục hàng trong đơn hàng.
 - **product_id:** ID của sản phẩm (kết nối với bảng `olist_products_dataset`).
 - **seller_id:** ID của nhà bán hàng (kết nối với bảng `olist_sellers_dataset`).
 - **shipping_limit_date:** Thời hạn cuối để vận chuyển đơn hàng.
 - **price:** Giá của sản phẩm trong đơn hàng.
 - **freight_value:** Phí vận chuyển của sản phẩm.




3. olist_order_payments_dataset

- **Kích thước:** Khoảng 5.78 MB 100,000 dòng, 4 thuộc tính
- **Nội dung:** Chứa thông tin về các giao dịch thanh toán, bao gồm số lượng thanh toán và loại hình thanh toán.
- **Các thuộc tính:**
 - **order_id:** ID của đơn hàng (kết nối với bảng `olist_orders_dataset`).
 - **payment_sequential:** Thứ tự của giao dịch thanh toán cho đơn hàng.
 - **payment_type:** Loại thanh toán (thẻ tín dụng, phiếu thưởng, chuyển khoản ngân hàng, v.v.).
 - **payment_installments:** Số lần trả góp cho giao dịch.
 - **payment_value:** Số tiền của giao dịch thanh toán.




4. olist_order_reviews_dataset

- **Kích thước:** Khoảng 14.45 MB, 100,000 dòng, 7 thuộc tính
- **Nội dung:** Chứa thông tin về đánh giá của khách hàng đối với các đơn hàng.
- **Các thuộc tính:**
 - **review_id:** ID của đánh giá.
 - **order_id:** ID của đơn hàng (kết nối với bảng **olist_orders_dataset**).
 - **review_score:** Điểm đánh giá (từ 1 đến 5).
 - **review_comment_title:** Tiêu đề của đánh giá.
 - **review_comment_message:** Nội dung của đánh giá.
 - **review_creation_date:** Ngày đánh giá được tạo.
 - **review_answer_timestamp:** Ngày đánh giá được phản hồi.




5. olist_products_dataset

- **Kích thước:** Khoảng 2.38 MB, 32,000 dòng, 9 thuộc tính
- **Nội dung:** Chứa thông tin về sản phẩm, bao gồm tên danh mục, chiều cao, chiều rộng, và trọng lượng của sản phẩm.
- **Các thuộc tính:**
 - **product_id:** ID của sản phẩm.
 - **product_category_name:** Tên danh mục của sản phẩm.
 - **product_name_lenght:** Độ dài tên của sản phẩm.
 - **product_description_lenght:** Độ dài phần mô tả sản phẩm.
 - **product_photos_qty:** Số lượng ảnh của sản phẩm.
 - **product_weight_g:** Trọng lượng của sản phẩm (gram).
 - **product_length_cm:** Chiều dài của sản phẩm (cm).
 - **product_height_cm:** Chiều cao của sản phẩm (cm).
 - **product_width_cm:** Chiều rộng của sản phẩm (cm).




6. olist_customers_dataset

- **Kích thước:** Khoảng 9.03MB, 100,000 dòng, 5 thuộc tính
- **Nội dung:** Chứa thông tin về khách hàng, bao gồm mã vùng và ID khách hàng.
- **Các thuộc tính:**
 - **customer_id:** ID của khách hàng.
 - **customer_unique_id:** ID duy nhất của khách hàng (không trùng lặp với khách hàng khác).
 - **customer_zip_code_prefix:** Mã vùng của khách hàng.
 - **customer_city:** Thành phố của khách hàng.
 - **customer_state:** Bang của khách hàng.




7. olist_sellers_dataset

- Kích thước: Khoảng 174.7 KB, 3,000 dòng, 4 thuộc tính
- Nội dung: Chứa thông tin về nhà bán hàng, bao gồm mã vùng và ID nhà bán hàng.
- Các thuộc tính:
 - `seller_id`: ID của nhà bán hàng.
 - `seller_zip_code_prefix`: Mã vùng của nhà bán hàng.
 - `seller_city`: Thành phố của nhà bán hàng.
 - `seller_state`: Bang của nhà bán hàng.



8. olist_geolocation_dataset

- **Kích thước:** Khoảng 61.27MB, 1,000,000 dòng, 5 thuộc tính
- **Nội dung:** Cung cấp thông tin địa lý cho mã vùng tại Brazil, bao gồm vĩ độ và kinh độ.
- **Các thuộc tính:**
 - `geolocation_zip_code_prefix`: Mã vùng địa lý.
 - `geolocation_lat`: Vĩ độ của mã vùng.
 - `geolocation_lng`: Kinh độ của mã vùng.
 - `geolocation_city`: Thành phố tương ứng với mã vùng.
 - `geolocation_state`: Bang tương ứng với mã vùng.




9. product_category_name_translation


- Kích thước: Khoảng 2.61kB, 71 dòng, 2 thuộc tính
- Nội dung: Thông tin phiên dịch danh mục sản phẩm
- Các thuộc tính:
 - `product_catagory_name`: Tên danh mục sản phẩm tiếng Tây Ban Nha
 - `product_catagory_name_english`: Tên danh mục sản phẩm Tiếng Anh



```
graph LR; A[product_catagory_name] --> C[product_category_name_translation]; B[product_catagory_name_english] --> C;
```




Dimension



OLTP sang OLAP

 Nhóm 10

Fact





fact_Sản_phẩm: product_id, product_category_name, order_id, price, freight_value

fact_Khách_hàng: customer_id, customer_unique_id, customer_zip_code_prefix, order_id, payment_value, review_id

fact_Đơn_hàng: order_id, customern_id, order_status, order_purchased_timestamp, order_approved_at, payment_type, payment_value, payment_installments.

fact_Giao_hàng: order_id, order_status, order_purchase_timestamp, order_delivered_carrier_date, order_delivered_customer_date, order_estimated_delivery_date, freight_value

Khám phá dữ liệu



Kiến trúc Data Warehouse



ETL



Hệ thống chiều khái niệm



Data Model



II. Phân tích & Thiết kế



Tổng quan bộ dữ liệu

Thành phố

8010

Bang

27

Khách hàng

96.10K

Số lượng đánh giá

98.41K

Điểm đánh giá trung
bình

4.09

Doanh thu

16.01M

Số lượng sản phẩm

32.95K

Danh mục sản phẩm

71

Hình thức thanh toán

5



Đặc trưng dữ liệu

	delivery_time	freight_value	payment_value	price	review_score
count	96476	112650	103886	112650	99224
mean	12.09408558	19.99031993	154.1003804	120.653739	4.086420624
std	9.551746107	15.80640541	217.4940639	183.6339281	1.347579131
min	0	0	0	0.85	1
25%	6	13.08	56.79	39.9	4
50%	10	16.26	100	74.99	5
75%	15	21.15	171.8375	134.9	5
max	209	409.68	13664.08	6735	5
max	209	409.68	13664.08	6735	5



Ma trận hệ số tương quan

"freight_value" và "price" có mức tương quan trung bình với hệ số 0.41. Điều này gợi ý rằng giá trị cước vận chuyển và giá sản phẩm có mối quan hệ nhất định


```
# Chuyển đổi các cột thời gian sang kiểu ngày-thời gian và tính toán thời gian giao hàng
orders_df$order_purchase_timestamp <- as.POSIXct(orders_df$order_purchase_timestamp, format="%Y-%m-%d %H:%M:%S")
orders_df$order_delivered_customer_date <- as.POSIXct(orders_df$order_delivered_customer_date, format="%Y-%m-%d %H:%M:%S")
orders_df$delivery_time <- as.numeric(difftime(orders_df$order_delivered_customer_date, orders_df$order_purchase_timestamp, units="secs"))


# Kết hợp các trường từ các bảng khác nhau thành một data frame duy nhất
data <- data.frame(
  freight_value = order_items_df$freight_value,
  price = order_items_df$price,
  payment_value = order_payments_df$payment_value,
  review_score = order_reviews_df$review_score,
  delivery_time = orders_df$delivery_time
)

# Loại bỏ các hàng chứa giá trị NA nếu có
data <- na.omit(data)

# Tính ma trận tương quan
correlation_matrix <- cor(data)


# Vẽ ma trận tương quan
ggcorrplot(correlation_matrix, lab = TRUE, lab_size = 3, colors = c("blue", "white", "red"), title = "Correlation Matrix of Selected Fields")
```





Số lượng đơn hàng và xu hướng thanh toán theo thời gian


Số lượng đơn hàng bán ra vào khoảng cuối tháng 11 năm 2017 đạt đỉnh, điều này có thể giải thích là do hiệu ứng của ngày Black Friday, khi sàn tung các voucher giảm giá sâu để thu hút người mua hàng.





Số lượng người bán và mua theo từng bang


Bang SP là thị trường lớn nhất của Olist





Doanh thu theo hình thức thanh toán


Hai phương thức chính – thẻ tín dụng và boleto – chi phối gần như toàn bộ doanh thu. Điều này cho thấy Olist nên tập trung vào các phương thức này để tối ưu trải nghiệm khách hàng, do chúng đáp ứng phần lớn nhu cầu thanh toán.





Doanh thu top 10 danh mục sản phẩm


Các danh mục sản phẩm chủ yếu liên quan đến sức khỏe, quà tặng, và đồ gia dụng có doanh thu cao và chiếm tỷ trọng lớn trong tổng doanh thu tích lũy.





Tương quan giữa cước phí vận chuyển với kích thước cũng như khối lượng sản phẩm


Cước phí vận chuyển có xu hướng tăng nhẹ khi khối lượng và thể tích sản phẩm tăng, nhưng không hoàn toàn tuyến tính hoặc rõ ràng. Điều này cho thấy cước phí không chỉ phụ thuộc vào kích thước hay khối lượng mà có thể còn bị ảnh hưởng bởi các yếu tố khác như loại hình vận chuyển, khoảng cách, hoặc chính sách cước phí cố định cho các mức khối lượng/thể tích nhất định.





Tương quan giữa ngày giao hàng dự kiến và thực tế


Các điểm dữ liệu tập trung gần đường chéo, cho thấy ngày giao hàng thực tế thường sát với ngày giao hàng dự kiến. Tuy nhiên, cũng có một số điểm nằm xa đường chéo, biểu hiện sự chậm trễ hoặc giao hàng sớm hơn dự kiến. Xu hướng chung này cho thấy hệ thống dự đoán ngày giao hàng khá chính xác, mặc dù vẫn có một số ngoại lệ.



PHÂN TÍCH KHUYNH HƯỚNG


XU HƯỚNG

- Xu hướng dài hạn:
 - Biểu đồ khuynh hướng cho thấy số lượng đơn hàng tăng đều từ năm 2016 đến đầu năm 2018, sau đó có dấu hiệu giảm nhẹ.
- Ý nghĩa:
 - Giai đoạn tăng trưởng đều đặn cho thấy doanh nghiệp đã mở rộng thị trường thành công hoặc có chiến lược thu hút khách hàng hiệu quả.




MÙA

- **Quan sát mùa vụ:**
 - Chu kỳ tăng mạnh rõ rệt vào cuối năm, đặc biệt là tháng 11–12. Đây có thể trùng với mùa lễ hội hoặc các sự kiện bán hàng lớn.
 - Mùa thấp điểm thường rơi vào các tháng giữa năm, có thể do giảm chi tiêu sau mùa lễ hội.
- **Ý nghĩa:**
 - Doanh nghiệp nên tập trung nguồn lực vào giai đoạn cao điểm (cuối năm) để tăng doanh số.
 - Xây dựng các chiến lược khuyến mãi nhằm kích cầu vào giai đoạn thấp điểm giữa năm.




DƯ

- **Phân tích phần dư:**
 - Phần dư dao động quanh mức 0, ngoại trừ một số tháng có giá trị lớn (có thể do yếu tố bất thường).
 - Biểu đồ phần dư tăng mạnh từ năm 2018, cho thấy mô hình chưa giải thích được hết các yếu tố tác động.
- **Ý nghĩa:**
 - Các yếu tố bất thường có thể liên quan đến các chiến dịch marketing, thay đổi chính sách hoặc sự kiện đặc biệt không lặp lại.



HOẠT ĐỘNG ĐỀ XUẤT



1. Tối ưu mùa cao điểm:

- Đẩy mạnh marketing vào cuối năm.
- Cung cấp nhiều ưu đãi hoặc giảm giá lớn trong các tháng lễ hội.

2. Kích cầu mùa thấp điểm:

- Tạo các chiến dịch khuyến mãi để tăng nhu cầu giữa năm.

3. Phân tích sâu phần dư:

- Kiểm tra các sự kiện bất thường hoặc yếu tố nội bộ ảnh hưởng đến số lượng đơn hàng.

4. Tăng cường dự báo:

- Xây dựng các mô hình dự báo chuỗi thời gian chính xác hơn để dự đoán nhu cầu.



Customer 1



Customer 2






Customer 3



Customer n




Kiến trúc Data Warehouse





Data Pipeline



© Nội dung ETL

DATA SOURCE —————> STAGING

- Xoá các cột không cần thiết
- Xử lý các giá trị NULL
- Xóa dữ liệu bị trùng
- Gộp dữ liệu
- Thêm trường dữ liệu mới
- Định dạng lại trường dữ liệu
- Chuyển đổi kiểu dữ liệu



© Nội dung ETL

 **customers**

```
column_to_drop = 'customer_city'  
dataCustomers.drop(column_to_drop, axis=1, inplace=True)
```

Data columns (total 5 columns):

#	Column	Non-Null Count	Dtype
0	customer_id	99441 non-null	object
1	customer_unique_id	99441 non-null	object
2	customer_zip_code_prefix	99441 non-null	int64
3	customer_city	99441 non-null	object
4	customer state	99441 non-null	object

BEFORE

Xóa cột không cần thiết

Data columns (total 4 columns):

#	Column	Non-Null Count	Dtype
0	customer_id	99441 non-null	object
1	customer_unique_id	99441 non-null	object
2	customer_zip_code_prefix	99441 non-null	int64
3	customer state	99441 non-null	object

AFTER

© Nội dung ETL



customers

```
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler

# Step 1: Load Data
orders = dataOrders
order_items = dataOrderItem
customers = dataCustomers

# Step 2: Prepare RFM Data
orders['order_purchase_timestamp'] = pd.to_datetime(orders['order_purchase_timestamp'])
current_date = orders['order_purchase_timestamp'].max()
recency = orders.groupby('customer_id').order_purchase_timestamp.max().reset_index()
recency['Recency'] = (current_date - recency['order_purchase_timestamp']).dt.days
recency = recency[['customer_id', 'Recency']]
frequency = orders.groupby('customer_id').order_id.count().reset_index()
frequency.columns = ['customer_id', 'Frequency']
order_items = order_items.merge(orders[['order_id', 'customer_id']], on='order_id')
monetary = order_items.groupby('customer_id').price.sum().reset_index()
monetary.columns = ['customer_id', 'Monetary']
rfm = recency.merge(frequency, on='customer_id').merge(monetary, on='customer_id')

# Step 3: Standardize Data
scaler = StandardScaler()
rfm_scaled = scaler.fit_transform(rfm[['Recency', 'Frequency', 'Monetary']])

# Step 4: Apply KMeans Clustering
kmeans = KMeans(n_clusters=4, random_state=0, n_init=10)
rfm['Cluster'] = kmeans.fit_predict(rfm_scaled)
```

Sử dụng mô hình
RFM để phân khúc
khách hàng

© Nội dung ETL



customers

```
# Step 5: Analyze Each Cluster's Average RFM Values
cluster_summary = rfm.groupby('Cluster').agg({
    'Recency': 'mean',
    'Frequency': 'mean',
    'Monetary': 'mean'
}).reset_index()

# Step 6: Define Labels for Each Cluster Based on Characteristics
cluster_labels = {}
for index, row in cluster_summary.iterrows():
    if row['Recency'] < 60 and row['Frequency'] > 5 and row['Monetary'] > 500:
        cluster_labels[row['Cluster']] = 'Champions'
    elif row['Recency'] < 60 and row['Frequency'] > 2:
        cluster_labels[row['Cluster']] = 'Potential Loyalists'
    elif row['Recency'] >= 60 and row['Frequency'] > 5:
        cluster_labels[row['Cluster']] = 'Loyal Customers'
    elif row['Recency'] >= 60 and row['Monetary'] > 300:
        cluster_labels[row['Cluster']] = 'At Risk'
    else:
        cluster_labels[row['Cluster']] = 'Hibernating'

# Step 7: Map Cluster Labels to Each Customer
rfm['Segment'] = rfm['Cluster'].map(cluster_labels)

# Step 8: Merge Segments with Customer Data and Save to CSV
customers_segmented = customers.merge(rfm[['customer_id', 'Segment']], on='customer_id', how='left')
```

**Sử dụng mô hình
RFM để phân khúc
khách hàng**

© Nội dung ETL

 **customers**

customer_id	customer_unique_id	customer_zip_code_prefix	customer_state
a1fbc88172c00ba8bc7	861eff4711a542e4b93843c6dd7febb0	14409	SP
d6b2def6b18a428ac77	290c77bc529b7ac935b93aa66c333dc3	9790	SP
6ebd08712fdd0374a03	060e732b5b29e8181a18229c7b0b2b5e	1151	SP
09e529d4dc6358b12c3	259dac757896d24d7702b9acbbff3f3c	8775	SP
ec8364f7c12e35b23ad	345ecd01c38d18a9036ed96c73b8d066	13056	SP

Sử dụng mô hình RFM để phân khúc khách hàng



customer_id	customer_unique_id	customer_zip_code_prefix	customer_state	Segment
a1fbc88172c00ba8bc7	861eff4711a542e4b93843c6dd7febb0	14409	SP	Hibernating
d6b2def6b18a428ac77	290c77bc529b7ac935b93aa66c333dc3	9790	SP	Hibernating
6ebd08712fdd0374a03	060e732b5b29e8181a18229c7b0b2b5e	1151	SP	Hibernating
09e529d4dc6358b12c3	259dac757896d24d7702b9acbbff3f3c	8775	SP	Hibernating
ec8364f7c12e35b23ad	345ecd01c38d18a9036ed96c73b8d066	13056	SP	Hibernating

© Nội dung ETL

```
column_to_drop = 'geolocation_city'  
dataGeo.drop(column_to_drop, axis=1, inplace=True)
```



geolocations

Data columns (total 5 columns):

#	Column	Non-Null Count		Dtype
---	-----	-----		-----
0	geolocation_zip_code_prefix	1000163	non-null	int64
1	geolocation_lat	1000163	non-null	float64
2	geolocation_lng	1000163	non-null	float64
3	geolocation_city	1000163	non-null	object
4	geolocation state	1000163	non-null	object

Xóa cột không cần thiết



Data columns (total 4 columns):

#	Column	Non-Null Count		Dtype
---	-----	-----		-----
0	geolocation_zip_code_prefix	1000163	non-null	int64
1	geolocation_lat	1000163	non-null	float64
2	geolocation_lng	1000163	non-null	float64
3	geolocation state	1000163	non-null	object

© Nội dung ETL



geolocations

```
# Loại bỏ các dòng trùng lặp dựa trên các cột 'geolocation_zip_code_prefix' và 'geolocation_state'  
dataGeo = dataGeo.drop_duplicates(subset=['geolocation_zip_code_prefix', 'geolocation_state'])
```

Data columns (total 4 columns):

#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	geolocation_zip_code_prefix	1000163	non-null	int64
1	geolocation_lat	1000163	non-null	float64
2	geolocation_lng	1000163	non-null	float64
3	geolocation state	1000163	non-null	object

Lọc trùng



Data columns (total 4 columns):

#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	geolocation_zip_code_prefix	19023	non-null	int64
1	geolocation_lat	19023	non-null	float64
2	geolocation_lng	19023	non-null	float64
3	geolocation_state	19023	non-null	object

© Nội dung ETL

```
def phanloai(x):  
    if x in ['AC', 'AP',  
            'AM', 'PA',  
            'RO',  
            'RR', 'TO']:  
        return 'North'  
    elif x in ['AL', 'BA',  
              'CE', 'MA', 'PB',  
              'PE', 'PI', 'RN',  
              'SE']:  
        return 'Northeast'  
    elif x in ['DF', 'GO',  
              'MT', 'MS']:  
        return 'Midwest'  
    elif x in ['ES', 'MG', 'RJ',  
              'SP']:  
        return 'Southeast'  
    elif x in ['PR', 'RS', 'SC']:  
        return 'South'  
  
dataGeo['region'] = dataGeo.geolocation_state.apply(phanloai)
```



geolocations

Dùng chatgpt để
phân cụm giúp
region

© Nội dung ETL

 **geolocations**

Data columns (total 4 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----		-----
0	geolocation_zip_code_prefix	19023	non-null	int64
1	geolocation_lat	19023	non-null	float64
2	geolocation_lng	19023	non-null	float64
3	geolocation_state	19023	non-null	object

Dùng chatgpt để
phân cụm giúp
region



Data columns (total 5 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----		-----
0	geolocation_zip_code_prefix	19023	non-null	int64
1	geolocation_lat	19023	non-null	float64
2	geolocation_lng	19023	non-null	float64
3	geolocation_state	19023	non-null	object
4	region	19023	non-null	object

© Nội dung ETL

 **products**

A ⁰ _C product_id	A ⁰ _C product_category_name	T ² ₃ product_name_lenght	T ² ₃ product_description_lenght	T ² ₃ product_photos_qty	T ² ₃ product_weight_g
1e9e8ef04dbcff4541ed26657ea517e5	perfumaria	40	287	1	
3aa071139cb16b67ca9e5dea641aaa...	artes	44	276	1	
96bd76ec8810374ed1b65e2919757...	esporte_lazer	46	250	1	
cef67bcfe19066a932b7673e239eb23d	bebes	27	261	1	
9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	37	402	4	
41d3672d4792049fa1779bb35283e...	instrumentos_musicais	60	745	1	
732bd381ad09e530fe0a5f457d81be...	cool_stuff	56	1272	4	
2548af3e6e77a690cf3eb6368e9ab61e	moveis_decoracao	56	184	2	
37cc742be07708b53a98702e77a21a...	eletrodomesticos	57	163	1	
8c92109888e8cdf9d66dc7e4630255...	brinquedos	36	1156	1	
14aa47b7fe5c25522b47b4b29c98dc...	cama_mesa_banho	54	630	1	
03b63c5fc16691530586ae020c3455...	bebes	49	728	4	
cf55509ea8edaaac1d28fdb16e48fc22	instrumentos_musicais	43	1827	3	
7bb6f29c2be57716194f96496660c7c2	moveis_decoracao	51	2083	2	
eb31436580a610f202c859463d8c74...	construcao_ferramentas_seguranca	59	1602	4	

Loại bỏ trường
không cần thiết,
xóa null, xóa trùng



A ⁰ _C product_id	A ⁰ _C product_category_name	T ² ₃ product_weight_g	T ² ₃ product_length_cm	T ² ₃ product_height_cm	T ² ₃ product_width_cm
1e9e8ef04dbcff4541ed26657ea517e5	perfumaria	225	16	10	14
3aa071139cb16b67ca9e5dea641aaa...	artes	1000	30	18	20
96bd76ec8810374ed1b65e2919757...	esporte_lazer	154	18	9	15
cef67bcfe19066a932b7673e239eb23d	bebes	371	26	4	26
9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	625	20	17	13
41d3672d4792049fa1779bb35283e...	instrumentos_musicais	200	38	5	11
732bd381ad09e530fe0a5f457d81be...	cool_stuff	18350	70	24	44
2548af3e6e77a690cf3eb6368e9ab61e	moveis_decoracao	900	40	8	40
37cc742be07708b53a98702e77a21a...	eletrodomesticos	400	27	13	17
8c92109888e8cdf9d66dc7e4630255...	brinquedos	600	17	10	12
14aa47b7fe5c25522b47b4b29c98dc...	cama_mesa_banho	1100	16	10	16
03b63c5fc16691530586ae020c3455...	bebes	7150	50	19	45
cf55509ea8edaaac1d28fdb16e48fc22	instrumentos_musicais	250	17	7	17
7bb6f29c2be57716194f96496660c7c2	moveis_decoracao	600	68	11	13
eb31436580a610f202c859463d8c74...	construcao_ferramentas_seguranca	200	17	7	17

© Nội dung ETL

 products

AB_C product_id	AB_C product_category_name	1^2_3 product_weight_g	1^2_3 product_length_cm	1^2_3 product_height_cm	1^2_3 product_width_cm
1e9e8ef04dbcff4541ed26657ea517e5	perfumaria	225	16	10	14
3aa071139cb16b67ca9e5dea641aaa...	artes	1000	30	18	20
96bd76ec8810374ed1b65e2919757...	esporte_lazer	154	18	9	15
cef67bcfe19066a932b7673e239eb23d	bebes	371	26	4	26
9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	625	20	17	13
41d3672d4792049fa1779bb35283e...	instrumentos_musicais	200	38	5	11
732bd381ad09e530fe0a5f457d81be...	cool_stuff	18350	70	24	44
2548af3e6e77a690cf3eb6368e9ab61e	moveis_decoracao	900	40	8	40
37cc742be07708b53a98702e77a21a...	eletrodomesticos	400	27	13	17
8c92109888e8cdf9d66dc7e4630255...	brinquedos	600	17	10	12
14aa47b7fe5c25522b47b4b29c98dc...	cama_mesa_banho	1100	16	10	16
03b63c5fc16691530586ae020c3455...	bebes	7150	50	19	45
cf55509ea8edaaac1d28fdb16e48fc22	instrumentos_musicais	250	17	7	17
7bb6f29c2be57716194f96496660c7c2	moveis_decoracao	600	68	11	13
eb31436580a610f202c859463d8c74...	construcao_ferramentas_seguranca	200	17	7	17

Tính cột mới volume =
product_length_cm*product_height_cm*product_width_cm. Sau
đó xóa các cột
product_length_cm,
product_height_cm,
product_width_cm.



AB_C product_id	AB_C product_category_name	1^2_3 product_weight_g	ABC 123 volume
1e9e8ef04dbcff4541ed26657ea517e5	perfumaria	225	2240
3aa071139cb16b67ca9e5dea641aaa...	artes	1000	10800
96bd76ec8810374ed1b65e2919757...	esporte_lazer	154	2430
cef67bcfe19066a932b7673e239eb23d	bebes	371	2704
9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	625	4420
41d3672d4792049fa1779bb35283e...	instrumentos_musicais	200	2090
732bd381ad09e530fe0a5f457d81be...	cool_stuff	18350	73920
2548af3e6e77a690cf3eb6368e9ab61e	moveis_decoracao	900	12800
37cc742be07708b53a98702e77a21a...	eletrodomesticos	400	5967
8c92109888e8cdf9d66dc7e4630255...	brinquedos	600	2040
14aa47b7fe5c25522b47b4b29c98dc...	cama_mesa_banho	1100	2560
03b63c5fc16691530586ae020c3455...	bebes	7150	42750

© Nội dung ETL

 **products**

● Thêm cột review_score

```
# Merge dataPro and dataOrderItem based on 'product_id'
merged_df = pd.merge(dataPro, dataOrderItem, on='product_id')

# Merge dataOrderItem and dataReview (selecting 'order_id' and 'review_score') based on 'order_id'
merged_order_df = pd.merge(dataOrderItem, dataReview[['order_id', 'review_score']], on='order_id', how='left')

# Merge merged_order_df and dataPro based on 'product_id'
final_merged_df = pd.merge(merged_order_df, dataPro, on='product_id', how='left')

# Calculate average review score per product
average_review_score_per_product = final_merged_df.groupby('product_id')['review_score'].mean()

# Merge the average review scores back into dataPro
dataPro = pd.merge(dataPro, average_review_score_per_product, on='product_id', how='left')
```

© Nội dung ETL

 **products**

Data columns (total 4 columns):

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	product_id	32341 non-null	object
1	product_category_name	32341 non-null	object
2	product_weight_g	32340 non-null	float64
3	volume	32340 non-null	float64

**Thêm cột
review_score**



Data columns (total 5 columns):

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	product_id	32341 non-null	object
1	product_category_name	32341 non-null	object
2	product_weight_g	32340 non-null	float64
3	volume	32340 non-null	float64
4	review_score	32184 non-null	float64

© Nội dung ETL



products

```
def phanloai(score):  
    if score >= 4:  
        return 'Good'  
    elif score >= 3:  
        return 'Average'  
    elif score.isna():  
        return 'No Review'  
    else:  
        return 'Poor'  
dataPro['product_quality'] = dataPro['review_score'].apply(phanloai)
```

**Thêm cột
product_quality**

© Nội dung ETL



products

Data columns (total 5 columns):

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	product_id	32341 non-null	object
1	product_category_name	32341 non-null	object
2	product_weight_g	32340 non-null	float64
3	volume	32340 non-null	float64
4	review_score	32184 non-null	float64

**Thêm cột
product_quality**



Data columns (total 6 columns):

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	product_id	32341 non-null	object
1	product_category_name	32341 non-null	object
2	product_weight_g	32340 non-null	float64
3	volume	32340 non-null	float64
4	review_score	32184 non-null	float64
5	product_quality	32341 non-null	object

© Nội dung ETL

```
column_to_drop = ['review_comment_title',  
                  'review_comment_message', 'review_creation_date',  
                  'review_answer_timestamp']  
dataReview.drop(column_to_drop, axis=1, inplace=True)
```



reviews

Data columns (total 7 columns):

#	Column	Non-Null Count	Dtype
0	review_id	99224 non-null	object
1	order_id	99224 non-null	object
2	review_score	99224 non-null	int64
3	review_comment_title	11568 non-null	object
4	review_comment_message	40977 non-null	object
5	review_creation_date	99224 non-null	object
6	review_answer_timestamp	99224 non-null	object

Xóa cột không cần thiết



Data columns (total 3 columns):

#	Column	Non-Null Count	Dtype
0	review_id	99224 non-null	object
1	order_id	99224 non-null	object
2	review score	99224 non-null	int64

© Nội dung ETL

 payments

```
column_to_drop = ['payment_sequential']  
dataPayment.drop(column_to_drop, axis=1, inplace=True)
```

```
Data columns (total 5 columns):  
#      Column                Non-Null Count  Dtype  
---  -  
0     order_id               103886 non-null  object  
1     payment_sequential     103886 non-null  int64  
2     payment_type           103886 non-null  object  
3     payment_installments   103886 non-null  int64  
4     payment_value          103886 non-null  float64
```

Xóa cột không cần thiết



```
Data columns (total 4 columns):  
#      Column                Non-Null Count  Dtype  
---  -  
0     order_id               103886 non-null  object  
1     payment_type           103886 non-null  object  
2     payment_installments   103886 non-null  int64  
3     payment value          103886 non-null  float64
```

© Nội dung ETL

 payments

Thêm cột xác định
payment_method

```
def std(x):  
    if x == 'voucher':  
        return 0  
    else:  
        return 1  
dataPayment['payment_count_sum'] = dataPayment.payment_type.apply(std)  
def method(x):  
    if x > 1:  
        return 1  
    else:  
        return 0  
dataPayment['payment_method'] = dataPayment.payment_count_sum.apply(method)
```


© Nội dung ETL

 payments

● Thêm cột xác định payment_method

Data columns (total 4 columns):			
#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	order_id	103886 non-null	object
1	payment_type	103886 non-null	object
2	payment_installments	103886 non-null	int64
3	payment_value	103886 non-null	float64



Data columns (total 6 columns):			
#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	order_id	103886 non-null	object
1	payment_type	103886 non-null	object
2	payment_installments	103886 non-null	int64
3	payment_value	103886 non-null	float64
4	payment_count_sum	103886 non-null	int64
5	payment_method	103886 non-null	int64

© Nội dung ETL

```
column_to_drop = ['seller_city']  
dataSeller.drop(column_to_drop, axis=1, inplace=True)
```

 **sellers**

```
Data columns (total 4 columns):  
#      Column                                Non-Null Count  Dtype  
---  -  
0     seller_id                             3095 non-null   object  
1     seller_zip_code_prefix                3095 non-null   int64  
2     seller_city                           3095 non-null   object  
3     seller_state                          3095 non-null   object
```

Xóa cột không cần thiết



```
Data columns (total 3 columns):  
#      Column                                Non-Null Count  Dtype  
---  -  
0     seller_id                             3095 non-null   object  
1     seller_zip_code_prefix                3095 non-null   int64  
2     seller_state                          3095 non-null   object
```

© Nội dung ETL

```
# Loại bỏ các dòng có giá trị NaN từ DataFrame
dataOrders = dataOrders.dropna()
```

 **orders**

Data columns (total 8 columns):

#	Column	Non-Null Count	Dtype
0	order_id	99441 non-null	object
1	customer_id	99441 non-null	object
2	order_status	99441 non-null	object
3	order_purchase_timestamp	99441 non-null	object
4	order_approved_at	99281 non-null	object
5	order_delivered_carrier_date	97658 non-null	object
6	order_delivered_customer_date	96476 non-null	object
7	order_estimated_delivery_date	99441 non-null	object

Bỏ null



Data columns (total 8 columns):

#	Column	Non-Null Count	Dtype
0	order_id	96461 non-null	object
1	customer_id	96461 non-null	object
2	order_status	96461 non-null	object
3	order_purchase_timestamp	96461 non-null	object
4	order_approved_at	96461 non-null	object
5	order_delivered_carrier_date	96461 non-null	object
6	order_delivered_customer_date	96461 non-null	object
7	order_estimated_delivery_date	96461 non-null	object

© Nội dung ETL

 **orders**

**Chuyển định dạng, thêm
cột order_shipping_days**

```
# Chuyển đổi các cột thời gian sang định dạng datetime
dataOrders['order_purchase_timestamp'] = pd.to_datetime(dataOrders['order_purchase_timestamp'])
dataOrders['order_approved_at'] = pd.to_datetime(dataOrders['order_approved_at'])
dataOrders['order_delivered_carrier_date'] = pd.to_datetime(dataOrders['order_delivered_carrier_date'])
dataOrders['order_delivered_customer_date'] = pd.to_datetime(dataOrders['order_delivered_customer_date'])
dataOrders['order_estimated_delivery_date'] = pd.to_datetime(dataOrders['order_estimated_delivery_date'])

# Thêm cột 'shipping_days' vào DataFrame
dataOrders['order_shipping_days'] = (dataOrders['order_delivered_customer_date'].dt.date - dataOrders['order_purchase_timestamp'].dt.date).dt.days
```


© Nội dung ETL

 **orders**

```
Data columns (total 8 columns):
#      Column                                Non-Null Count  Dtype
---  -
0     order_id                               96461 non-null  object
1     customer_id                             96461 non-null  object
2     order_status                             96461 non-null  object
3     order_purchase_timestamp                96461 non-null  object
4     order_approved_at                       96461 non-null  object
5     order_delivered_carrier_date             96461 non-null  object
6     order_delivered_customer_date            96461 non-null  object
7     order_estimated_delivery_date            96461 non-null  object
```

**Chuyển định
dạng, thêm cột
order_shipping_day**



```
Data columns (total 9 columns):
#      Column                                Non-Null Count  Dtype
---  -
0     order_id                               96461 non-null  object
1     customer_id                             96461 non-null  object
2     order_status                             96461 non-null  object
3     order_purchase_timestamp                96461 non-null  datetime64[ns]
4     order_approved_at                       96461 non-null  datetime64[ns]
5     order_delivered_carrier_date             96461 non-null  datetime64[ns]
6     order_delivered_customer_date            96461 non-null  datetime64[ns]
7     order_estimated_delivery_date            96461 non-null  datetime64[ns]
8     order_shipping_days                      96461 non-null  object
```

© Nội dung ETL

 orders

**Chuyển định dạng của
ordershippingday và lọc
bỏ dữ liệu không hợp lệ**

```
dataOrders['order_shipping_days'] = dataOrders['order_shipping_days'].apply(lambda x: x.days)
# Lọc bỏ dữ liệu không hợp lệ
filtered_dataOrders = dataOrders[
    ~(
        (dataOrders['order_shipping_days'] < 0) & # So sánh với 0 thay vì pd.Timedelta(days=0)
        dataOrders['order_delivered_carrier_date'].notnull() &
        dataOrders['order_delivered_customer_date'].notnull()
    )
]
```


© Nội dung ETL

 **orders**

**Chuyển định dạng
của ordershippingday
và lọc bỏ dữ liệu
không hợp lệ**

Data columns (total 9 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----		-----
0	order_id	96461	non-null	object
1	customer_id	96461	non-null	object
2	order_status	96461	non-null	object
3	order_purchase_timestamp	96461	non-null	datetime64[ns]
4	order_approved_at	96461	non-null	datetime64[ns]
5	order_delivered_carrier_date	96461	non-null	datetime64[ns]
6	order_delivered_customer_date	96461	non-null	datetime64[ns]
7	order_estimated_delivery_date	96461	non-null	datetime64[ns]
8	order_shipping_days	96461	non-null	object



Data columns (total 9 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----		-----
0	order_id	96441	non-null	object
1	customer_id	96441	non-null	object
2	order_status	96441	non-null	object
3	order_purchase_timestamp	96441	non-null	datetime64[ns]
4	order_approved_at	96441	non-null	datetime64[ns]
5	order_delivered_carrier_date	96441	non-null	datetime64[ns]
6	order_delivered_customer_date	96441	non-null	datetime64[ns]
7	order_estimated_delivery_date	96441	non-null	datetime64[ns]
8	order_shipping_days	96441	non-null	int64

© Nội dung ETL

 orders

**Tạo cột arrival_status
đánh giá tình trạng vận
chuyển**

```
# Tạo cột 'arrival_status' bằng cách tính số ngày chênh lệch so với thời gian ước tính
dataOrders['arrival_status'] = dataOrders['order_delivered_customer_date'] - dataOrders['order_estimated_delivery_date']

# Áp dụng hàm lambda để ánh xạ giá trị của 'arrival_status' thành 'Early', 'OnTime', hoặc 'Late'
dataOrders['arrival_status'] = dataOrders['arrival_status'].apply(
    lambda x: 'Early' if x < pd.Timedelta(days=0) else ('OnTime' if x == pd.Timedelta(days=0) else 'Late')
)
```


© Nội dung ETL

```
Data columns (total 9 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   order_id                             96441 non-null   object
1   customer_id                           96441 non-null   object
2   order_status                           96441 non-null   object
3   order_purchase_timestamp               96441 non-null   datetime64[ns]
4   order_approved_at                     96441 non-null   datetime64[ns]
5   order_delivered_carrier_date            96441 non-null   datetime64[ns]
6   order_delivered_customer_date           96441 non-null   datetime64[ns]
7   order_estimated_delivery_date           96441 non-null   datetime64[ns]
8   order_shipping_days                    96441 non-null   int64
```



orders

**Tạo cột arrival_status
đánh giá tình trạng
vận chuyển**



```
Data columns (total 10 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   order_id                             96461 non-null   object
1   customer_id                           96461 non-null   object
2   order_status                           96461 non-null   object
3   order_purchase_timestamp               96461 non-null   datetime64[ns]
4   order_approved_at                     96461 non-null   datetime64[ns]
5   order_delivered_carrier_date            96461 non-null   datetime64[ns]
6   order_delivered_customer_date           96461 non-null   datetime64[ns]
7   order_estimated_delivery_date           96461 non-null   datetime64[ns]
8   order_shipping_days                    96461 non-null   int64
9   arrival_status                         96461 non-null   object
```

© Nội dung ETL

```
# Định nghĩa hàm phân loại danh mục sản phẩm
def phanloai(x):
    if x in ['office_furniture', 'furniture_decor', 'furniture_living_room', 'bed_bath_table',
            'kitchen_dining_laundry_garden_furniture', 'garden_tools', 'home_comfort', 'home_comfort_2',
            'home_construction', 'furniture_bedroom', 'furniture_mattress_and_upholstery']:
        return 'Furniture'
    elif x in ['auto', 'computers_accessories', 'musical_instruments', 'consoles_games', 'watches_gifts',
            'air_conditioning', 'telephony', 'electronics', 'fixed_telephony', 'tablets_printing_image', 'cc',
            'small_appliances_home_oven_and_coffee', 'small_appliances', 'audio', 'signaling_and_security', '':
        return 'Electronics'
    elif x in ['fashion_female_clothing', 'fashion_male_clothing', 'fashion_bags_accessories', 'fashion_shoes',
            'fashion_underwear_beach', 'fashion_childrens_clothes', 'baby', 'cool_stuff']:
        return 'Fashion'
    elif x in ['housewares', 'home_comfort', 'home_appliances', 'home_appliances_2', 'flowers', 'costruction_tools',
            'garden_tools', 'construction_tools_lights', 'costruction_tools_tools', 'luggage_accessories',
            'la_cuisine', 'pet_shop', 'market_place']:
        return 'Home & Garden'
    elif x in ['sports_leisure', 'toys', 'cds_dvds_musicals', 'music', 'dvds_blu_ray', 'cine_photo', 'party_supplies',
            'christmas_supplies', 'arts_and_craftmanship', 'art']:
        return 'Entertainment'
    elif x in ['health_beauty', 'perfumery', 'diapers_and_hygiene']:
        return 'Beauty & Health'
    elif x in ['food_drink', 'drinks', 'food']:
        return 'Food & Drinks'
    elif x in ['books_general_interest', 'books_technical',
            'books_imported', 'stationery']:
        return 'Books & Stationery'
    elif x in ['construction_tools_construction', 'construction_tools_safety', 'industry_commerce_and_business',
            'agro_industry_and_commerce']:
        return 'Industry & Construction'
```



translations

**Dùng
ChatGPT
phân
cụm
danh
mục**

© Nội dung ETL

Data columns (total 2 columns):

#	Column	Non-Null Count	Dtype
0	product_category_name	71 non-null	object
1	product_category_name_english	71 non-null	object

Data columns (total 3 columns):

#	Column	Non-Null Count	Dtype
0	product_category_name	71 non-null	object
1	product_category_name_english	71 non-null	object
2	product_category	70 non-null	object

dtypes: object(3)
memory usage: 1.8+ KB
None


	product_category_name	product_category_name_english	product_category
0	beleza_saude	health_beauty	Beauty & Health
1	informatica_acessorios	computers_accessories	Electronics
2	automotivo	auto	Electronics
3	cama_mesa_banho	bed_bath_table	Furniture
4	moveis_decoracao	furniture_decor	Furniture

ERD hệ thống OLTP


 Nhóm 10



Fact




Dimension



OLTP sang OLAP

 Nhóm 10

Dimension




OLTP sang OLAP



Nhóm 10

Fact





fact_Sản_phẩm: product_id, product_category, seller_id, seller_state, price, review_score, order_id, order_status

fact_Khách_hàng: customer_id, customer_state, Segment, region, order_id, order_purchase_timestamp, payment_value,

fact_Đơn_hàng: order_id, customer_id, Segment, payment_value, payment_type, product_id, order_status, order_purchase_timestamp, geolocation_zip_code_prefix, product_category,

fact_Giao_hàng: order_id, order_status, order_shipping_days, arrival_status, Volumn, product_weight_g, product_id, freight_value, customer_state, payment_type, payment_value

Tạo bảng DIM

```
CREATE TABLE [dbo].[dim_Địa_điểm](
    [location_id] [int] IDENTITY(1,1) NOT NULL,
    [zip_code_prefix] [nvarchar](50) NULL,
    [state] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Địa_điểm] PRIMARY KEY CLUSTERED
(
    [location_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[dim_Hình_thức_thanh_toán](
    [payment_type_id] [int] IDENTITY(1,1) NOT NULL,
    [payment_type] [nvarchar](50) NULL,
    [payment_instalments] [int] NULL,
    CONSTRAINT [PK_dim_Hình_thức_thanh_toán] PRIMARY KEY CLUSTERED
(
    [payment_type_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[dim_Khu_vực](
    [region_id] [int] IDENTITY(1,1) NOT NULL,
    [region] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Khu_vực] PRIMARY KEY CLUSTERED
(
    [region_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

Tạo bảng DIM

```
CREATE TABLE [dbo].[dim_Kích_thước_sản_phẩm](
    [product_id] [nvarchar](50) NOT NULL,
    [volumn] [float] NULL,
    [product_weight] [float] NULL,
    CONSTRAINT [PK_dim_Kích_thước_sản_phẩm] PRIMARY KEY CLUSTERED
(
    [product_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[dim_Ngành_hàng](
    [product_category_id] [int] IDENTITY(1,1) NOT NULL,
    [product_category_name] [nvarchar](50) NULL,
    [product_category] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Ngành_hàng] PRIMARY KEY CLUSTERED
(
    [product_category_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[dim_Nhà_cung_cấp](
    [seller_state_id] [int] IDENTITY(1,1) NOT NULL,
    [seller_state] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Nhà_cung_cấp] PRIMARY KEY CLUSTERED
(
    [seller_state_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

Tạo bảng DIM

```
CREATE TABLE [dbo].[dim_Phân_khúc_khách_hàng](
    [segment_id] [int] IDENTITY(1,1) NOT NULL,
    [segment_name] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Phân_khúc_khách_hàng] PRIMARY KEY CLUSTERED
(
    [segment_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[dim_Thời_gian](
    [date] [date] NULL,
    [year] [int] NULL,
    [quarter] [int] NULL,
    [month] [int] NULL,
    [day] [int] NULL
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[dim_Trạng_thái_giao_hàng](
    [status_id] [int] IDENTITY(1,1) NOT NULL,
    [status_] [nvarchar](50) NULL,
    [arrival_status] [nvarchar](50) NULL,
    CONSTRAINT [PK_staus] PRIMARY KEY CLUSTERED
(
    [status_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

Tạo bảng FACT

```
CREATE TABLE [dbo].[fact_Đơn_hàng](
    [order_id] [nvarchar](50) NULL,
    [customer_id] [nvarchar](50) NULL,
    [product_id] [nvarchar](50) NULL,
    [order_date] [date] NULL,
    [payment_type] [nvarchar](50) NULL,
    [payment_value] [float] NULL,
    [zip_code] [nvarchar](50) NULL,
    [order_status] [nvarchar](50) NULL,
    [segment] [nvarchar](50) NULL,
    [product_category_name] [nvarchar](50) NULL
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[fact_Khách_hàng](
    [customer_id] [nvarchar](50) NULL,
    [location_id] [nchar](10) NULL,
    [total_orders] [nchar](10) NULL,
    [total_spent] [nchar](10) NULL,
    [first_order_date] [date] NULL,
    [recent_order_date] [date] NULL,
    [customer_segment] [nvarchar](50) NULL,
    [customer_region] [nvarchar](50) NULL
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[fact_Giao_hàng](
    [order_id] [nvarchar](50) NULL,
    [order_shipping_days] [nvarchar](50) NULL,
    [arrival_status] [nvarchar](50) NULL,
    [order_status_id] [nvarchar](50) NULL,
    [product_id] [nvarchar](50) NULL,
    [volumn] [float] NULL,
    [product_weight_g] [float] NULL,
    [freight_value] [float] NULL,
    [payment_type] [nvarchar](50) NULL,
    [product_category] [nvarchar](50) NULL,
    [state] [nvarchar](50) NULL
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[fact_Sản_phẩm](
    [product_id] [nvarchar](50) NULL,
    [product_category] [nvarchar](50) NULL,
    [seller] [nvarchar](50) NULL,
    [seller_state] [nvarchar](50) NULL,
    [total_sale] [int] NULL,
    [total_revenue] [float] NULL,
    [average_rating] [float] NULL,
    [is_Cancelled] [int] NULL
) ON [PRIMARY]
```

Insert dữ liệu vào bảng Fact

```
INSERT INTO fact_Giao_hàng (
    order_id,
    order_shipping_days,
    product_id,
    arrival_status,
    order_status_id,
    volumn,
    product_weight_g,
    freight_value,
    payment_type,
    product_category,
    state
)
SELECT
    o.order_id,
    o.order_shipping_days,
    oi.product_id,
    o.arrival_status,
    dt.status_,
    dk.volumn,
    dk.product_weight,
    oi.freight_value,
    py.payment_type,
    dn.product_category,
    dd.state
FROM
    orders o
LEFT JOIN
    order_items oi ON o.order_id = oi.order_id
LEFT JOIN
    dim_Trạng_thái_giao_hàng dt ON o.order_status = dt.status_
LEFT JOIN
    [dim_Kích_thước_sản_phẩm] dk ON oi.product_id = dk.product_id
LEFT JOIN
    payments py ON py.order_id = o.order_id
LEFT JOIN
    product po ON po.product_id = oi.product_id
LEFT JOIN
    dim_Ngành_hàng dn ON dn.product_category_name = po.product_category_name
LEFT JOIN
    customers c ON c.customer_id = o.customer_id
LEFT JOIN
    dim_Địa_điểm dd ON dd.zip_code_prefix = c.customer_zip_code_prefix
```

```
INSERT INTO fact_Đơn_hàng(
    order_id,
    customer_id,
    product_id,
    order_date,
    payment_type,
    payment_value,
    zip_code,
    order_status,
    segment,
    product_category_name
)
SELECT
    o.order_id,
    c.customer_id,
    oi.product_id,
    o.order_purchase_timestamp,
    py.payment_type,
    py.payment_value,
    dd.zip_code_prefix,
    dt.status_,
    dp.segment_name,
    dn.product_category
FROM
    orders o
LEFT JOIN
    customers c ON c.customer_id = o.customer_id
LEFT JOIN
    order_items oi ON o.order_id = oi.order_id
LEFT JOIN
    payments py ON py.order_id = o.order_id
LEFT JOIN
    product po ON po.product_id = oi.product_id
LEFT JOIN
    dim_Trạng_thái_giao_hàng dt ON o.order_status = dt.status_
LEFT JOIN
    dim_Phân_khúc_khách_hàng dp ON dp.segment_name = c.Segment
LEFT JOIN
    dim_Ngành_hàng dn ON dn.product_category_name = po.product_category_name
LEFT JOIN
    dim_Địa_điểm dd ON dd.zip_code_prefix = c.customer_zip_code_prefix
```


Insert dữ liệu vào bảng Fact

```
INSERT INTO fact_Sản_phẩm(
    product_id,
    product_category,
    seller,
    seller_state,
    total_sale,
    total_revenue,
    average_rating,
    is_Cancelled
)
SELECT
    p.product_id,
    dn.product_category,
    s.seller_id,
    dncc.seller_state,
    COUNT(oi.order_id) AS total_sales,           -- Đếm số lần sản phẩm được bán
    SUM(oi.price) AS total_revenue,             -- Tổng doanh thu
    AVG(CAST(r.review_score AS FLOAT)) AS average_rating, -- Điểm đánh giá trung bình
    CASE
        WHEN COUNT(CASE WHEN o.order_status = 'canceled' THEN 1 END) > 0 THEN 1
        ELSE 0
    END AS is_cancelled
FROM
    product p
LEFT JOIN
    order_items oi ON oi.product_id = p.product_id
LEFT JOIN
    sellers s ON s.seller_id = oi.seller_id
LEFT JOIN
    dim_Ngành_hàng dn ON p.product_category_name = dn.product_category_name
LEFT JOIN
    dim_Nhà_cung_cấp dncc ON dncc.seller_state = s.seller_state
LEFT JOIN
    orders o ON oi.order_id = o.order_id
LEFT JOIN
    reviews r ON o.order_id = r.order_id
GROUP BY
    p.product_id,
    dn.product_category,
    s.seller_id,
    dncc.seller_state
```

```
INSERT INTO fact_Khách_hàng(
    customer_id,
    location_id,
    total_orders,
    total_spent,
    first_order_date,
    recent_order_date,
    customer_segment,
    customer_region
)
SELECT
    c.customer_id,
    dd.state,
    COUNT(o.order_id) AS total_orders,
    SUM(p.payment_value) AS total_spent,
    MIN(o.order_purchase_timestamp) AS first_order_date,
    MAX(o.order_purchase_timestamp) AS last_order_date,
    dp.segment_name,
    dk.region
FROM
    customers c
LEFT JOIN
    orders o ON c.customer_id = o.customer_id
LEFT JOIN
    payments p ON p.order_id = o.order_id
LEFT JOIN
    geolocations geo ON geo.geolocation_zip_code_prefix = c.customer_zip_code_prefix
LEFT JOIN
    dim_Phân_khúc_khách_hàng dp ON dp.segment_name = c.Segment
LEFT JOIN
    dim_Địa_điểm dd ON dd.zip_code_prefix = c.customer_zip_code_prefix
LEFT JOIN
    dim_Khu_vực dk ON dk.region = geo.region
GROUP BY
    c.customer_id,
    c.customer_unique_id,
    dd.state,
    dp.segment_name,
    dk.region
```

Hệ thống Dimension

12 values 31 values 3 values

Tháng	Ngày	Năm
1	1	2016
2	1	2017
3	2	2018
4	3	
5	4	
6	5	
7	6	
8	7	
9	8	
10	9	
11	10	
12	11	
	12	
	13	
	14	
	15	
	...	

73 values

product_category_name	product_category
beleza_saude	Beauty & Health
informatica_acessorios	Electronics
automotivo	Furniture
cama_mesa_banho	Entertainment
moveis_decoracao	Home & Garden
esporte_lazer	Food & Drinks
perfumaria	Fashion
utilidades_domesticas	Books & Stationery
telefonica	Industry & Construction
relogios_presentes	
alimentos_bebidas	
bebes	
papelaria	
tablets_impressao_imagem	
brinquedos	
...	

9 values

27 values

geolocation_state	region
SP	Southeast
RJ	South
ES	Midwest
MG	North
BA	Northeast
SE	
PE	
RN	
AL	
...	

5 values

5 values

payment_type	payment_installments
credit_card	0
boleto	1
voucher	2
debit_card	3
not_defined	4
	5
	6
	7
	8
	9
	10
	...

24 values

2 values

order_status	arrival_status
delivered	Early
canceled	Late

2 values


3 values

product_quality
Good
Poor
Average


Data Model Logic



Data Model Vật Lí


[Menu](#)[About Us](#)[@reallygreatsite](#)

Logical Data Model



Physical Data Model

fact_Sản_phẩm




Physical Data Model

fact_Khách_hàng



Physical Data Model

fact_Giao_hàng



Physical Data Model

fact_Đơn_hàng



III. Xây dựng hệ thống




Dashboard phân tích Giao hàng

Dashboard phân tích Khách hàng
Dashboard phân tích Bán hàng
Dashboard phân tích Sản phẩm



© Nội dung ETL



Sử dụng Airflow để tự động hóa

olist_etl_pipeline_dag - Graph - 1

localhost:8080/dags/olist_etl_pipeline_dag/graph/?root=

11:46 UTC

Airflow

DAGs Datasets Security Browse Admin Docs

DAG: olist_etl_pipeline_dag

ETL pipeline for Olist E-commerce data

success

Schedule: @daily

Next Run: 2024-11-17, 00:00:00

Grid

Graph

Calendar

Task Duration

Task Times

Landing Times

Gantt

Details

Code

Audit Log

2024-11-16T03:32:35Z

Runs

25

Run

manual__2024-11-16T03:32:34.168362+00:00

Layout

Left > Right

Update

Find Task...

MySqlOperator

PythonOperator

deferred

failed

queued

removed

restarting

running

scheduled

shutdown

skipped

success

up_for_reschedule

up_for_retry

upstream_failed

no_status

Auto-refresh


download_data

create_database

transform_customers


load_to_mysql

© Nội dung ETL




Sử dụng Airflow để tự động hóa


Khai phá luật kết hợp




**Tổng quan về khai phá luật
kết hợp**




Tập phổ biến




Luật kết hợp




Các khái niệm



Thuật toán




Data input



Áp dụng mô hình

Tổng quan về khai phá luật kết hợp



- **Luật kết hợp** là một khái niệm trong lĩnh vực dữ liệu lớn (big data) và khai phá dữ liệu (data mining)
- Được sử dụng để tìm ra các mối quan hệ hoặc mẫu xuất hiện đồng thời trong một tập dữ liệu.
- Cụ thể, luật kết hợp được áp dụng trong việc khai phá dữ liệu mua sắm, dữ liệu truy xuất web, dữ liệu y tế, và nhiều lĩnh vực khác.



Customer 1



Customer 2




Customer 3





Customer n

Tập phổ biến



- **Tập phổ biến** là tập hợp các mục (item) xuất hiện cùng nhau trong một tập dữ liệu với một tần suất đủ lớn.
- **Ví dụ:**
{Milk, Bread}: Tập phổ biến nếu xuất hiện trong nhiều giao dịch.







- Luật kết hợp được biểu diễn dưới dạng “IF - THEN”:

$$A \Rightarrow B$$

- *A (Antecedent): Một tập hợp các mục (Items) ban đầu.*
- *B (Consequent): Một tập hợp các mục có khả năng xảy ra khi A xuất hiện.*



Các khái niệm

- **Support (Độ hỗ trợ):** Tỷ lệ giao dịch chứa cả A và B trên tổng số giao dịch.
- **Confidence (Độ tin cậy):** Xác suất B xảy ra khi A đã xảy ra.
- **Lift :** Đo lường mức độ phụ thuộc giữa A và B so với sự độc lập

$$\text{Supp}(X) = \frac{\text{Freq}(X)}{T}$$


$$\text{Confidence} = \frac{\text{Freq}(X,Y)}{\text{Freq}(X)}$$

$$\text{Lift} = \frac{\text{Supp}(X,Y)}{\text{Supp}(X) \times \text{Supp}(Y)}$$


Lift > 1: A và B có quan hệ tích cực.

Lift = 1: A và B độc lập.

Lift < 1: A và B có quan hệ tiêu cực.



- **Apriori Algorithm:** Dựa trên nguyên lý loại bỏ tập con không phổ biến, sinh dần các tập phổ biến từ 1 mục trở lên, nhưng chậm với dữ liệu lớn.
- **FP-Growth Algorithm:** Sử dụng cây tần số (FP-Tree) để tìm tập phổ biến nhanh mà không cần sinh tập hợp, nhưng tốn nhiều bộ nhớ.



Thuật toán	Ưu điểm	Hạn chế
Apriori	Dễ triển khai	Chậm với dữ liệu lớn
FP-Growth	Hiệu quả với dữ liệu lớn	Tốn bộ nhớ hơn

Dữ liệu đầu vào

Mã hóa one-hot

[illegible]

Áp dụng mô hình

	support	itemsets
0	0.095839	(bed bath table)
1	0.090945	(health beauty)
5	0.078757	(sports leisure)
8	0.068717	(computers accessories)
22	0.066202	(furniture decor)
14	0.061004	(housewares)
16	0.058132	(watches gifts)
3	0.043513	(telephony)
21	0.040369	(auto)
11	0.040285	(toys)

Áp dụng mô hình

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift
0	(bed bath table, garden tools)	(housewares)	0.000168	0.061004	0.000031	0.187500	3.073570
1	(garden tools, housewares)	(bed bath table)	0.000252	0.095839	0.000031	0.125000	1.304265
2	(fashion bags accessories, bed bath table)	(housewares)	0.000115	0.061004	0.000021	0.181818	2.980431
3	(fashion bags accessories, housewares)	(bed bath table)	0.000115	0.095839	0.000021	0.181818	1.897112
4	(home confort)	(bed bath table)	0.004150	0.095839	0.000566	0.136364	1.422834
5	(home confort, furniture decor)	(bed bath table)	0.000094	0.095839	0.000021	0.222222	2.318693

Các nội dung đã thực hiện >

Hạn chế cần khắc phục >

Bài học và hướng phát triển >



IV. Tổng kết

Các nội dung đã thực hiện

- Báo cáo đầy đủ các nội dung yêu cầu: tìm dữ liệu, khảo sát, ETL dữ liệu, khám phá dữ liệu, xây dựng mô hình ERD, OLTP, vẽ Dashboard và phân tích. ww
- Phân tích nghiệp vụ của bài toán
- Đánh giá quy mô bộ dữ liệu
- Phân tích, làm sạch dữ liệu Sử dụng đa dạng công cụ để xử lý dữ liệu: Power BI, MySQL, Python, Microsoft Excel...
- Thiết kế kiến trúc Data Warehouse
- Xây dựng đa dạng các biểu đồ trong phần khám phá dữ liệu
- Xây dựng đa dạng các dashboard
- Dùng thuật toán trong khai phá luật kết hợp để tìm hiểu những thói quen mua sắm của khách hàng
- Sử dụng AI trong việc phân lớp khu vực
- Sử dụng học máy để phân cụm khách hàng
- Sử dụng Airflow để tự động hóa quy trình ETL
- Đã phân tích khuynh, mùa
- Sử dụng tableau để xây dựng dashboard



Mục đã thêm, sửa

- Trong phần khảo sát đã sửa lại Data taxonomy.
- Sửa lại cây phân tích Dashboard.
- Trình bày phần khảo sát nghiệp vụ chi tiết hơn.
- Sửa lại phụ thuộc hàm trong Mô hình dữ liệu logic.
- Phần dimension đã đổi màu cho các phân vùng.
- Trong dashboard đã có thêm đề mục, có icon cho các biểu đồ để chi tiết hơn
- Bổ sung các đơn vị trên các biểu đồ
- Sử dụng slicer trong dashboard giao hàng
- Trong dashboard giao hàng, đã phân tích theo dòng thời gian để suy ra trend và xu hướng,...



Hạn chế cần khắc phục

- Tìm kiếm bộ dữ liệu chưa đa dạng, dữ liệu đã khá cũ.
- Một số biểu đồ khám phá dữ liệu chưa rút ra được nhiều ý nghĩa.
- Mô hình Data chưa tối ưu với bài toán đưa ra



Bài học và hướng phát triển

- Các yêu cầu phân tích cần bám sát bộ dữ liệu
- Cần khảo sát nghiệp vụ kỹ càng để phân tích và xây dựng được hệ thống đúng
- Phân tích dashboard cần bám sát nghiệp vụ, mang tính phân tích, so sánh, dự báo,..., cần có tính thẩm mỹ và logic
- Cần nghiên cứu bộ dữ liệu một cách tỉ mỉ trước khi xử lý dữ liệu để tránh xảy ra sai sót và mất mát dữ liệu
- Đối với file dữ liệu có kích thước lớn, các công cụ thông thường không thể hoặc rất khó để xử lý hết, cần tìm được công cụ phù hợp hoặc chia nhỏ để dễ thực hiện.
- Cần linh hoạt trong xử lý dữ liệu vì không phải lúc nào dữ liệu cũng được chuẩn hoá sẵn.



thank you



123 Anywhere St.



+123-456-7890



@reallygreatsite