

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN - TIN



KHO DỮ LIỆU VÀ KINH DOANH THÔNG MINH

CHỦ ĐỀ: THƯƠNG MẠI ĐIỆN TỬ

Nhóm 18

Giảng viên hướng dẫn: ThS. Nguyễn Danh Tú
Nhóm sinh viên thực hiện: Nguyễn Trung Hiếu 20216828
Lê Tiến Nghĩa 20216861
Bùi Quang Hưng 20216837
Phạm Thị Thanh Hà 20216823
Phạm Hữu Chiến 20216802

Hà Nội, tháng 12 năm 2024

Lời cảm ơn

Lời đầu tiên, tập thể nhóm 18 xin gửi lời cảm ơn chân thành nhất đến thầy, Ths. Nguyễn Danh Tú đã đồng hành cùng tập thể nhóm và các bạn sinh viên trong môn học Kho dữ liệu và Kinh doanh thông minh kỳ 2024.1. Các nội dung thầy giảng dạy trên lớp rất có ý nghĩa đối với quá trình phát triển của bản thân tập thể nhóm với định hướng công việc đã đưa ra. Với nội dung phong phú và cách trình bày gãy gọn của thầy đã giúp tập thể nhóm có thêm nhiều kiến thức về dữ liệu, Kho dữ liệu, Kinh doanh thông minh, các quy trình cơ bản của một hệ thống phân tích dữ liệu,...

Báo cáo nhóm 18 với chủ đề Thương mại điện tử (Electronics Commerce) này đã trình bày lại chi tiết và đầy đủ hơn project của nhóm trong học phần này sau lần một thuyết trình. Mặc dù nhóm đã cố gắng để hoàn thiện các nội dung được thầy góp ý, nhưng chắc chắn rằng báo cáo có thể còn nhiều thiếu sót về nội dung và hình thức, tập thể nhóm rất mong được nhận thêm những góp ý từ thầy và các bạn để báo cáo có thể hoàn thiện hơn. Cuối cùng, tập thể nhóm 18 xin chúc thầy có nhiều sức khỏe, đạt nhiều thành công trong công tác giảng dạy và nghiên cứu khoa học. Tập thể nhóm chúng em xin chân thành cảm ơn thầy rất nhiều !

Hà Nội, tháng 12 năm 2024

Nhóm 18

Mở đầu

Các công cụ kinh doanh thông minh đã mở ra cơ hội cho doanh nghiệp thuộc mọi quy mô tiếp cận với khả năng phân tích dữ liệu mạnh mẽ. Tận dụng được nguồn tài nguyên dữ liệu dồi dào và tìm ra xu hướng là điều cần thiết để các doanh nghiệp thúc đẩy các quyết định kinh doanh tốt hơn, đưa ra những chiến lược hiệu quả cho phép các tổ chức tăng doanh thu, cải thiện hiệu suất hoạt động và hơn nữa là đạt được lợi thế cạnh tranh so với các đối thủ kinh doanh.

Kho dữ liệu xuất hiện đóng vai trò như một thành phần cốt lõi của kinh doanh thông minh, giúp thúc đẩy và nâng cao hiệu suất.

Trong báo cáo này, chúng em giới thiệu về những khái niệm quan trọng trong kho dữ liệu và kinh doanh thông minh, từ đó áp dụng những kiến thức đã học được để thực hành xử lý và phân tích với bộ dữ liệu của doanh nghiệp. Qua đó đưa ra được những góc nhìn về hoạt động kinh doanh và rút ra được những kinh nghiệm quý báu trong quá trình làm việc với dữ liệu thực tế.

Báo cáo gồm các phần chính như sau:

- Chương 1: Tổng quan về Kho dữ liệu.
- Chương 2: Tổng quan về Kinh doanh thông minh
- Chương 3: Khảo sát.
- Chương 4: Phân tích và thiết kế hệ thống.
- Chương 5: Xây dựng hệ thống.
- Chương 6: Phần mở rộng.
- Chương 7: Tổng kết.

Mục lục

Lời cảm ơn	1
Mở đầu	1
Đánh giá thành viên	6
Danh sách hình vẽ	6
1 Tổng quan về kho dữ liệu	10
1.1 Giới thiệu chung về Data Warehouse	10
1.2 Đặc điểm của Data Warehouse	10
1.3 Phân loại Data Warehouse	11
1.4 Kiến trúc của Data Warehouse	12
1.4.1 Các lớp của Data Warehouse	12
1.4.2 Các thành phần chính của kiến trúc Data Warehouse	14
1.4.3 Các loại kiến trúc Data Warehouse	15
1.4.4 Kiến trúc 2 lớp	16
1.4.5 Kiến trúc 3 lớp	16
1.5 Ưu nhược điểm của Data Warehouse	18
1.6 Ứng dụng của Data Warehouse	18
1.7 Mô hình dữ liệu đa chiều (OLAP)	19
1.7.1 Thành phần của OLAP	19
1.7.2 Cách hoạt động của OLAP	20
1.7.3 Các thao tác trong OLAP	20
1.7.4 Các công nghệ OLAP	21
2 Tổng quan về Business Intelligence	22
2.1 Giới thiệu chung	22
2.1.1 Khái niệm	22
2.1.2 Lịch sử	23
2.2 Các thành phần của hệ thống BI	24
2.3 Ứng dụng của BI	26
2.4 Trực quan hóa dữ liệu với PowerBI	26
2.4.1 Tổng quan về PowerBI	26
2.4.2 Xử lý dữ liệu với PowerBI	28
3 Khảo sát hệ thống	32
3.1 Tổng quan về E-commerce	32
3.1.1 Hệ thống tổng hợp và phân tích dữ liệu E-commerce	32
3.1.2 Giới thiệu về công ty Olist	33

3.2	Model Canvas	34
3.3	Khảo sát nghiệp vụ	36
3.3.1	Các hệ thống đang sử dụng trong E-commerce	36
3.3.2	Luồng nghiệp vụ	36
3.3.3	Cây nghiệp vụ	39
3.3.4	Biểu đồ luồng dữ liệu (Data flow)	39
3.4	Yêu cầu phân tích	40
3.4.1	Khảo sát yêu cầu hệ thống	40
3.4.2	Các yêu cầu phân tích	40
3.4.3	Các yêu cầu phân tích Dashboard	42
3.5	Khảo sát về hệ thống dữ liệu	43
3.5.1	Tổng quan về bộ dữ liệu	43
3.5.2	Giới thiệu chi tiết bộ dữ liệu	44
3.5.3	Data taxonomy	48
3.6	ERD hệ thống OLTP, Data flow	49
3.6.1	ERD hệ thống OLTP	49
3.6.2	Các trường quan trọng để xây dựng Data Model đa chiều OLAP	50
4	Phân tích và thiết kế hệ thống	53
4.1	Khám phá dữ liệu	53
4.2	Kiến trúc datawarehouse	62
4.3	Tiền xử lí dữ liệu	62
4.3.1	Data pipeline	63
4.3.2	Các hoạt động ETL dữ liệu	63
4.3.3	Mở rộng: Sử dụng Apache Airflow để ETL dữ liệu	78
4.4	Mô hình dữ liệu OLTP	79
4.4.1	OLTP sau ETL	79
4.4.2	Thống kê các trường dữ liệu để xây dựng data model đa chiều OLAP	80
4.5	Mô hình dữ liệu OLAP	82
4.5.1	Chuyển đổi mô hình OLTP sang OLAP	82
4.5.2	Hệ thống chiều khái niệm	86
4.6	Data Mart	87
4.6.1	Mô hình dữ liệu Logic	87
4.6.2	Thiết kế cơ sở dữ liệu cho DataMart	88
4.6.3	Mô hình dữ liệu vật lý	88
5	Xây Dựng hệ thống	90
5.1	Dashboard phân tích khách hàng	90
5.2	Dashboard phân tích Doanh thu	92
5.3	Dashboard phân tích Sản phẩm	93
5.4	Dashboard phân tích Giao hàng	95

6 Khai phá luật kết hợp	97
6.1 Tổng quan khai phá luật kết hợp	97
6.2 Tập phổ biến	97
6.3 Luật kết hợp	97
6.4 Các khái niệm	97
6.5 Các thuật toán	98
6.6 Dữ liệu đầu vào	98
6.7 Kết quả sau khi áp dụng mô hình	99
Tổng kết	100
Tài liệu tham khảo	102

Đánh giá thành viên

BẢNG ĐÁNH GIÁ THÀNH VIÊN
MÔN HỌC: KHO DỮ LIỆU VÀ KINH DOANH THÔNG MINH

	HỌ VÀ TÊN:	Lê Tiến Nghĩa					
	LỚP:	K66 - Toán Tin 01					
	NHÓM:	N18					

STT	Tên thành viên	Làm tốt phần việc được giao	Liên hệ được khi cần	Khả năng đóng góp sáng kiến, ý kiến cho hoạt động nhóm	Sẵn sàng giúp đỡ	Đóng góp chung vào kết quả của nhóm	Tổng điểm
1	Phạm Thị Thanh Hà	5	5	5	5	5	25
2	Phạm Hữu Chiên	5	5	5	5	5	25
3	Bùi Quang Hưng	5	5	5	5	5	25
4	Nguyễn Trung Hiếu	5	5	5	5	5	25
5	Lê Tiến Nghĩa	5	5	5	5	5	25

Ký (Ghi rõ họ tên)

Danh sách hình vẽ

1.1	Các lớp của kiến trúc DW	13
1.2	Thành phần của một kiến trúc Data Warehouse	14
1.3	Kiến trúc 1 lớp	15
1.4	Kiến trúc 2 lớp	16
1.5	Kiến trúc 3 lớp	17
1.6	Mô hình dữ liệu OLAP	20
2.1	Business Intelligence	22
2.2	Kiến trúc chung của hệ thống kinh doanh thông minh	24
2.3	Logo Power BI	27
2.4	Tiền xử lý dữ liệu với Power Query	28
2.5	Tạo dashboard để trực quan hoá dữ liệu	31
3.1	Công ty thương mại điện tử Olist	33
3.2	Công ty thương mại điện tử Olist	34
3.3	Luồng nghiệp vụ đặt hàng trực tuyến	37
3.4	Luồng nghiệp vụ giao hàng	38
3.5	Cây nghiệp vụ của Olist	39
3.6	Data flow của hệ thống	39
3.7	Mind map nhu cầu phân tích	42
3.8	Tần suất cập nhật dữ liệu	44
3.9	Mind map dữ liệu	48
3.10	Data taxonomy của hệ thống	49
3.11	Mô hình thực thể liên kết ERD OLTP	49
3.12	Khoanh các dim, fact	50
3.13	Nối các trường để tổng hợp bảng DIM	51
3.14	Nối các trường để tổng hợp bảng FACT	52
4.1	Tổng quan bộ dữ liệu	53
4.2	Bảng đặc trưng của một số trường dữ liệu	54
4.3	Ma trận tương quan	54
4.4	Số lượng đơn hàng theo thời gian	55
4.5	Xu hướng thanh toán theo thời gian	55
4.6	Số lượng người bán và mua theo từng bang	56
4.7	Doanh thu theo hình thức thanh toán	57
4.8	Top 10 danh mục sản phẩm có doanh thu cao nhất	58
4.9	Tương quan giữa cước phí vận chuyển và khối lượng	58
4.10	Tương quan giữa cước phí vận chuyển và thể tích	59
4.11	Tương quan giữa ngày giao hàng dự kiến và thực tế	59
4.12	Trend	60

4.13	Seasonality	60
4.14	Residuals	61
4.15	Kiến trúc Data Warehouse	62
4.16	Tổng quan hoạt động ETL	62
4.17	Data pipeline.	63
4.18	Tóm tắt các hoạt động ETL.	63
4.19	Before	64
4.20	After	64
4.21	Before	65
4.22	After	66
4.23	Before	66
4.24	After	66
4.25	Before	67
4.26	After	67
4.27	Before	67
4.28	After	68
4.29	Before	68
4.30	After	68
4.31	Before	69
4.32	After	69
4.33	Before	70
4.34	After	70
4.35	Before	70
4.36	After	71
4.37	Before	71
4.38	After	71
4.39	Before	72
4.40	After	72
4.41	Before và After	73
4.42	Before và After	73
4.43	Before và After	74
4.44	Before và After	75
4.45	Before và After	76
4.46	Before và After	77
4.47	Before và After	78
4.48	Sơ đồ ETL dữ liệu	79
4.49	Kết quả thực thi các task	79
4.50	ERD hệ thống OLTP sau ETL	80
4.51	Nối dimension sau ETL	81
4.52	Fact sau ETL	82
4.53	Tạo các bảng dim Địa điểm và Hình thức thanh toán	83
4.54	Tạo các bảng dim Khu vực và Kích thước sản phẩm	83
4.55	Tạo các bảng dim Ngành hàng và Nhà cung cấp	84
4.56	Tạo các bảng dim Phân khúc khách hàng, Thời gian và Trạng thái giao hàng	84

4.57	Tạo các bảng Fact	85
4.58	Ghi dữ liệu vào fact Đơn hàng và Giao hàng	85
4.59	Ghi dữ liệu vào fact Sản phẩm và Khách hàng	86
4.60	Các chiều khái niệm	86
4.61	Mô hình dữ liệu Logic	87
4.62	Star Schema của bảng fact_Đơn_hàng	88
4.63	Star Schema của bảng fact_Giao_hàng	88
4.64	Star Schema của bảng fact_Khách_hàng	89
4.65	Star Schema của bảng fact_Sản_phẩm	89
5.1	Dashboard phân tích khách hàng	90
5.2	Dashboard phân tích Doanh thu	92
5.3	Dashboard phân tích Doanh thu	93
5.4	Dashboard phân tích Giao hàng	95
6.1	Mã hóa one-hot.	99
6.2	Kết quả những danh mục phổ biến nhất	99
6.3	Kết quả sự kết hợp các danh mục.	100

Tổng quan về kho dữ liệu

1.1 Giới thiệu chung về Data Warehouse

Data Warehouse hay kho dữ liệu là một hệ thống cung cấp một kiến trúc mở(kiến trúc có thể thay đổi dựa vào yêu cầu của hệ thống) và công cụ cho các doanh nghiệp, nhà điều hành nhằm hỗ trợ quá trình ra quyết định, cũng như tập trung vào việc lưu trữ và phân tích dữ liệu.

Data warehouse còn là một phần của giải pháp kinh doanh thông minh (BI). Theo truyền thống, kho dữ liệu được lưu trữ tại chỗ và tập trung vào việc trích xuất dữ liệu từ các nguồn khác nhau. Tuy nhiên, ở thời điểm hiện tại, datawarehouse có thể được lưu trữ trên một thiết bị chuyên dụng hoặc trên dữ liệu đám mây,... để tối ưu hóa quá trình phân tích.

Khác với DataBase được thiết kế để lưu trữ thì Data Warehouse vừa lưu trữ vừa hỗ trợ phân tích dữ liệu và báo cáo.[4]

Data Warehouse sẽ có các chức năng :

- o Cung cấp một góc nhìn toàn diện về doanh nghiệp
- o Cung cấp đầy đủ thông tin hiện tại và lịch sử của doanh nghiệp, và sẵn sàng cho việc khai thác, sử dụng cho việc hỗ trợ ra quyết định chiến lược
- o Đảm bảo thông tin có tính nhất quán
- o Là nguồn thông tin mềm dẻo và có tính tương tác, tức là người dùng có thể lấy các thông tin khác nhau của cùng 1 đối tượng, với nhiều thao tác thay vì trả lại một danh sách tĩnh

1.2 Đặc điểm của Data Warehouse

Data Warehouse sẽ lưu trữ dữ liệu từ nhiều nguồn khác nhau, dữ liệu trong kho thường mang tính lịch sử , biến đổi theo thời gian, không biến động và tích hợp cũng như hướng chủ đề.[6]

- o **Hướng chủ đề** : Data warehouse cung cấp thông tin phục vụ cho một chủ thể cụ thể thay vì các hoạt động liên tục của toàn tổ chức. Điều đó có nghĩa là quy trình lưu trữ dữ liệu được đề xuất để xử lý theo một chủ đề cụ thể được xác định rõ hơn. Các chủ đề này có thể là bán hàng, phân phối, tiếp thị, v.v.

- o **Tính tích hợp** : Tích hợp có nghĩa là thành lập một thực thể dùng chung để mở rộng quy mô tất cả dữ liệu tương tự từ các cơ sở dữ liệu khác nhau. Dữ liệu cũng được yêu cầu phải được lưu trữ trong các kho dữ liệu khác nhau theo cách được chia sẻ và cấp phép chung. Ví dụ: nếu một hệ thống sử dụng tên vùng như “Bắc Carolina” và hệ thống khác sử dụng các chữ viết tắt như “NC”, kho dữ liệu tích hợp sẽ điều chỉnh tên vùng để tạo ra một hệ thống mã hóa nhất quán.
- o **Tính Biến đổi theo thời gian** : Dữ liệu trong kho được duy trì theo thời gian, cho phép phân tích xu hướng, dự báo, AI/ML và báo cáo lịch sử. Đó không chỉ là ảnh chụp nhanh về thời điểm hiện tại mà còn là dòng thời gian dữ liệu cho phép doanh nghiệp nhìn thấy những thay đổi và phát triển theo thời gian. Nó tạo ra các giới hạn thời gian khác nhau được cấu trúc giữa các bộ dữ liệu lớn và được giữ trong quy trình giao dịch trực tuyến (OLTP).
- o **Tính không biến động** : Dữ liệu nằm trong kho dữ liệu là vĩnh viễn. Điều đó cũng có nghĩa là dữ liệu không bị xóa khi dữ liệu mới được chèn vào (ngoại trừ bị lấy cấp hoặc bảo trì). Trong đó, dữ liệu ở chế độ chỉ đọc và được làm mới theo các khoảng thời gian cụ thể. Điều này có lợi trong việc phân tích dữ liệu lịch sử và hiểu được chức năng.
- o **Tính lịch sử** : Khả năng phân tích của nó cho phép các tổ chức thu được những hiểu biết kinh doanh có giá trị từ dữ liệu của họ để cải thiện việc ra quyết định. Theo thời gian, nó xây dựng một hồ sơ lịch sử có thể là vô giá đối với các nhà khoa học dữ liệu và nhà phân tích kinh doanh.

1.3 Phân loại Data Warehouse

Data Warehouse chia thành 3 loại chính :

- **Enterprise Data Warehouse (EDW - Kho Dữ Liệu Doanh Nghiệp)**: EDW đóng vai trò là hệ thống lưu trữ dữ liệu toàn diện cho toàn bộ tổ chức hoặc doanh nghiệp. Nó tích hợp dữ liệu từ nhiều nguồn khác nhau, biến đổi và lưu trữ chúng để hỗ trợ quá trình ra quyết định toàn diện.
 - o **Ưu điểm** :
 - ◊ Cung cấp một nguồn dữ liệu chính xác và đáng tin cậy cho toàn bộ tổ chức.
 - ◊ Hỗ trợ việc thực hiện các phân tích phức tạp và báo cáo quản lý.
 - ◊ Đảm bảo tính nhất quán và tính toàn vẹn của dữ liệu.
 - o **Nhược điểm** :
 - ◊ Đòi hỏi nguồn lực và ngân sách lớn để triển khai và duy trì.
 - ◊ Việc tích hợp và chuẩn hóa dữ liệu có thể tốn thời gian và phức tạp.
- **Operational Data Store (ODS - Kho Dữ Liệu Hoạt Động)**: ODS là một kho dữ liệu trung gian giữa hệ thống ghi chép (OLTP) và Data Warehouse. Nó chứa dữ liệu được cập nhật gần thời gian thực và hỗ trợ các nhiệm vụ hoạt động như giao dịch và cập nhật dữ liệu.


- o **Ưu điểm :**
 - ◇ Cung cấp truy cập nhanh chóng đối với dữ liệu gần thời gian thực
 - ◇ Hỗ trợ quá trình ghi chép và nhiệm vụ hoạt động hàng ngày của tổ chức.
- o **Nhược điểm :**
 - ◇ Không phải lúc nào cũng phản ánh dữ liệu lịch sử hoặc phân tích.
 - ◇ Có thể dẫn đến sự phức tạp trong việc quản lý và duy trì nếu không được thiết kế cẩn thận.
- **Data Mart (Kho Dữ Liệu Riêng):** Data Mart là một phần của Data Warehouse tập trung vào một lĩnh vực hoặc phòng ban cụ thể của tổ chức. Nó chứa dữ liệu liên quan đến một loại hoạt động hoặc một số lượng nhỏ người dùng cuối[3].
 - o **Ưu điểm :**
 - ◇ Dễ dàng triển khai và quản lý vì kích thước nhỏ hơn so với EDW.
 - ◇ Phục vụ nhu cầu cụ thể của một phần của tổ chức hoặc người dùng cuối.
 - o **Nhược điểm :**
 - ◇ Có thể dẫn đến tính không nhất quán nếu không được tích hợp chặt chẽ với EDW.
 - ◇ Không thể hỗ trợ phân tích toàn diện của tổ chức.
 - o **Data Mart có ba loại Data mart chính:**
 - ◇ Độc lập: Hoạt động độc lập và không phụ thuộc vào Data Warehouse.
 - ◇ Phụ thuộc: Phụ thuộc vào Data Warehouse hiện có.
 - ◇ Kết hợp: Tích hợp dữ liệu từ các nguồn bên ngoài vào một Data Warehouse hiện có.

Mỗi loại kho dữ liệu này có ưu điểm và nhược điểm riêng, và việc lựa chọn loại kho phù hợp phụ thuộc vào nhu cầu và mục tiêu của tổ chức. Thường thì một tổ chức sẽ kết hợp cả ba loại này để đảm bảo có sự linh hoạt trong việc quản lý và sử dụng dữ liệu.

1.4 Kiến trúc của Data Warehouse

Kiến trúc kho dữ liệu là một thiết kế có chủ đích của các dịch vụ dữ liệu và hệ thống con nhằm hợp nhất các nguồn dữ liệu khác nhau thành một kho lưu trữ duy nhất cho hoạt động thông minh kinh doanh (BI), AI/ML và phân tích. Bản thân kiến trúc là một tập hợp các dịch vụ logic tạo nên xương sống của hệ thống kho dữ liệu, cung cấp cách lưu trữ, quản lý và truy xuất lượng dữ liệu khổng lồ có cấu trúc và mạch lạc.[4]

1.4.1 Các lớp của Data Warehouse



Hình 1.1: Các lớp của kiến trúc DW

- **Lớp nguồn :**

Lớp logic của tất cả các hệ thống bản ghi (SOR) cung cấp dữ liệu vào kho. Chúng có thể bao gồm các hệ thống điểm bán hàng, tự động hóa tiếp thị, CRM hoặc ERP. Mỗi SOR nguồn có một định dạng dữ liệu cụ thể và có thể yêu cầu một phương pháp thu thập dữ liệu khác nhau dựa trên định dạng dữ liệu đó.

- **Lớp dàn dựng :**

Khu vực đích cho dữ liệu từ SOR nguồn. Cách tốt nhất để dàn dựng dữ liệu là nhập dữ liệu từ SOR mà không áp dụng logic nghiệp vụ hoặc chuyển đổi. Điều quan trọng nữa là phải đảm bảo rằng dữ liệu dàn dựng không được sử dụng trong phân tích dữ liệu sản xuất; dữ liệu trong khu vực tổ chức vẫn chưa được làm sạch, chuẩn hóa, lập mô hình, quản lý và xác minh.

- **Lớp kho :**


Lớp nơi tất cả dữ liệu được lưu trữ. Dữ liệu kho bây giờ được định hướng theo chủ đề, tích hợp, thay đổi theo thời gian và không biến động. Lớp này sẽ có các lược đồ vật lý, bảng, dạng xem, thủ tục được lưu trữ và các hàm cần thiết để truy cập dữ liệu được mô hình hóa kho.

- **Lớp tiêu thụ :**

Còn được gọi là lớp phân tích, là nơi bạn lập mô hình dữ liệu để sử dụng bằng các công cụ phân tích như ThoughtSpot, nhà phân tích dữ liệu, nhà khoa học dữ liệu và người dùng doanh nghiệp.

Và để có thể cho dữ liệu đi lớp nguồn đến lớp dữ liệu cần 3 quy trình là: **di chuyển, làm sạch và chuyển đổi dữ liệu.**

1.4.2 Các thành phần chính của kiến trúc Data Warehouse



Hình 1.2: Thành phần của một kiến trúc Data Warehouse

- **Data Sources** (Nguồn Dữ Liệu) :

Các nguồn dữ liệu ban đầu từ hệ thống giao dịch, cơ sở dữ liệu, ứng dụng, và nguồn dữ liệu khác. Nguồn dữ liệu này có thể là dữ liệu có cấu trúc (như cơ sở dữ liệu SQL) hoặc dữ liệu không có cấu trúc (như các tệp văn bản, hình ảnh, hoặc dữ liệu từ máy chụp cảm biến). Vai trò của Data Sources là cung cấp dữ liệu nguyên thủy để được xử lý và biến đổi thành dữ liệu có ích cho phân tích.

- **ETL** (Extract, Transform, Load) :

ETL là quá trình trích xuất (Extract), biến đổi (Transform) và nạp (Load) dữ liệu từ các nguồn dữ liệu vào kho dữ liệu. Quá trình này bao gồm việc làm sạch, chuyển đổi định dạng, và tích hợp dữ liệu để nó phù hợp với cấu trúc của kho dữ liệu và khả năng phân tích.

- **Data Warehouse Database** (Cơ Sở Dữ Liệu Kho Dữ Liệu) :

Dữ liệu sau khi đã được ETL sẽ lưu trữ tại đây. Kho dữ liệu thường được thiết kế để hỗ trợ việc truy vấn và phân tích dữ liệu một cách hiệu quả. Cơ sở dữ liệu kho dữ liệu thường có cấu trúc sao cho dễ dàng tạo ra các báo cáo và truy vấn phức tạp. Vai trò chính là lưu trữ và cung cấp dữ liệu cho các ứng dụng phân tích và báo cáo.

- **Data Marts** (Kho Dữ Liệu Phụ) :

Data Marts là các phần con của kho dữ liệu được tạo ra để phục vụ cho các phần của tổ chức cụ thể, chẳng hạn như một bộ phận hoặc một nhóm công việc. Data Marts thường tập trung vào một tầm nhìn cụ thể và được tối ưu hóa cho mục tiêu đó. Data Marts cung cấp dữ liệu tập trung và tối ưu hóa cho một phần của tổ chức.

- **Metadata** (Dữ Liệu Mô Tả) :

Metadata là thông tin về dữ liệu trong kho dữ liệu, bao gồm các mô tả về nguồn gốc của dữ liệu, cấu trúc, nguồn dữ liệu, quyền truy cập và các thông tin liên quan. Metadata giúp người quản trị và người sử dụng hiểu dữ liệu và cách sử dụng nó. Metadata hỗ trợ quản lý dữ liệu, giúp người dùng hiểu cấu trúc và tính chất của dữ liệu, và quản lý quyền truy cập.

- **Monitoring and Administration** :

Đây là quá trình theo dõi hiệu suất của kho dữ liệu và thực hiện các điều chỉnh nhằm đảm bảo việc truy vấn và phân tích dữ liệu diễn ra một cách hiệu quả. Như vậy, đây chính là thành phần giúp kho dữ liệu hoạt động ổn định và có hiệu suất tốt.

- **OLAP** (Xử lý phân tích trực tuyến)

- **Data Access Tools** (Công Cụ Truy Cập Dữ Liệu):


Data Access Tools được hiểu là các ứng dụng và công cụ được sử dụng để truy cập và tương tác với dữ liệu trong kho dữ liệu. Bao gồm các công cụ truy vấn SQL, các ứng dụng phân tích dữ liệu, và các giao diện trực quan cho việc tạo báo cáo và biểu đồ. Cho phép người dùng cuối truy cập, truy vấn, và hiển thị dữ liệu theo cách dễ dàng và linh hoạt.

1.4.3 Các loại kiến trúc Data Warehouse

Như ta thường được biết, kiến trúc Data Warehouse được chia thành 3 loại phổ biến .[2]

Kiến trúc một lớp


Kiến trúc một lớp không được sử dụng thường xuyên trong thực tế. Mục đích là giảm thiểu lượng dữ liệu được lưu trữ bằng cách loại bỏ những dữ liệu dư thừa. Kho dữ liệu là ảo và được triển khai dưới dạng chế độ xem đa chiều của dữ liệu vận hành. Điểm yếu chính của kiến trúc một lớp là không tách biệt được việc xử lý dữ liệu phân tích và giao dịch.



Hình 1.3: Kiến trúc 1 lớp

1.4.4 Kiến trúc 2 lớp

Trong kiến trúc hai lớp, có sự tách biệt giữa hai lớp: một lớp nguồn dữ liệu và dữ liệu lớp kho. Mặc dù nó được gọi là kiến trúc hai lớp để nhấn mạnh sự tách biệt của hai lớp, nhưng thực tế nó bao gồm bốn giai đoạn luồng dữ liệu: lớp nguồn, tầng dữ liệu, lớp kho dữ liệu và phân tích. Ngược lại với kiến trúc một lớp, trong kiến trúc này có sự tách biệt giữa dữ liệu phân tích và dữ liệu giao dịch.



Hình 1.4: Kiến trúc 2 lớp

1.4.5 Kiến trúc 3 lớp


Kiểu kiến trúc kho dữ liệu ba tầng là kiểu thiết kế DWH hiện đại phổ biến nhất vì nó tạo ra luồng dữ liệu được tổ chức tốt từ thông tin thô đến những hiểu biết có giá trị.

Tầng dưới cùng trong mô hình kho dữ liệu thường bao gồm máy chủ ngân hàng dữ liệu tạo ra lớp trừu tượng trên dữ liệu từ nhiều nguồn, như ngân hàng dữ liệu giao dịch được sử dụng cho mục đích sử dụng giao diện người dùng.

Tầng giữa bao gồm máy chủ Xử lý phân tích trực tuyến (OLAP). Cấp độ này thay đổi dữ liệu thành một cách sắp xếp phù hợp hơn để phân tích và thăm dò nhiều mặt từ góc độ của người dùng. Vì nó bao gồm một máy chủ OLAP được xây dựng sẵn trong kiến trúc nên chúng ta cũng có thể gọi nó là kho dữ liệu tập trung vào OLAP.

Cấp thứ ba và trên cùng là cấp độ máy khách bao gồm các công cụ và Giao diện lập trình ứng

dụng (API) được sử dụng để phân tích, tìm hiểu và báo cáo dữ liệu cấp cao. Tuy nhiên, mọi người hầu như không đưa tầng thứ 4 vào kiến trúc kho dữ liệu vì nó thường không được coi là không thể thiếu như ba loại còn lại.



Hình 1.5: Kiến trúc 3 lớp

1.5 Ưu nhược điểm của Data Warehouse

Ưu điểm	Nhược điểm
- Chất lượng dữ liệu tốt hơn: Kho dữ liệu tập trung dữ liệu từ nhiều nguồn khác nhau như hệ thống giao dịch, cơ sở dữ liệu vận hành và tệp phẳng. Sau đó, kho dữ liệu sẽ tiến hành tiêu chuẩn hóa để tạo ra một nguồn dữ liệu duy nhất, chính xác.	- Chi phí lớn: Khi các công ty bắt đầu lưu trữ nhiều và mở rộng kho dữ liệu, chi phí đầu tư sẽ tăng cao đáng kể.
- Tăng khả năng phân tích cho doanh nghiệp: Kho dữ liệu cho phép tích hợp dữ liệu từ nhiều nguồn, giúp công ty tận dụng toàn bộ dữ liệu vào quá trình phân tích và đánh giá hiệu quả.	- Lỗi đầu vào: Các lỗi trong dữ liệu đầu vào có thể ảnh hưởng đến tính toàn vẹn và độ tin cậy của dữ liệu được lưu trữ.
- Ra quyết định thông minh hơn: Kho dữ liệu cung cấp cho các nhà lãnh đạo thông tin chính xác, hỗ trợ ra quyết định trong quy trình kinh doanh, quản lý tài chính và quản lý hàng tồn kho.	- Tích hợp nhiều nguồn: Việc tích hợp dữ liệu từ nhiều nguồn có thể gây ra sự không nhất quán hoặc mâu thuẫn trong dữ liệu.
- Phát triển lợi thế cạnh tranh: Việc sử dụng kho dữ liệu giúp doanh nghiệp phát hiện các cơ hội, điểm mạnh và điểm yếu của thị trường, từ đó tăng cường lợi thế cạnh tranh.	- Khả năng bảo trì và nâng cấp: Khi quy mô kho dữ liệu mở rộng, việc bảo trì và nâng cấp hệ thống có thể trở thành thách thức lớn.

Bảng 1.1: Ưu điểm và nhược điểm của kho dữ liệu (Data Warehouse)

1.6 Ứng dụng của Data Warehouse

Hiện nay, mỗi doanh nghiệp đều cần phát triển Data warehouse để kết nối và tổng hợp thông tin từ các nguồn khác nhau. Nguyên nhân là vì kho dữ liệu là yếu tố quan trọng trong việc dự đoán, phân tích, báo cáo, triển khai kinh doanh thông minh và tạo điều kiện cho quyết định mạnh mẽ.

Dưới đây là một số ứng dụng xuất sắc của kho dữ liệu trong các ngành công nghiệp đa dạng.

- **Thương mại điện tử :**

Kho dữ liệu (Data warehouse) được sử dụng phổ biến trong việc quản lý thông tin hàng hóa, người bán, người mua, tình trạng đơn hàng, các chương trình khuyến mãi.

- **Giáo dục :**

Kho dữ liệu là yếu tố quan trọng giúp ngành giáo dục quản lý thông tin học sinh – giáo viên – công nhân viên của trường, quản lý quá trình học tập, giáo án, bài giảng, kết quả học tập của học sinh. . .

- **Ngân hàng :**

Data Warehouse được dùng quản lý dòng tiền, quản lý các quỹ đầu tư, cho vay, thời hạn thanh toán. Ngoài ra, việc triển khai giải pháp Data Warehouse còn giúp ngân hàng tối ưu hóa quản lý tài nguyên. Điều này cho phép doanh nghiệp có thể kiểm soát thông tin về khách hàng, quản lý nguồn lực theo hướng mà họ mong muốn.

1.7 Mô hình dữ liệu đa chiều (OLAP)

Data Warehouse chủ yếu được các doanh nghiệp kinh doanh lớn sử dụng để phân tích xu hướng kinh doanh và theo dõi lợi nhuận kinh doanh của họ. Các nhà phân tích sử dụng kho dữ liệu để trích xuất thông tin kinh doanh giúp đưa ra quyết định tốt hơn. Loại quy trình ra quyết định tương tác này được cung cấp bởi các công cụ OLAP (Xử lý phân tích trực tuyến) . Các ứng dụng OLAP này hầu hết chỉ sử dụng việc đọc dữ liệu để đưa ra quyết định. Các truy vấn phân tích phức tạp theo thời gian thực được trả lời bằng OLAP.

OLAP là một trong những công nghệ mạnh mẽ cung cấp các công cụ tính vi cho doanh nghiệp để đáp ứng mục tiêu cạnh tranh của mình.[5]

1.7.1 Thành phần của OLAP

Các hệ thống xử lý phân tích trực tuyến (OLAP) lưu trữ dữ liệu đa chiều bằng cách biểu diễn thông tin dưới dạng hai chiều trở lên hoặc các danh mục. Dữ liệu hai chiều bao gồm các cột và hàng, nhưng dữ liệu đa chiều có nhiều đặc điểm hơn.


Đối tượng chính của OLAP là khối, một sự biểu diễn đa chiều của dữ liệu chi tiết và tổng thể. Một khối bao gồm một bảng sự kiện (Fact), một hoặc nhiều bảng chiều (Dimensions), các đơn vị đo (Measures) và các phân hoạch (Partitions).

Ngoài ra còn có Cây phân cấp và số liệu tổng hợp Mức độ chi tiết của các tiêu chí thể hiện cho người dùng được gọi là mức dữ liệu (data granularity), được quyết định bằng việc kết hợp các mức dữ liệu của từng cắt lớp.

Ví dụ: Người dùng có thể lựa chọn mức độ chi tiết của số liệu:

- **Chiều hàng hoá(Product)**, có các mức :
sản phẩm, loại sản phẩm, công nghiệp
- **Chiều thị trường**, có các mức :
khu vực, quốc gia, thành phố, địa điểm
- **Chiều thời gian**, có các mức :
năm, quý, tháng, tuần, ngày

Số liệu tổng hợp: Việc tổng hợp số liệu xảy ra khi người dùng thay đổi mức chi tiết của dữ liệu lấy ra từ cube, bằng cách duyệt qua cây phân cấp của cắt lớp.



Hình 1.6: Mô hình dữ liệu OLAP

Ví dụ: Nếu cắt lớp Thời gian sử dụng ở mức quý thay vì mức ngày thì doanh số của quý sẽ được tổng hợp bằng phép cộng. Tương tự, dữ liệu ở mức Tất cả được tổng hợp bằng giá trị dữ liệu của tất cả các ngày.

1.7.2 Cách hoạt động của OLAP

Một hệ thống xử lý phân tích trực tuyến (OLAP) hoạt động bằng cách thu thập, tổ chức, tổng hợp và phân tích dữ liệu theo các bước sau:

- 1 Máy chủ OLAP thu thập dữ liệu từ nhiều nguồn dữ liệu, bao gồm cơ sở dữ liệu quan hệ và kho dữ liệu.
- 2 Sau đó, các công cụ trích xuất, chuyển đổi và tải (ETL) làm sạch, tổng hợp, tính toán trước và lưu trữ dữ liệu trong một khối OLAP theo số lượng chiều được chỉ định.
- 3 Các chuyên viên phân tích kinh doanh sử dụng công cụ OLAP để truy vấn và lập báo cáo từ dữ liệu đa chiều trong khối OLAP.

OLAP sử dụng ngôn ngữ truy vấn đa chiều (MDX) để truy vấn khối OLAP. MDX là một truy vấn, tương tự như SQL, cung cấp một tập các hướng dẫn để thao tác cơ sở dữ liệu.

1.7.3 Các thao tác trong OLAP

Để thực hiện phân tích đa chiều một cách nhanh chóng và để có phản hồi truy vấn nhanh hơn, OLAP bao gồm các thao tác cơ bản sau:

- *Roll-Up*: Còn được gọi là tổng hợp trong đó dữ liệu từ cấp thấp đến cấp cao được tổng hợp để cung cấp bản tóm tắt ở cấp cao. Chọn A,B,C,SUM(số lượng)
- *Drill-down*: Cho phép điều hướng dữ liệu từ dữ liệu cấp cao hơn đến dữ liệu cấp thấp hơn.

- *Slicing*: Mô tả việc lựa chọn dữ liệu theo một chiều mà khung nhìn là một bảng.
- *Dicing*: Mô tả việc lựa chọn dữ liệu theo nhiều chiều mà chế độ xem lại là một khối phụ.

Sử dụng các thao tác trên olap sẽ đưa ra phân tích đa chiều theo yêu cầu của người dùng. Việc sử dụng tổng phụ của hoạt động Roll-Up có thể được tổng hợp thành tổng cuối, bằng cách sử dụng Drill-down có thể điều hướng từ tổng cuối đến tổng phụ. Bằng cách sử dụng thao tác Dicing, một khối phụ có thể được chọn. Sử dụng Slicing một mặt cắt ngang của khối được chọn tức là có thể chọn một bảng.

1.7.4 Các công nghệ OLAP

Hiện nay OLAP có 3 công nghệ chiếm ưu thế lớn:

- OLAP đa chiều (MOLAP)
- OLAP quan hệ (ROLAP)
- OLAP lai (HOLAP)
- **MOLAP:**
Xử lý phân tích trực tuyến đa chiều (MOLAP) liên quan đến việc tạo ra một khối dữ liệu đại diện cho dữ liệu đa chiều từ một kho dữ liệu. Hệ thống MOLAP lưu trữ dữ liệu được tính toán trước trong siêu khối. Các kỹ sư dữ liệu sử dụng MOLAP vì loại công nghệ OLAP này cung cấp phân tích tốc độ cao.
- **ROLAP:**
Thay vì sử dụng một khối dữ liệu, xử lý phân tích trực tuyến quan hệ (ROLAP) cho phép các kỹ sư dữ liệu thực hiện phân tích dữ liệu đa chiều trên một cơ sở dữ liệu quan hệ. Nói cách khác, các kỹ sư dữ liệu sử dụng truy vấn SQL để tìm kiếm và truy xuất thông tin cụ thể dựa trên các chiều yêu cầu. ROLAP phù hợp cho phân tích dữ liệu rộng và chi tiết. Tuy nhiên, ROLAP có hiệu suất truy vấn chậm so với MOLAP.
- **HOLAP:**
Xử lý phân tích trực tuyến lai (HOLAP) kết hợp MOLAP và ROLAP để mang tới những ưu điểm tốt nhất của cả hai kiến trúc. HOLAP cho phép các kỹ sư dữ liệu nhanh chóng lấy kết quả phân tích từ một khối dữ liệu và trích xuất thông tin chi tiết từ cơ sở dữ liệu quan hệ.

Tổng quan về Business Intelligence

2.1 Giới thiệu chung

2.1.1 Khái niệm

Theo Forrester Research , kinh doanh thông minh (Business Intelligence) là "một tập hợp các phương pháp, quy trình, kiến trúc và công nghệ biến dữ liệu thô thành thông tin có ý nghĩa và hữu ích được sử dụng để cho phép hiểu biết sâu sắc về chiến lược, chiến thuật và hoạt động cũng như ra quyết định hiệu quả hơn trong kinh doanh."



Hình 2.1: Business Intelligence

Theo định nghĩa này, kinh doanh thông minh (Business Intelligence) bao gồm quản lý thông tin (tích hợp dữ liệu , chất lượng dữ liệu , lưu trữ kho dữ liệu, quản lý dữ liệu thông minh, phân tích nội dung văn bản, v.v.). Do đó, Forrester coi việc chuẩn bị dữ liệu và sử dụng dữ liệu là hai phân đoạn riêng biệt nhưng được liên kết chặt chẽ với nhau trong kiến trúc kinh doanh thông minh.

Một số yếu tố trong kinh doanh thông minh, gọi tắt là BI, bao gồm:

- Kết hợp và phân bổ đa chiều.
- Phi chuẩn, gán nhãn và chuẩn hóa.
- Báo cáo thời gian thực với cảnh báo phân tích.
- Phương pháp giao tiếp với các nguồn dữ liệu phi cấu trúc.
- Hợp nhất nhóm, lập ngân sách và dự báo theo kiểu rolling.
- Suy luận thống kê và mô phỏng xác suất.
- Tối ưu hóa các chỉ số hiệu suất chính.
- Kiểm soát phiên bản và quản lý quy trình.
- Quản lý mục mở.

Forrester phân biệt điều này với thị trường kinh doanh thông minh, vốn "chỉ là các lớp trên cùng của kiến trúc BI, chẳng hạn như báo cáo, phân tích và dashboard"[1].

2.1.2 Lịch sử

Năm 1865, Richard Millar Devens trình bày cụm từ “Kinh doanh thông minh” (BI) trong “Cyclopædia of Commercial and Business Anecdotes.” Ông dùng nó để mô tả cách Ngài Henry Furnese, một chủ ngân hàng, thu lợi từ thông tin bằng cách thu thập và hành động dựa trên thông tin đó trước đối thủ cạnh tranh. Gần đây hơn, vào năm 1958, một bài báo được viết bởi nhà khoa học máy tính của IBM tên là Hans Peter Luhn, mô tả tiềm năng thu thập thông tin kinh doanh thông minh (BI) thông qua việc sử dụng công nghệ.

Kinh doanh thông minh, như được hiểu ngày nay, sử dụng công nghệ để thu thập và phân tích dữ liệu, chuyển nó thành thông tin hữu ích và hành động dựa trên nó “trước khi cạnh tranh”. Về cơ bản, phiên bản hiện đại của BI tập trung vào công nghệ như một cách để đưa ra quyết định nhanh chóng và hiệu quả, dựa trên thông tin phù hợp vào đúng thời điểm.


Vào năm 1968, chỉ những cá nhân có kỹ năng cực kỳ chuyên môn mới có thể chuyển dữ liệu thành thông tin có thể sử dụng được. Vào thời điểm này, dữ liệu từ nhiều nguồn thường được lưu trữ trong các kho riêng biệt và nghiên cứu thường được trình bày dưới dạng một báo cáo rời rạc, phân mảnh và có thể giải thích được. Edgar Codd nhận ra đây là một vấn đề và xuất bản một bài báo vào năm 1970, thay đổi cách mọi người nghĩ về cơ sở dữ liệu. Đề xuất của ông về việc phát triển một “mô hình cơ sở dữ liệu quan hệ” đã trở nên vô cùng phổ biến và được áp dụng trên toàn thế giới.

Hệ thống hỗ trợ quyết định (Decision support systems(DSS)) là hệ thống quản lý cơ sở dữ liệu đầu tiên được phát triển. Nhiều nhà sử học cho rằng phiên bản kinh doanh thông minh hiện đại được phát triển từ cơ sở dữ liệu DSS. Số lượng nhà cung cấp BI tăng lên vào những năm 1980, khi các doanh nhân phát hiện ra giá trị của kinh doanh thông minh. Một loạt các công cụ đã

được phát triển trong thời gian này để truy cập và sắp xếp dữ liệu theo những cách đơn giản hơn. OLAP, hệ thống thông tin điều hành và kho dữ liệu là một số công cụ được phát triển để hoạt động với DSS [3].

2.2 Các thành phần của hệ thống BI

Một hệ thống BI điển hình bao gồm bốn cấp độ thành phần và mô-đun quản lý siêu dữ liệu. Kiến trúc chung của các hệ thống BI truyền thống được hiển thị bên dưới. Các thành phần khác nhau này hợp tác với nhau để tạo điều kiện thuận lợi cho các chức năng BI cơ bản: trích xuất dữ liệu từ hệ thống vận hành của công ty, lưu trữ dữ liệu đã trích xuất trong kho dữ liệu trung tâm và truy xuất dữ liệu đã lưu trữ cho các ứng dụng phân tích kinh doanh khác nhau [5].



Hình 2.2: Kiến trúc chung của hệ thống kinh doanh thông minh

- **Cấp độ hệ thống vận hành:**

Là nguồn dữ liệu của hệ thống BI, hệ thống vận hành kinh doanh chủ yếu là hệ thống xử lý giao dịch trực tuyến (OLTP) hỗ trợ hoạt động kinh doanh hàng ngày. Các hệ thống OLTP điển hình là hệ thống xử lý đơn đặt hàng của khách hàng, hệ thống tài chính và hệ thống quản lý nguồn nhân lực.

- **Cấp độ thu thập dữ liệu:**

Cấp độ này là thành phần tiền xử lý dữ liệu bao gồm ba giai đoạn: trích xuất, chuyển đổi và tải (ETL). Một công ty thường có các hệ thống OLTP khác nhau tạo ra lượng dữ liệu khổng lồ. Dữ liệu này trước tiên được trích xuất từ các hệ thống OLTP bằng quy trình

ETL và sau đó được chuyển đổi theo một bộ quy tắc chuyển đổi. Dữ liệu được chuyển đổi sẽ sạch sẽ, thống nhất và tổng hợp và cuối cùng được tải vào kho dữ liệu trung tâm. ETL là thành phần cơ bản nhất của hệ thống BI vì chất lượng dữ liệu của tất cả các thành phần khác chủ yếu dựa vào quy trình ETL. Trong thiết kế và phát triển ETL, chất lượng dữ liệu, tính linh hoạt của hệ thống và tốc độ xử lý là những mối quan tâm chính.

- **Mức lưu trữ dữ liệu:**

Dữ liệu được xử lý bởi thành phần ETL được lưu trữ trong kho dữ liệu được triển khai chủ yếu bằng hệ thống quản lý cơ sở dữ liệu quan hệ truyền thống (RDBMS). RDBMS được thiết kế để hỗ trợ xử lý giao dịch. Ngược lại, kho dữ liệu là kho lưu trữ dữ liệu tích hợp (integrated), có định hướng chủ đề (subject oriented), thay đổi theo thời gian (time-variant) và không biến động (non-volatile)(Inmon 1993). Dữ liệu từ hệ thống OLTP của công ty được trích xuất, chuyển đổi và tải vào kho dữ liệu dựa trên các lược đồ được xác định trước. Lược đồ hình sao (star schema) và lược đồ bông tuyết(snowflake schema) là những lược đồ kho dữ liệu phổ biến nhất. Cho dù kho dữ liệu được thiết kế theo loại lược đồ nào thì kho dữ liệu luôn bao gồm hai loại bảng cơ bản: bảng fact và bảng dimension.

- **Cấp độ phân tích.**

Dựa trên kho dữ liệu, nhiều loại ứng dụng phân tích khác nhau được phát triển, đại diện cho cấp độ cuối cùng: Phân tích. Hệ thống BI hỗ trợ hai loại chức năng phân tích cơ bản: báo cáo và xử lý phân tích trực tuyến (OLAP). Chức năng báo cáo cung cấp cho người quản lý các báo cáo kinh doanh khác nhau, chẳng hạn như báo cáo bán hàng, báo cáo sản phẩm và báo cáo nhân sự. Báo cáo được tạo bằng cách thực hiện các truy vấn vào kho dữ liệu (DW). Các truy vấn DW chủ yếu là các câu truy vấn được xác định trước do các nhà phát triển DW lập trình. Do đó, các báo cáo do hệ thống BI tạo ra thường có định dạng tĩnh và chứa các loại dữ liệu cố định.

Phân tích BI hứa hẹn nhất là OLAP. OLAP cho phép người quản lý duyệt hiệu quả dữ liệu kinh doanh của họ từ các khía cạnh phân tích khác nhau thông qua các hoạt động slicing, dicing và drilling theo ý muốn. Phân tích dimension là một góc độ trong đó dữ liệu được trình bày, ví dụ: loại sản phẩm, địa điểm bán hàng, thời gian và khách hàng. So với chức năng báo cáo, OLAP hỗ trợ phân tích dữ liệu đặc biệt, tức là người quản lý có toàn quyền kiểm soát dữ liệu bằng cách chọn các dimension phân tích khác nhau mà họ quan tâm. OLAP dựa trên các mô hình dữ liệu đa chiều (được gọi là lược đồ bông tuyết và ngôi sao).

Ngoài báo cáo và OLAP, còn có nhiều loại ứng dụng phân tích khác có thể được xây dựng trên cơ sở hệ thống DW, chẳng hạn như khai thác dữ liệu, dashboard, quản lý quan hệ khách hàng và quản lý hiệu quả kinh doanh. Về mặt kỹ thuật, các ứng dụng này không nhất thiết phải được xây dựng trên kho dữ liệu. Tuy nhiên, việc tích hợp chúng với các hệ thống DW đã trở thành một thông lệ trong nhiều hệ thống BI thực tế.

- **Quản lý siêu dữ liệu:**

Siêu dữ liệu là dữ liệu đặc biệt về các dữ liệu khác như nguồn dữ liệu, lưu trữ kho dữ liệu, quy tắc kinh doanh, ủy quyền truy cập cũng như cách trích xuất và chuyển đổi các dữ liệu khác nhau. Siêu dữ liệu rất quan trọng để tạo ra thông tin chính xác, nhất quán và bảo trì

hệ thống. Nó ảnh hưởng đến toàn bộ quá trình thiết kế, phát triển, thử nghiệm, triển khai và sử dụng hệ thống BI (Caserta 2004; Inmon 2002).

2.3 Ứng dụng của BI

BI có thể được ứng dụng trong nhiều lĩnh vực kinh doanh khác nhau, bao gồm: [7]

- **Marketing:** BI giúp doanh nghiệp phân tích hành vi khách hàng, từ đó đưa ra các chiến lược marketing hiệu quả hơn.
- **Bán hàng:** BI giúp doanh nghiệp phân tích hiệu quả hoạt động bán hàng, từ đó tối ưu hóa quy trình bán hàng.
- **Chăm sóc khách hàng:** BI giúp doanh nghiệp phân tích phản hồi của khách hàng, từ đó nâng cao chất lượng dịch vụ khách hàng.
- **Sản xuất:** BI giúp doanh nghiệp tối ưu hóa quy trình sản xuất, từ đó giảm chi phí và tăng năng suất.
- **Tài chính:** BI giúp doanh nghiệp phân tích tình hình tài chính, từ đó đưa ra các quyết định đầu tư hiệu quả hơn, hỗ trợ quyết định.
- **Kinh doanh:** Phân tích dữ liệu về tương tác của khách hàng với các kênh tiếp thị như email, mạng xã hội, và trang web, đánh giá hiệu quả của các chiến dịch tiếp thị, từ đó tối ưu hóa chiến lược tiếp thị.

2.4 Trực quan hóa dữ liệu với PowerBI

2.4.1 Tổng quan về PowerBI

Giới thiệu chung

Power BI là một công cụ phân tích dữ liệu và trực quan hóa dữ liệu của Microsoft. Công cụ này là tập hợp các ứng dụng, dịch vụ phần mềm và trình kết nối kết hợp với nhau để biến các tệp dữ liệu rời rạc thành thông tin chuyên sâu mang tính tương tác và ấn tượng về mặt trực quan. Power BI có thể hoạt động với các nguồn dữ liệu đơn giản như Microsoft Excel và các nguồn dữ liệu phức tạp như cơ sở dữ liệu trên cloud, mySQL... Power BI có khả năng dễ dàng kết nối với các nguồn dữ liệu, trực quan hóa, chia sẻ và publish các phân tích của bạn để bất kỳ ai cũng có thể truy cập. Power BI có thể kết nối với file Excel hoặc cơ sở dữ liệu cục bộ một cách dễ dàng. Đây cũng là một công cụ mạnh mẽ, phù hợp cho việc phân tích dữ liệu thời gian thực. Điều này có nghĩa là nó có thể được sử dụng trong nhiều môi trường khác nhau, từ công cụ trực quan và báo cáo cá nhân đến công cụ phân tích và ra quyết định đằng sau các dự án nhóm, bộ phận hoặc toàn bộ tập đoàn. Vì Power BI là một sản phẩm của Microsoft và được tích hợp sẵn các kết nối với Excel nên có nhiều chức năng quen thuộc với người dùng Excel. [2]



Hình 2.3: Logo Power BI

Tính năng chính

Power BI có một số tính năng chính sau:

- Kết nối với dữ liệu: Power BI cho phép người dùng kết nối với dữ liệu từ nhiều nguồn khác nhau, bao gồm:
 - Cơ sở dữ liệu SQL Server
 - Cơ sở dữ liệu Oracle
 - Cơ sở dữ liệu MySQL
 - Tập Excel
 - Tập CSV
 - Ứng dụng web
 - Dịch vụ đám mây
- Phân tích dữ liệu: Power BI cung cấp một số công cụ phân tích dữ liệu mạnh mẽ, bao gồm:
 - Tạo truy vấn
 - Tạo bảng tổng hợp
 - Tạo biểu đồ và đồ thị
 - Tạo mô hình dữ liệu
- Trực quan hóa dữ liệu: Power BI cung cấp một thư viện các biểu đồ và đồ thị trực quan hóa dữ liệu phong phú. Người dùng có thể tùy chỉnh các biểu đồ và đồ thị này để phù hợp với nhu cầu của mình.
- Chia sẻ dữ liệu: Power BI cho phép người dùng chia sẻ dữ liệu và báo cáo với người khác. Người dùng có thể chia sẻ dữ liệu qua web, qua email hoặc qua ứng dụng di động

Ưu điểm nổi bật


Power BI có một số ưu điểm nổi bật sau:

- Dễ sử dụng: Power BI có giao diện người dùng trực quan và dễ sử dụng. Người dùng không cần phải có kiến thức kỹ thuật cao để sử dụng Power BI
- Khả năng kết nối với nhiều nguồn dữ liệu: Power BI có thể kết nối với dữ liệu từ nhiều nguồn khác nhau, giúp người dùng dễ dàng truy cập và phân tích dữ liệu.
- Công cụ phân tích dữ liệu mạnh mẽ: Power BI cung cấp một số công cụ phân tích dữ liệu mạnh mẽ, giúp người dùng dễ dàng phân tích dữ liệu phức tạp.
- Tính năng trực quan hóa dữ liệu phong phú: Power BI cung cấp một thư viện các biểu đồ và đồ thị trực quan hóa dữ liệu phong phú, giúp người dùng dễ dàng hiểu và truyền đạt kết quả phân tích dữ liệu.

2.4.2 Xử lý dữ liệu với PowerBI

Tiền xử lý dữ liệu

Tiền xử lý dữ liệu là một bước quan trọng trong quá trình phân tích dữ liệu. Tiền xử lý dữ liệu giúp đảm bảo rằng dữ liệu được làm sạch và chuẩn hóa, sẵn sàng cho phân tích. Tiền xử lý dữ liệu gồm 3 bước: trích xuất, chuyển đổi và tải. Quá trình này trích xuất, chuyển đổi và tải dữ liệu từ nhiều nguồn vào kho dữ liệu. Dữ liệu được thu thập tập trung này giúp phân tích sâu hơn và xử lý dữ liệu dễ dàng hơn. Trong Power BI, tiền xử lý dữ liệu được thực hiện trong Power Query Editor. Power Query Editor là một công cụ tích hợp trong Power BI cho phép người dùng kết nối với dữ liệu từ nhiều nguồn khác nhau, chuyển đổi dữ liệu và tải dữ liệu vào Power BI. Có



Hình 2.4: Tiền xử lý dữ liệu với Power Query

một số công cụ và tính năng tiền xử lý dữ liệu có sẵn trong Power Query Editor, có thể kể đến:

- Tạo truy vấn: Truy vấn là một tập hợp các hướng dẫn cho Power Query Editor về cách trích xuất dữ liệu từ nguồn dữ liệu. Khi tạo truy vấn, người dùng có thể sử dụng các công cụ và tính năng tiền xử lý dữ liệu để làm sạch và chuẩn hóa dữ liệu.
- Thay đổi kiểu dữ liệu: Power Query Editor cho phép người dùng thay đổi kiểu dữ liệu của các cột dữ liệu. Điều này có thể giúp đảm bảo rằng dữ liệu được xử lý chính xác.
- Xóa các cột: Power Query Editor cho phép người dùng xóa các cột dữ liệu không cần thiết. Điều này có thể giúp cải thiện hiệu suất phân tích dữ liệu.

- Trộn và hợp nhất các bảng: Power Query Editor cho phép người dùng trộn và hợp nhất các bảng dữ liệu. Điều này có thể giúp tạo ra một tập dữ liệu duy nhất cho phân tích.
- Thêm các cột: Power Query Editor cho phép người dùng thêm các cột dữ liệu mới. Điều này có thể giúp bổ sung thêm thông tin cho phân tích dữ liệu.
- Pivot: Chuyển đổi các hàng thành cột. Điều này rất hữu ích khi bạn muốn tổng hợp dữ liệu theo một tiêu chí cụ thể. Ví dụ, nếu bạn có dữ liệu bán hàng hàng tháng và muốn chuyển nó thành dữ liệu tổng hợp theo năm.
- Unpivot: Chuyển đổi các cột thành hàng. Điều này hữu ích khi bạn có dữ liệu trong nhiều cột và muốn hợp nhất chúng thành một cột với các giá trị tương ứng.
- Power Query Editor cho phép bạn chạy các script R và Python để thực hiện các phân tích và biến đổi dữ liệu nâng cao mà không có sẵn qua giao diện người dùng. Điều này rất hữu ích cho các nhà phân tích dữ liệu và nhà khoa học dữ liệu muốn áp dụng các kỹ thuật phức tạp hơn.
- Data Profiling: Hiển thị thông tin thống kê về các cột dữ liệu như số lượng giá trị duy nhất, giá trị rỗng, phân phối giá trị, giúp bạn kiểm tra và đảm bảo chất lượng dữ liệu.

Mô hình hóa dữ liệu

Về bản chất, mô hình hóa dữ liệu là quá trình xác định cấu trúc dữ liệu, các thuộc tính và mối quan hệ trong một mô hình dữ liệu. Mô hình dữ liệu trong Power BI là một biểu diễn logic của cách dữ liệu được cấu trúc và liên kết trong công cụ này. Nó là một tập hợp các bảng và các mối quan hệ giữa chúng được sử dụng để tạo báo cáo và trực quan hóa.^[9] Một mô hình dữ liệu thường bao gồm một hoặc nhiều nguồn dữ liệu, có thể là từ bảng tính Excel cho đến các cơ sở dữ liệu trên nền tảng đám mây và một hoặc nhiều bảng đại diện cho dữ liệu trong các nguồn đó. Các mối quan hệ kết nối các bảng này là nền tảng của mô hình hóa dữ liệu. Có ba khái niệm mô hình hóa dữ liệu: mô hình hóa dữ liệu khái niệm, mô hình hóa dữ liệu logic và mô hình hóa dữ liệu vật lý. Từ trừu tượng đến cụ thể, các khái niệm mô hình hóa dữ liệu tạo ra một bản thiết kế cho cách dữ liệu được tổ chức và quản lý trong một tổ chức.^[9] Sự cần thiết của mô hình hóa dữ liệu:

- Hỗ trợ khám phá dữ liệu: Mô hình hóa dữ liệu cho phép người dùng tạo các cấp bậc và các đường đi phân tích, điều này hỗ trợ việc khám phá dữ liệu hiệu quả. Người dùng có thể nhanh chóng điều hướng qua dữ liệu để phát hiện các thông tin chi tiết và nhận diện xu hướng.
- Ảnh hưởng đến hiệu suất: Cách thiết kế mô hình dữ liệu ảnh hưởng trực tiếp đến tốc độ và hiệu quả của việc truy xuất dữ liệu. Các mô hình dữ liệu thiết kế kém, như những mô hình có mối quan hệ phức tạp và sự dư thừa dữ liệu, có thể dẫn đến hiệu suất truy vấn chậm, gây ra sự chậm trễ trong việc hiển thị báo cáo.
- Thúc đẩy báo cáo chính xác hơn: Khi mô hình dữ liệu được thiết kế đúng cách, nó có thể đảm bảo độ chính xác, sự nhất quán và độ tin cậy của dữ liệu sử dụng trong báo cáo. Điều này có thể mang lại những thông tin chi tiết chính xác hơn và cải thiện quyết định.


- Dễ bảo trì: Một mô hình dữ liệu được thiết kế tốt đảm bảo rằng các báo cáo có khả năng mở rộng, điều này có thể giảm bớt nỗ lực cần thiết để duy trì báo cáo khi doanh nghiệp phát triển và thay đổi. Việc tạo các thành phần có thể tái sử dụng, cải thiện tài liệu và chuẩn hóa dữ liệu cũng có thể đảm bảo rằng các báo cáo dễ dàng bảo trì và cập nhật theo thời gian.

Các khái niệm mô hình hóa dữ liệu[8]:

- Mô hình dữ liệu khái niệm: Thể hiện cách thế giới kinh doanh nhìn nhận thông tin mà nó sử dụng, tập trung vào bức tranh tổng thể và các mục tiêu chiến lược quan trọng. Nó không cụ thể mà mang tính chung chung, chỉ nắm bắt mức độ sử dụng kinh doanh cao nhất. Mô hình này đi kèm với sơ đồ phân cấp hoạt động hoặc phân rã chức năng để thể hiện các chức năng chính trong khu vực vấn đề kinh doanh.
- Mô hình dữ liệu logic: Mô hình dữ liệu logic là diễn giải có cấu trúc hơn của mô hình kinh doanh khái niệm, dùng làm cơ chế giao tiếp trong môi trường kỹ thuật. Nó tập trung vào chi tiết các thực thể và mối quan hệ của chúng. Các bước chính bao gồm:
 1. Đưa mô hình khái niệm vào dạng chuẩn thực thể.
 2. Giải quyết mối quan hệ nhiều-nhiều bằng cách xác định thực thể liên kết.
 3. Xác định các mục dữ liệu duy nhất nhận diện thực thể (candidate identifiers).
 4. Lựa chọn các định danh chính từ danh sách các ứng cử viên (primary identifiers).
 5. Gán thuộc tính cho các thực thể đã được xác định và khóa.
 6. Chuyển các khóa chính xuống các thực thể phụ thuộc như khóa ngoại.
 7. Định nghĩa các miền của tất cả các thuộc tính và các quy tắc ràng buộc.
- Mô hình dữ liệu vật lý: Mô hình vật lý là diễn giải chi tiết hơn và có cấu trúc của mô hình logic, mô tả những thay đổi để phù hợp với môi trường mục tiêu. Nó đi kèm với các sơ đồ đường dẫn truy cập, hiển thị chi tiết các đường dẫn sẽ được thực hiện qua mô hình khi mỗi quy trình được thực hiện. Mô hình này đảm bảo hiệu suất tối đa trong môi trường mục tiêu.
- Mô hình dữ liệu chiều: Mô hình dữ liệu chiều là sự triển khai vật lý của cấu trúc quan hệ thực thể đã được chuẩn hóa. Chúng thường được sử dụng trong các kho dữ liệu và các kho dữ liệu nhỏ, được xem như phần của các cơ sở dữ liệu chuyên dụng.

Trực quan hóa dữ liệu

Sau khi tạo mô hình dữ liệu, bạn có thể tạo báo cáo và dashboard. Báo cáo và dashboard là các công cụ trực quan hóa dữ liệu giúp bạn dễ dàng hiểu và truyền đạt kết quả phân tích dữ liệu.



Hình 2.5: Tạo dashboard để trực quan hoá dữ liệu

Khảo sát hệ thống

3.1 Tổng quan về E-commerce

Ngày nay, với sự phát triển mạnh mẽ của thương mại điện tử, nhu cầu mua sắm trực tuyến gia tăng đáng kể. Sự tiện lợi, phong phú về sản phẩm và trải nghiệm khách hàng đã thúc đẩy nhiều người tiêu dùng chuyển sang mua sắm qua các nền tảng E-commerce. E-Commerce đã và đang trở thành lĩnh vực có ảnh hưởng cực kỳ quan trọng đến tăng trưởng kinh tế của các quốc gia. Thị trường đang có xu hướng tăng trưởng, đạt tổng giá trị 20,5 tỷ đô vào 2023. Tuy nhiên, sự gia tăng này cũng dẫn đến việc sinh ra khối lượng dữ liệu khổng lồ, bao gồm các dữ liệu về khách hàng, đơn hàng, sản phẩm, kho hàng, và phản hồi từ khách hàng. Quản lý và phân tích dữ liệu đa dạng này để đưa ra quyết định kinh doanh phù hợp trở thành một thách thức lớn cho các doanh nghiệp.

Để tận dụng tối đa giá trị từ dữ liệu E-commerce, các doanh nghiệp cần xây dựng một hệ thống tổng hợp và phân tích dữ liệu. Hệ thống này không chỉ giúp tối ưu hóa việc quản lý dữ liệu mà còn tạo điều kiện cho các phân tích chuyên sâu để nâng cao trải nghiệm khách hàng và cải thiện hiệu quả kinh doanh.

3.1.1 Hệ thống tổng hợp và phân tích dữ liệu E-commerce

Hệ thống tổng hợp và phân tích dữ liệu E-commerce là một giải pháp công nghệ tiên tiến được triển khai nhằm thu thập, lưu trữ, quản lý, và phân tích dữ liệu liên quan đến hoạt động E-commerce. Hệ thống này giúp các doanh nghiệp thương mại điện tử đưa ra quyết định kinh doanh hiệu quả hơn và cung cấp dịch vụ khách hàng tối ưu.


Hệ thống tích hợp các công nghệ như AI, Machine Learning, Big Data, và Analytics. AI và Machine Learning có thể hỗ trợ trong việc phân tích hành vi của khách hàng, dự đoán nhu cầu, và cá nhân hóa dịch vụ. Big Data và Analytics xử lý khối lượng dữ liệu lớn từ nhiều nguồn, giúp doanh nghiệp có cái nhìn toàn diện về xu hướng thị trường và nhu cầu người tiêu dùng. Các công nghệ này cho phép phân tích chi tiết để tối ưu hóa quy trình bán hàng, cải thiện chiến lược marketing, và tăng tỷ lệ chuyển đổi. Hệ thống tổng hợp và phân tích dữ liệu E-commerce giúp:

- Hiểu rõ hơn về hành vi khách hàng: Phân tích dữ liệu để hiểu rõ hơn về nhu cầu, sở thích và hành vi mua sắm, giúp tùy chỉnh dịch vụ cho từng khách hàng.
- Tối ưu hóa quyết định kinh doanh: Giúp quản lý và tối ưu hóa các quyết định liên quan đến kho hàng, chuỗi cung ứng, và định giá sản phẩm.

- Cải thiện trải nghiệm khách hàng: Giúp cung cấp trải nghiệm cá nhân hóa thông qua việc phân tích hành vi người dùng và tối ưu hóa các điểm chạm trên hành trình mua sắm.
- Dự đoán xu hướng thị trường: Phân tích dữ liệu lịch sử để dự báo nhu cầu và xu hướng mua sắm, giúp doanh nghiệp chuẩn bị chiến lược kinh doanh hiệu quả.
- Phát hiện gian lận: Sử dụng các mô hình học máy để phát hiện và ngăn chặn các hành vi gian lận, bảo vệ lợi ích của doanh nghiệp và khách hàng.
- Tối ưu hóa chiến lược marketing: Phân tích hiệu quả của các chiến dịch marketing, giúp tối ưu chi phí và tăng tỷ lệ chuyển đổi.
- Quản lý tài chính hiệu quả: Hệ thống giúp tối ưu hóa nguồn tài chính và quản lý dòng tiền, hỗ trợ doanh nghiệp tăng trưởng bền vững.

3.1.2 Giới thiệu về công ty Olist


Olist là một tập đoàn công nghệ được thành lập vào năm 2015 bởi Tiago Dalvi, trụ sở đặt tại thành phố Curitiba, bang Parana, Brazil. Tập đoàn này điều hành trang web thương mại điện tử Olist - là nơi kết nối nhiều cửa hàng và sản phẩm của họ với thị trường tiêu dùng Brazil. Olist tạo ra môi trường hoạt động, kinh doanh mua bán cho nhiều đối tượng, từ chủ cửa hàng bán lẻ đến các doanh nghiệp lớn đều có thể tham gia vào hệ thống thương mại điện tử này. Đến nay, sàn thương mại điện tử Olist đã thu hút được hơn 200.000 người dùng đến từ hơn 180 quốc gia trên thế giới và hơn 45.000 cửa hàng, nhà bán lẻ đăng ký kinh doanh trên hệ thống. Olist được đầu tư phát triển trên nhiều kênh truyền thông cũng như mạng xã hội, tăng khả năng tiếp cận thêm nhiều đối tượng khách hàng thông qua nhiều phương thức khác nhau.



Hình 3.1: Công ty thương mại điện tử Olist

3.2 Model Canvas

Mô hình canvas của Olist gồm 9 khung chính:



Hình 3.2: Công ty thương mại điện tử Olist

1. Key partners: Những đối tác chính của Olist là các công ty vận chuyển nội địa và quốc tế, và các bên thanh toán cùng các nhà cung cấp sản phẩm:

- Công ty vận chuyển: Correios, DHL, FedEx, ..
- Đối tác thanh toán: PagSeguro, PayPal, ..
- Nhà cung cấp sản phẩm: Samsung, Sony, Nestlé, Nike, các nhà bán lẻ nhỏ

2. Key activities: Hoạt động chính của công ty là quản lý sàn thương mại điện tử, giúp vận chuyển hàng hóa và chăm sóc khách hàng cùng đưa ra những chiến lược phù hợp để tối ưu hóa trải nghiệm mua hàng:

- Quản lý và bán sản phẩm
- Vận chuyển
- Chăm sóc khách hàng
- Tối ưu hóa dữ liệu

3. Key resources: Nguồn lực quan trọng nhất của Olist là cửa hàng thương mại điện tử, dữ liệu của khách hàng và hệ thống nhân sự.

- Dữ liệu khách hàng
- Hệ thống CRM
- Hệ thống phân tích
- Đội ngũ hỗ trợ khách hàng

4. Channels: Các kênh của Olist được biết đến rộng rãi: nền tảng số của Olist, trang web, ứng dụng di động cũng như phương tiện truyền thông xã hội và đại chúng của họ.

- Nền tảng Olist
- Website
- Ứng dụng di động
- Email marketing
- Mạng xã hội

5. Value propositions : Olist xây dựng một hệ sinh thái thương mại điện tử hỗ trợ và tối ưu hóa quy trình kinh doanh cho các nhà bán lẻ vừa và nhỏ. Các giá trị cốt lõi bao gồm:

- Tiếp cận thị trường rộng lớn
- Dịch vụ hỗ trợ toàn diện
- Tối ưu hóa marketing và trải nghiệm khách hàng
- Phân tích và quản lý dữ liệu kinh doanh

6. Customer segments: Việc phân khúc khách hàng của Olist chủ yếu được thực hiện nhờ chiến lược giá thấp cơ bản. Do đó, khách hàng của nó có xu hướng là những người đang tìm kiếm sản phẩm giá rẻ nhưng chất lượng tốt, cho dù họ là người có thu nhập thấp hay chỉ tìm kiếm lợi ích chi phí tốt nhất.

- Người tiêu dùng trực tuyến
- Các nhà bán lẻ và doanh nghiệp có nhu cầu tiếp cận thị trường

7. Customer relationships: Về mối quan hệ với khách hàng, có 2 thành phần chính:

- Với người bán: tạo điều kiện tối ưu cho người mở gian hàng, hỗ trợ tiếp cận khách hàng
- Với người mua: bảo vệ quyền lợi khách hàng, chăm sóc và hỗ trợ 24/7, có các chương trình khuyến mãi và giảm giá

8. Cost structure: Chi phí chính của nền tảng là chi phí nhân sự và các chi phí duy trì nền tảng cùng quảng cáo:

- Chi phí phát triển và duy trì nền tảng công nghệ

- Chi phí vận chuyển và logistics
- Chi phí marketing và quảng cáo
- Chi phí hỗ trợ khách hàng và quản lý yêu cầu
- Chi phí quản lý và điều hành

9. Revenue streams: Doanh thu chính của Olist đến từ phí hoa hồng các doanh nghiệp bán lẻ trả cho nền tảng, cùng với đó là các dịch vụ cao cấp và các dịch vụ marketing:

- Phí hoa hồng bán hàng
- Phí dịch vụ vận chuyển và logistics
- Phí tư vấn và phân tích dữ liệu
- Dịch vụ quảng cáo và marketing cho nhà bán hàng
- Gói dịch vụ cao cấp


3.3 Khảo sát nghiệp vụ

3.3.1 Các hệ thống đang sử dụng trong E-commerce

- **Hệ thống quản lý khách hàng (CRM):** Hệ thống CRM giúp quản lý mối quan hệ với khách hàng, lưu trữ thông tin liên lạc, lịch sử mua hàng, phản hồi và đánh giá của khách hàng, cũng như hỗ trợ quá trình bán hàng và chăm sóc khách hàng.
- **Hệ thống quản lý sản phẩm:** Lưu trữ và xử lý thông tin về sản phẩm như tên, mã, giá cả, tồn kho, và danh mục. Hệ thống này cho phép quản lý sản phẩm dễ dàng, hỗ trợ cập nhật nhanh chóng các thay đổi và tối ưu hóa danh mục sản phẩm.
- **Hệ thống thanh toán và xử lý giao dịch:** Xử lý các giao dịch thanh toán, bao gồm các phương thức thanh toán trực tuyến, ví điện tử, và các chương trình khuyến mãi. Hệ thống này đảm bảo quá trình thanh toán nhanh chóng, an toàn và đáng tin cậy.
- **Hệ thống kho vận:** Theo dõi và quản lý quá trình giao nhận từ người bán đến người mua. Hệ thống này giúp giảm thiểu chi phí vận hành và nâng cao hiệu quả chuỗi cung ứng.

3.3.2 Luồng nghiệp vụ

Luồng nghiệp vụ đặt hàng trực tuyến




Hình 3.3: Luồng nghiệp vụ đặt hàng trực tuyến

Khách hàng truy cập vào website của hệ thống thương mại điện tử, nơi hiển thị các sản phẩm từ nhiều cửa hàng khác nhau. Khách hàng có thể tìm kiếm và lựa chọn sản phẩm mà họ muốn mua. Nếu họ quyết định mua ngay sản phẩm đã chọn, hệ thống sẽ tiếp nhận yêu cầu mua hàng, tính giá trị đơn hàng và gửi thông tin thanh toán cho khách hàng. Nếu khách hàng chưa muốn mua ngay, họ có thể thêm sản phẩm vào giỏ hàng và thanh toán sau.

Khi hệ thống hiển thị giá trị đơn hàng và thông tin thanh toán, khách hàng sẽ chọn phương thức thanh toán phù hợp. Sau khi xác nhận thanh toán, hệ thống gửi thông báo xác nhận qua website và đồng thời gửi thông tin địa chỉ của khách hàng cho bộ phận quản lý kho vận. Bộ phận này cập nhật lại số lượng sản phẩm trong kho, đóng gói hàng và chuẩn bị vận chuyển. Thông tin đơn hàng chi tiết cũng được in ra để phục vụ cho quá trình giao hàng.

Luồng nghiệp vụ giao hàng




Hình 3.4: Luồng nghiệp vụ giao hàng

Hệ thống giao hàng tiếp nhận thông tin đơn hàng, ước lượng thời gian giao hàng và hiển thị ngày giao dự kiến trên trang web. Người giao hàng nhận hàng từ kho và thông báo cho khách hàng về thời gian giao hàng dự kiến.


Trong quá trình vận chuyển, bộ phận quản lý giao vận liên tục kiểm tra và cập nhật tình trạng đơn hàng cho đến khi khách hàng xác nhận đã nhận được hàng. Nếu có vấn đề về giao nhận, hệ thống sẽ kiểm tra và cập nhật thông tin kịp thời cho khách hàng. Khách hàng có thể phản hồi về chất lượng sản phẩm và dịch vụ, và nếu cần, thực hiện quy trình trả hàng.

3.3.3 Cây nghiệp vụ



Hình 3.5: Cây nghiệp vụ của Olist

3.3.4 Biểu đồ luồng dữ liệu (Data flow)



Hình 3.6: Data flow của hệ thống

3.4 Yêu cầu phân tích

3.4.1 Khảo sát yêu cầu hệ thống

Đánh giá hệ thống hiện tại

Hệ thống xử lý dữ liệu hiện có đáp ứng được các chức năng lưu trữ và quản lý cơ bản. Tuy nhiên vẫn còn rất nhiều vấn đề tồn đọng trong hệ thống xử lý này:

- Dữ liệu mang tính thống kê, chưa phân tích theo nhiều chiều
- Dữ liệu dư thừa
- Dữ liệu chưa có khả năng rút ra đánh giá hiệu suất bán hàng

Yêu cầu hệ thống mới

Từ những hạn chế của hệ thống hiện tại, chúng em đặt ra những yêu cầu cho hệ thống mới để cải tiến chất lượng hệ thống quản trị, xử lý dữ liệu:

- Dễ dàng trích xuất dữ liệu
- Kiến trúc linh hoạt, dễ dàng mở rộng quy mô dữ liệu
- Cung cấp các công cụ phân tích, đưa ra các dashboard, báo cáo trực quan dữ liệu
- Đáp ứng dữ liệu lớn, dễ dàng chuẩn hóa thống nhất dữ liệu theo yêu cầu phân tích
- Hệ thống mới sẽ có chức năng phân tích dữ liệu dựa trên nhiều chiều
- Cập nhật dữ liệu theo định kỳ

3.4.2 Các yêu cầu phân tích

Với bài toán E-commerce chúng em đề xuất phân tích các khía cạnh liên quan đến 4 chủ đề chính:

- **Phân tích khách hàng:** Hành vi mua sắm, Phân khúc khách hàng, Tỷ lệ khách hàng quay lại.
- **Phân tích đơn hàng và doanh thu :** Doanh thu theo thời gian, Giá trị đơn hàng trung bình, Doanh thu theo phân khúc sản phẩm và khu vực.
- **Phân tích sản phẩm:** Sản phẩm bán chạy, Đánh giá và phản hồi sản phẩm, Tỷ lệ hoàn trả sản phẩm.
- **Phân tích giao hàng:** Thời gian giao hàng trung bình, Hiệu suất đối tác vận chuyển Tỷ lệ trễ hạn giao hàng.

Chủ điểm	Chỉ số	Khía cạnh
Khách hàng	• Số lượng khách hàng • Giá trị khách hàng	• Thời gian • Khu vực • Phân khúc khách hàng • Địa điểm
Đơn hàng	• Doanh thu • Số lượng đơn hàng • Tỷ lệ hủy đơn	• Thời gian • Đại điểm • Ngành hàng • Phân khúc khách hàng • Hình thức thanh toán • Trạng thái đơn hàng
Sản phẩm	• Số lượng bán • Điểm đánh giá trung bình • Tỷ lệ hoàn trả	• Ngành hàng • Nhà cung cấp • Kích thước sản phẩm
Giao hàng	• Thời gian giao hàng • Tỷ lệ giao hàng thành công • Chi phí vận chuyển	• Địa điểm • Kích thước sản phẩm • Ngành hàng • Trạng thái giao hàng • Hình thức thanh toán

Để tăng tính trực quan hóa, nhóm xin trình bày mindmap biểu diễn các chủ điểm phân tích như hình dưới:



Hình 3.7: Mind map nhu cầu phân tích

3.4.3 Các yêu cầu phân tích Dashboard

Với mỗi một chủ điểm, chúng em sẽ liệt kê những yêu cầu phân tích cần đưa ra.

Chủ điểm khách hàng

- Có bao nhiêu khách hàng theo từng thời gian (theo tháng, quý, năm)?
- Khu vực nào có số lượng khách hàng cao nhất?
- Khách hàng phân bố theo từng phân khúc như thế nào?
- Giá trị trung bình của một khách hàng trong các khu vực có xu hướng gì không?
- Giá trị trung bình của khách hàng theo phân khúc thay đổi như thế nào theo thời gian?

Chủ điểm đơn hàng

- Doanh thu theo từng ngành hàng là bao nhiêu?
- Doanh thu thay đổi theo thời gian (ngày, tháng, quý, năm) như thế nào?
- Khu vực nào đóng góp doanh thu cao nhất?

- Tỷ trọng đơn hàng theo từng hình thức thanh toán như thế nào?
- Số lượng đơn hàng theo từng ngành hàng và phân khúc khách hàng có sự phụ thuộc nào không?
- Tỷ lệ hủy đơn hàng có liên quan gì đến khu vực?
- Ngành hàng nào có tỷ lệ hủy đơn cao nhất?

Chủ điểm sản phẩm

- Ngành hàng nào có số lượng sản phẩm bán cao nhất?
- Số lượng sản phẩm bán thay đổi như thế nào theo thời gian?
- Sản phẩm nào nhận được điểm đánh giá cao nhất/thấp nhất?
- Điểm đánh giá trung bình thay đổi như thế nào theo từng nhà cung cấp?
- Ngành hàng nào có tỷ lệ hoàn trả cao nhất?
- Kích thước sản phẩm (nhỏ, trung bình, lớn) có ảnh hưởng đến tỷ lệ hoàn trả không?

Chủ điểm giao hàng


- Thời gian giao hàng trung bình theo khu vực là bao nhiêu?
- Ngành hàng nào có thời gian giao hàng lâu nhất?
- Khu vực nào có tỷ lệ giao hàng thành công cao nhất?
- Tỷ lệ giao hàng thành công theo từng trạng thái giao hàng là bao nhiêu?
- Chi phí vận chuyển trung bình có liên quan gì đến kích thước sản phẩm không?
- Chi phí vận chuyển thay đổi như thế nào theo thời gian và khu vực?

3.5 Khảo sát về hệ thống dữ liệu

3.5.1 Tổng quan về bộ dữ liệu

- Tên bộ dữ liệu: Brazilian E-Commerce Public Dataset by Olist
- Nguồn: Kaggle
- Kích thước: 126.19 MB
- 9 files, 52 columns
- Định dạng file: .csv

- Thời gian: 2016-2018
- Nội dung: Các đơn đặt hàng được thực hiện tại Cửa hàng Olist. Bộ dữ liệu có thông tin khoảng 100.000 đơn đặt hàng từ năm 2016 đến năm 2018 được thực hiện tại nhiều thị trường ở Brazil.
- Tần suất cập nhật dữ liệu: Thông tin tài khoản khách hàng theo thời gian thực. Thông tin giao dịch ngay sau khi giao dịch được thực hiện



Hình 3.8: Tần suất cập nhật dữ liệu

Tốc độ cập nhật dữ liệu cho thấy mức độ tăng trưởng cao, cần có công cụ phân tích và quản lý một cách thích hợp.

3.5.2 Giới thiệu chi tiết bộ dữ liệu

Bộ dữ liệu gồm 9 bảng:

1. olist_orders_dataset

- **Kích thước:** 17.65 MB, Khoảng 100,000 dòng, 8 thuộc tính
- **Nội dung:** Chứa thông tin về đơn hàng, bao gồm thời gian đặt hàng, trạng thái, và mã khách hàng.
- **Các thuộc tính:**
 - **order_id:** ID của đơn hàng (Duy nhất cho mỗi đơn hàng).

- **customer_id**: ID của khách hàng (kết nối với bảng `olist_customers_dataset`).
- **order_status**: Trạng thái đơn hàng (đã giao hàng, đang xử lý, hủy bỏ, v.v.).
- **order_purchase_timestamp**: Thời gian khách hàng thực hiện giao dịch mua.
- **order_approved_at**: Thời gian đơn hàng được xác nhận thanh toán.
- **order_delivered_carrier_date**: Thời gian đơn hàng được giao cho hãng vận chuyển.
- **order_delivered_customer_date**: Thời gian đơn hàng được giao đến khách hàng.
- **order_estimated_delivery_date**: Ngày dự kiến giao hàng.

2. `olist_order_items_dataset`

- **Kích thước**: Khoảng 15.44 MB, 110,000 dòng, 7 thuộc tính
- **Nội dung**: Chứa thông tin về các sản phẩm trong mỗi đơn hàng, bao gồm số lượng, giá và mã sản phẩm.
- **Các thuộc tính**:
 - **order_id**: ID của đơn hàng (kết nối với bảng `olist_orders_dataset`).
 - **order_item_id**: ID của mục hàng trong đơn hàng.
 - **product_id**: ID của sản phẩm (kết nối với bảng `olist_products_dataset`).
 - **seller_id**: ID của nhà bán hàng (kết nối với bảng `olist_sellers_dataset`).
 - **shipping_limit_date**: Thời hạn cuối để vận chuyển đơn hàng.
 - **price**: Giá của sản phẩm trong đơn hàng.
 - **freight_value**: Phí vận chuyển của sản phẩm.

3. `olist_order_payments_dataset`

- **Kích thước**: Khoảng 5.78 MB 100,000 dòng, 4 thuộc tính
- **Nội dung**: Chứa thông tin về các giao dịch thanh toán, bao gồm số lượng thanh toán và loại hình thanh toán.
- **Các thuộc tính**:
 - **order_id**: ID của đơn hàng (kết nối với bảng `olist_orders_dataset`).
 - **payment_sequential**: Thứ tự của giao dịch thanh toán cho đơn hàng.
 - **payment_type**: Loại thanh toán (thẻ tín dụng, phiếu thưởng, chuyển khoản ngân hàng, v.v.).
 - **payment_installments**: Số lần trả góp cho giao dịch.
 - **payment_value**: Số tiền của giao dịch thanh toán.

4. olist_order_reviews_dataset

- **Kích thước:** Khoảng 14.45 MB, 100,000 dòng, 7 thuộc tính
- **Nội dung:** Chứa thông tin về đánh giá của khách hàng đối với các đơn hàng.
- **Các thuộc tính:**
 - **review_id:** ID của đánh giá.
 - **order_id:** ID của đơn hàng (kết nối với bảng olist_orders_dataset).
 - **review_score:** Điểm đánh giá (từ 1 đến 5).
 - **review_comment_title:** Tiêu đề của đánh giá.
 - **review_comment_message:** Nội dung của đánh giá.
 - **review_creation_date:** Ngày đánh giá được tạo.
 - **review_answer_timestamp:** Ngày đánh giá được phản hồi.

5. olist_products_dataset

- **Kích thước:** Khoảng 2.38 MB, 32,000 dòng, 9 thuộc tính
- **Nội dung:** Chứa thông tin về sản phẩm, bao gồm tên danh mục, chiều cao, chiều rộng, và trọng lượng của sản phẩm.
- **Các thuộc tính:**
 - **product_id:** ID của sản phẩm.
 - **product_category_name:** Tên danh mục của sản phẩm.
 - **product_name_lenght:** Độ dài tên của sản phẩm.
 - **product_description_lenght:** Độ dài phần mô tả sản phẩm.
 - **product_photos_qty:** Số lượng ảnh của sản phẩm.
 - **product_weight_g:** Trọng lượng của sản phẩm (gram).
 - **product_length_cm:** Chiều dài của sản phẩm (cm).
 - **product_height_cm:** Chiều cao của sản phẩm (cm).
 - **product_width_cm:** Chiều rộng của sản phẩm (cm).

6. olist_customers_dataset

- **Kích thước:** Khoảng 9.03MB, 100,000 dòng, 5 thuộc tính
- **Nội dung:** Chứa thông tin về khách hàng, bao gồm mã vùng và ID khách hàng.
- **Các thuộc tính:**
 - **customer_id:** ID của khách hàng.

- **customer_unique_id**: ID duy nhất của khách hàng (không trùng lặp với khách hàng khác).
- **customer_zip_code_prefix**: Mã vùng của khách hàng.
- **customer_city**: Thành phố của khách hàng.
- **customer_state**: Bang của khách hàng.

7. olist_sellers_dataset

- **Kích thước**: Khoảng 174.7 KB, 3,000 dòng, 4 thuộc tính
- **Nội dung**: Chứa thông tin về nhà bán hàng, bao gồm mã vùng và ID nhà bán hàng.
- **Các thuộc tính**:
 - **seller_id**: ID của nhà bán hàng.
 - **seller_zip_code_prefix**: Mã vùng của nhà bán hàng.
 - **seller_city**: Thành phố của nhà bán hàng.
 - **seller_state**: Bang của nhà bán hàng.

8. olist_geolocation_dataset

- **Kích thước**: Khoảng 61.27MB, 1,000,000 dòng, 5 thuộc tính
- **Nội dung**: Cung cấp thông tin địa lý cho mã vùng tại Brazil, bao gồm vĩ độ và kinh độ.
- **Các thuộc tính**:
 - **geolocation_zip_code_prefix**: Mã vùng địa lý.
 - **geolocation_lat**: Vĩ độ của mã vùng.
 - **geolocation_lng**: Kinh độ của mã vùng.
 - **geolocation_city**: Thành phố tương ứng với mã vùng.
 - **geolocation_state**: Bang tương ứng với mã vùng.

9. product_category_name_translation


- **Kích thước**: Khoảng 2.61kB, 71 dòng, 2 thuộc tính
- **Nội dung**: Thông tin phiên dịch danh mục sản phẩm
- **Các thuộc tính**:
 - **product_catagory_name**: Tên danh mục sản phẩm tiếng Tây Ban Nha
 - **product_catagory_name_english**: Tên danh mục sản phẩm Tiếng Anh



Hình 3.9: Mind map dữ liệu

3.5.3 Data taxonomy


Phân loại dữ liệu (Data Taxonomy) là một hệ thống phân cấp được thiết kế để sắp xếp và tổ chức dữ liệu một cách logic và hiệu quả. Data Taxonomy giống như một hệ thống thư viện, giúp thực hiện tìm kiếm và truy cập thông tin cần thiết.



Hình 3.10: Data taxonomy của hệ thống

3.6 ERD hệ thống OLTP, Data flow


3.6.1 ERD hệ thống OLTP



Hình 3.11: Mô hình thực thể liên kết ERD OLTP


3.6.2 Các trường quan trọng để xây dựng Data Model đa chiều OLAP

Trước hết chúng em thực hiện khoanh các trường sẽ được sử dụng để xây dựng dim, fact:




Hình 3.12: Khoanh các dim, fact

Để chi tiết hơn, nhóm bọn em đã nổi các trường được sử dụng để tổng hợp nên các bảng dim, fact:



Hình 3.13: Nối các trường để tổng hợp bảng DIM



Hình 3.14: Nối các trường để tổng hợp bảng FACT

Phân tích và thiết kế hệ thống

4.1 Khám phá dữ liệu

Tổng quan bộ dữ liệu



Hình 4.1: Tổng quan bộ dữ liệu

Bộ dữ liệu của nền tảng thương mại điện tử Olist cung cấp một cái nhìn toàn cảnh về quy mô và mức độ hoạt động rộng rãi của nền tảng này tại Brazil. Với sự hiện diện ở 8010 thành phố thuộc 27 bang (bao gồm tất cả các khu vực địa lý chính của Brazil), Olist dường như đã phủ sóng toàn quốc, đem lại khả năng tiếp cận dịch vụ cho khách hàng ở khắp mọi nơi.

Lượng khách hàng đạt gần 96,1 nghìn, thể hiện cơ sở người dùng đáng kể mà Olist đã xây dựng được. Sự tích cực của người dùng được phản ánh qua gần 98,4 nghìn lượt đánh giá, cho thấy khách hàng có xu hướng để lại phản hồi sau khi mua hàng. Điểm đánh giá trung bình đạt 4,09, chứng minh sự hài lòng khá cao của khách hàng về sản phẩm và dịch vụ của Olist, mặc dù

vẫn còn dư địa để cải thiện thêm.

Tổng doanh thu của Olist đạt khoảng 16,01 triệu đơn vị tiền tệ (có thể là R\$ - Real Brazil), thể hiện sức mua mạnh mẽ và hiệu quả trong hoạt động kinh doanh. Với gần 33 nghìn sản phẩm thuộc 71 danh mục khác nhau, nền tảng này có sự đa dạng hàng hóa rất lớn, đáp ứng nhu cầu phong phú của người tiêu dùng. Bên cạnh đó, Olist cung cấp 5 phương thức thanh toán, tạo sự linh hoạt và thuận tiện trong giao dịch, giúp tăng cường trải nghiệm mua sắm của khách hàng.


Bảng đặc trưng của một số trường dữ liệu

	delivery_time	freight_value	payment_value	price	review_score
count	96476	112650	103886	112650	99224
mean	12.09408558	19.99031993	154.1003804	120.653739	4.086420624
std	9.551746107	15.80640541	217.4940639	183.6339281	1.347579131
min	0	0	0	0.85	1
25%	6	13.08	56.79	39.9	4
50%	10	16.26	100	74.99	5
75%	15	21.15	171.8375	134.9	5
max	209	409.68	13664.08	6735	5

Hình 4.2: Bảng đặc trưng của một số trường dữ liệu

Ma trận tương quan


Sử dụng ngôn ngữ **R** để trực quan hóa ma trận tương quan:




Hình 4.3: Ma trận tương quan

Nhìn chung, các biến có mối tương quan rất thấp với nhau, thể hiện qua các hệ số gần 0, ngoại trừ "freight_value" và "price" có mức tương quan trung bình với hệ số 0.41. Điều này gợi ý rằng giá trị cước vận chuyển và giá sản phẩm có mối quan hệ nhất định, trong khi các biến còn lại gần như không ảnh hưởng đến nhau.

Số lượng đơn hàng theo thời gian và xu hướng thanh toán theo thời gian



Hình 4.4: Số lượng đơn hàng theo thời gian




Hình 4.5: Xu hướng thanh toán theo thời gian

Sàn TMDT Olist được thành lập vào cuối năm 2015 - đầu năm 2016, có lẽ đó là lí do vào khoảng thời gian bắt đầu ghi nhận dữ liệu ta thấy số lượng đơn hàng còn khá thấp. Có lẽ do đẩy mạnh truyền thông, quảng bá nên sang đến năm 2017 đã có sự tăng trưởng đột phá.

Đáng chú ý khi số lượng đơn hàng bán ra vào khoảng cuối tháng 11 năm 2017 đạt đỉnh, điều này có thể giải thích là do hiệu ứng của ngày Black Friday, khi sàn tung các voucher giảm giá sâu để thu hút người mua hàng.

Điều tương tự cũng được giải thích cho xu hướng thanh toán.

Số lượng người bán và người mua theo từng bang



Hình 4.6: Số lượng người bán và mua theo từng bang

Bang Sao Paulo có số lượng người bán và người mua cao nhất, vượt trội so với các bang khác. Số lượng người bán ở SP đạt hơn 1750 người, và số lượng người mua ở mức gần 40,000, cho thấy đây là thị trường lớn nhất của Olist. Các bang tiếp theo như RJ, MG và RS có số lượng người bán và người mua giảm đáng kể. Các khu vực khác có số lượng người bán và người mua khá thấp, đặc biệt ở các bang như RR, AP, và AC, cho thấy mức độ hoạt động thương mại điện tử ở các bang này còn hạn chế.


Doanh thu theo hình thức thanh toán

Biểu đồ thể hiện doanh thu theo các phương thức thanh toán trên Olist, trong đó thẻ tín dụng chiếm tỷ trọng lớn nhất với 12.5 triệu, tương đương 78% tổng doanh thu. Boleto đứng thứ hai, đóng góp 2.9 triệu và nâng tỷ lệ tích lũy lên 96%. Các phương thức khác như voucher và thẻ ghi nợ có mức sử dụng thấp, chiếm chưa đến 4% tổng doanh thu.

Như vậy, hai phương thức chính – thẻ tín dụng và boleto – chi phối gần như toàn bộ doanh thu. Điều này cho thấy Olist nên tập trung vào các phương thức này để tối ưu trải nghiệm khách hàng, do chúng đáp ứng phần lớn nhu cầu thanh toán.

Top 10 danh mục sản phẩm có doanh thu cao nhất

Biểu đồ thể hiện doanh thu của top 10 danh mục sản phẩm trên sàn thương mại điện tử Olist, trong đó "health_beauty" dẫn đầu với doanh thu 1,347,468.49 R\$, chiếm 14% doanh thu tích



Hình 4.7: Doanh thu theo hình thức thanh toán

lũy. Tiếp theo là các danh mục "watches_gifts" và "bed_bath_table," với doanh thu lần lượt là 1,259,634.58 R\$ và 1,228,795.46 R\$, nâng tỷ lệ tích lũy lên 27% và 40%. Qua biểu đồ, có thể thấy các danh mục sản phẩm chủ yếu liên quan đến sức khỏe, quà tặng, và đồ gia dụng có doanh thu cao và chiếm tỷ trọng lớn trong tổng doanh thu tích lũy.

Tương quan giữa cước phí vận chuyển với kích thước cũng như khối lượng sản phẩm


1. Tương quan giữa cước phí vận chuyển và khối lượng sản phẩm:

- Nhìn chung, cước phí vận chuyển có xu hướng tăng dần khi khối lượng sản phẩm tăng, nhưng mối quan hệ này không quá rõ ràng.
- Phần lớn các điểm tập trung ở mức cước phí vận chuyển dưới 100, cho thấy phần lớn sản phẩm có khối lượng không quá lớn và có mức phí vận chuyển thấp.
- Một số điểm nằm rải rác ở phía trên, cho thấy có một số sản phẩm có khối lượng lớn hơn nhưng không làm tăng cước phí vận chuyển một cách đáng kể, điều này có thể là do giới hạn cước phí hoặc các yếu tố khác ảnh hưởng đến chi phí.


2. Tương quan giữa cước phí vận chuyển và thể tích sản phẩm:

- Tương tự, phần lớn các điểm tập trung ở mức cước phí vận chuyển dưới 100. Điều này có thể là do đa số sản phẩm có thể tích nhỏ.
- Có một vài điểm có cước phí cao hơn ở thể tích sản phẩm lớn, tuy nhiên không có mối quan hệ tuyến tính rõ ràng. Một số sản phẩm có thể tích rất lớn nhưng cước phí vẫn không tăng quá cao, có thể là do các chính sách cước phí không chỉ phụ thuộc vào thể tích mà còn các yếu tố khác.

3. Kết luận:



Hình 4.8: Top 10 danh mục sản phẩm có doanh thu cao nhất




Hình 4.9: Tương quan giữa cước phí vận chuyển và khối lượng


- Cước phí vận chuyển có xu hướng tăng nhẹ khi khối lượng và thể tích sản phẩm tăng, nhưng không hoàn toàn tuyến tính hoặc rõ ràng. Điều này cho thấy cước phí không chỉ phụ thuộc vào kích thước hay khối lượng mà có thể còn bị ảnh hưởng bởi các yếu tố khác như loại hình vận chuyển, khoảng cách, hoặc chính sách cước phí cố định cho các mức khối lượng/thể tích nhất định.
- Có thể nghiên cứu thêm để xác định các yếu tố khác ảnh hưởng đến cước phí, hoặc sử dụng các mô hình hồi quy để kiểm tra mối quan hệ chính xác hơn giữa cước phí và các biến này.

Tương quan giữa ngày giao hàng dự kiến và thực tế

Các điểm dữ liệu tập trung gần đường chéo, cho thấy ngày giao hàng thực tế thường sát với ngày giao hàng dự kiến. Tuy nhiên, cũng có một số điểm nằm xa đường chéo, biểu hiện sự chậm



Hình 4.10: Tương quan giữa cước phí vận chuyển và thể tích



Hình 4.11: Tương quan giữa ngày giao hàng dự kiến và thực tế

trễ hoặc giao hàng sớm hơn dự kiến. Xu hướng chung này cho thấy hệ thống dự đoán ngày giao hàng khá chính xác, mặc dù vẫn có một số ngoại lệ.

Phân tích khuynh hướng Trend - Mùa - Dư


1. Trend (Xu hướng)

- **Xu hướng dài hạn**


- Biểu đồ khuynh hướng cho thấy số lượng đơn hàng tăng đều từ năm 2016 đến đầu năm 2018, sau đó có dấu hiệu giảm nhẹ.

- **Ý nghĩa**

- Giai đoạn tăng trưởng đều đặn cho thấy doanh nghiệp đã mở rộng thị trường thành công hoặc có chiến lược thu hút khách hàng hiệu quả.



Hình 4.12: Trend



Hình 4.13: Seasonality

- Sự suy giảm từ năm 2018 có thể là dấu hiệu cần cải thiện hoạt động kinh doanh, ví dụ như tối ưu hóa quảng bá hoặc tăng cường trải nghiệm người dùng.


2. Seasonality (Tính mùa vụ)

• Quan sát mùa vụ

- Chu kỳ tăng mạnh rõ rệt vào cuối năm, đặc biệt là tháng 11–12. Đây có thể trùng với mùa lễ hội hoặc các sự kiện bán hàng lớn.
- Mùa thấp điểm thường rơi vào các tháng giữa năm, có thể do giảm chi tiêu sau mùa lễ hội.

• Ý nghĩa

- Doanh nghiệp nên tập trung nguồn lực vào giai đoạn cao điểm (cuối năm) để tăng doanh số.
- Xây dựng các chiến lược khuyến mãi nhằm kích cầu vào giai đoạn thấp điểm giữa năm.



Hình 4.14: Residuals

3. Residuals (Phần dư)

- **Phân tích phần dư**

- Phần dư dao động quanh mức 0, ngoại trừ một số tháng có giá trị lớn (có thể do yếu tố bất thường).
- Biểu đồ phần dư tăng mạnh từ năm 2018, cho thấy mô hình chưa giải thích được hết các yếu tố tác động.

- **Ý nghĩa**

- Các yếu tố bất thường có thể liên quan đến các chiến dịch marketing, thay đổi chính sách hoặc sự kiện đặc biệt không lặp lại.

4. Hành động đề xuất

- **Tối ưu mùa cao điểm**

- Đẩy mạnh marketing vào cuối năm.
- Cung cấp nhiều ưu đãi hoặc giảm giá lớn trong các tháng lễ hội.

- **Kích cầu mùa thấp điểm**

- Tạo các chiến dịch khuyến mãi để tăng nhu cầu giữa năm.


- **Phân tích sâu phần dư**

- Kiểm tra các sự kiện bất thường hoặc yếu tố nội bộ ảnh hưởng đến số lượng đơn hàng.

- **Tăng cường dự báo**

- Xây dựng các mô hình dự báo chuỗi thời gian chính xác hơn để dự đoán nhu cầu.


4.2 Kiến trúc datawarehouse



Hình 4.15: Kiến trúc Data Warehouse

4.3 Tiền xử lí dữ liệu


ETL là viết tắt của Extract, Transform, Load (Trích xuất, Chuyển đổi, Tải dữ liệu). Đây là quá trình quan trọng trong việc chuẩn bị và xử lý dữ liệu trong các hệ thống phân tích dữ liệu và Data Warehouse.



Hình 4.16: Tổng quan hoạt động ETL

ETL giúp tổ chức thu thập, chuẩn hóa và sắp xếp dữ liệu từ nhiều nguồn khác nhau để tạo ra một nguồn dữ liệu duy nhất và phù hợp cho phân tích và báo cáo. Đây là quá trình quan trọng trong việc xây dựng hệ thống phân tích dữ liệu hiệu quả và đáng tin cậy.

4.3.1 Data pipeline




Hình 4.17: Data pipeline.

Quy trình tổng thể:

- **Extract:** Trích xuất dữ liệu từ nguồn *Brazilian E-Commerce Public Dataset by Olist* trên Kaggle.
- **Transform:** Gồm các hoạt động được thực hiện trên **Power Query**, **Python** và **MySQL** như trong hình trên.
- **Load:** Tải dữ liệu và cơ sở dữ liệu trong **MySQL**.

4.3.2 Các hoạt động ETL dữ liệu



Hình 4.18: Tóm tắt các hoạt động ETL.

Bảng customers

Xoá cột không cần thiết:

```
1 column_to_drop = 'customer_city'
2 dataCustomers.drop(column_to_drop, axis=1, inplace=True)
```

Kết quả:

Data columns (total 5 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	customer_id	99441	non-null	object
1	customer_unique_id	99441	non-null	object
2	customer_zip_code_prefix	99441	non-null	int64
3	customer_city	99441	non-null	object
4	customer_state	99441	non-null	object

Hình 4.19: Before

Data columns (total 4 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	customer_id	99441	non-null	object
1	customer_unique_id	99441	non-null	object
2	customer_zip_code_prefix	99441	non-null	int64
3	customer_state	99441	non-null	object

Hình 4.20: After

Sử dụng mô hình RFM để phân khúc khách hàng:

```

1 from sklearn.cluster import KMeans
2 from sklearn.preprocessing import StandardScaler
3
4 # Step 1: Load Data
5 orders = dataOrders
6 order_items = dataOrderItem
7 customers = dataCustomers
8
9 # Step 2: Prepare RFM Data
10 orders['order_purchase_timestamp'] = pd.to_datetime(orders['
    order_purchase_timestamp'])
11 current_date = orders['order_purchase_timestamp'].max()
12 recency = orders.groupby('customer_id').order_purchase_timestamp.max().
    reset_index()
13 recency['Recency'] = (current_date - recency['order_purchase_timestamp'
    ]).dt.days
14 recency = recency[['customer_id', 'Recency']]
15
16 frequency = orders.groupby('customer_id').order_id.count().reset_index()
17 frequency.columns = ['customer_id', 'Frequency']
18
19 monetary = order_items.merge(orders[['order_id', 'customer_id']], on='
    order_id')
20 monetary = monetary.groupby('customer_id').price.sum().reset_index()
21 monetary.columns = ['customer_id', 'Monetary']
22
23 rfm = recency.merge(frequency, on='customer_id').merge(monetary, on='
    customer_id')
24

```

```

25 # Step 3: Standardize Data
26 scaler = StandardScaler()
27 rfm_scaled = scaler.fit_transform(rfm[['Recency', 'Frequency', 'Monetary'
28     ']])
29
30 # Step 4: Apply KMeans Clustering
31 kmeans = KMeans(n_clusters=4, random_state=0, n_init=10)
32 rfm['Cluster'] = kmeans.fit_predict(rfm_scaled)
33
34 # Step 5: Analyze Each Cluster's Average RFM Values
35 cluster_summary = rfm.groupby('Cluster').agg({
36     'Recency': 'mean',
37     'Frequency': 'mean',
38     'Monetary': 'mean'
39 }).reset_index()
40
41 # Step 6: Define Labels for Each Cluster Based on Characteristics
42 cluster_labels = {}
43 for index, row in cluster_summary.iterrows():
44     if row['Recency'] < 60 and row['Frequency'] > 5 and row['Monetary']
45         > 500:
46         cluster_labels[row['Cluster']] = 'Champions'
47     elif row['Recency'] < 60 and row['Frequency'] > 2:
48         cluster_labels[row['Cluster']] = 'Potential Loyalists'
49     elif row['Recency'] >= 60 and row['Frequency'] > 5:
50         cluster_labels[row['Cluster']] = 'Loyal Customers'
51     elif row['Recency'] >= 60 and row['Monetary'] > 300:
52         cluster_labels[row['Cluster']] = 'At Risk'
53     else:
54         cluster_labels[row['Cluster']] = 'Hibernating'
55
56 # Step 7: Map Cluster Labels to Each Customer
57 rfm['Segment'] = rfm['Cluster'].map(cluster_labels)
58
59 # Step 8: Merge Segments with Customer Data and Save to CSV
60 customers_segmented = customers.merge(rfm[['customer_id', 'Segment']],
61     on='customer_id', how='left')

```

Kết quả:

customer_id	customer_unique_id	customer_zip_code_prefix	customer_state
a1fbc88172c00ba8bc7	861eff4711a542e4b93843c6dd7febb0	14409	SP
d6b2def6b18a428ac77	290c77bc529b7ac935b93aa66c333dc3	9790	SP
6ebd08712fdd0374a03	060e732b5b29e8181a18229c7b0b2b5e	1151	SP
09e529d4dc6358b12c3	259dac757896d24d7702b9acbbff3f3c	8775	SP
ec8364f7c12e35b23ad	345ecd01c38d18a9036ed96c73b8d066	13056	SP

Hình 4.21: Before

customer_id	customer_unique_id	customer_zip_code_prefix	customer_state	Segment
a1fbc88172c00ba8bc7	861eff4711a542e4b93843c6dd7febb0	14409	SP	Hibernating
d6b2def6b18a428ac77	290c77bc529b7ac935b93aa66c333dc3	9790	SP	Hibernating
6ebd08712fdd0374a03	060e732b5b29e8181a18229c7b0b2b5e	1151	SP	Hibernating
09e529d4dc6358b12c3	259dac757896d24d7702b9acbbff3f3c	8775	SP	Hibernating
ec8364f7c12e35b23ad	345ecd01c38d18a9036ed96c73b8d066	13056	SP	Hibernating

Hình 4.22: After

Bảng geolocations

Xóa cột không cần thiết:

```
1 column_to_drop = 'geolocation_city'
2 dataGeo.drop(column_to_drop, axis=1, inplace=True)
```

Kết quả:

Data columns (total 5 columns):			
#	Column	Non-Null Count	Dtype
0	geolocation_zip_code_prefix	1000163 non-null	int64
1	geolocation_lat	1000163 non-null	float64
2	geolocation_lng	1000163 non-null	float64
3	geolocation_city	1000163 non-null	object
4	geolocation_state	1000163 non-null	object

Hình 4.23: Before

Data columns (total 4 columns):			
#	Column	Non-Null Count	Dtype
0	geolocation_zip_code_prefix	1000163 non-null	int64
1	geolocation_lat	1000163 non-null	float64
2	geolocation_lng	1000163 non-null	float64
3	geolocation_state	1000163 non-null	object

Hình 4.24: After

Lọc trùng:

```
1 dataGeo = dataGeo.drop_duplicates(subset=['geolocation_zip_code_prefix',
2                                     'geolocation_state'])
```

Kết quả:

Data columns (total 4 columns):			
#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	geolocation_zip_code_prefix	1000163 non-null	int64
1	geolocation_lat	1000163 non-null	float64
2	geolocation_lng	1000163 non-null	float64
3	geolocation_state	1000163 non-null	object

Hình 4.25: Before

Data columns (total 4 columns):			
#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	geolocation_zip_code_prefix	19023 non-null	int64
1	geolocation_lat	19023 non-null	float64
2	geolocation_lng	19023 non-null	float64
3	geolocation_state	19023 non-null	object

Hình 4.26: After

Dùng chatgpt để giúp phân cụm region:

```

1 def phanloai(x):
2     if x in ['AC', 'AP', 'AM', 'PA', 'RO', 'RR', 'TO']:
3         return 'North'
4     elif x in ['AL', 'BA', 'CE', 'MA', 'PB', 'PE', 'PI', 'RN', 'SE']:
5         return 'Northeast'
6     elif x in ['DF', 'GO', 'MT', 'MS']:
7         return 'Midwest'
8     elif x in ['ES', 'MG', 'RJ', 'SP']:
9         return 'Southeast'
10    elif x in ['PR', 'RS', 'SC']:
11        return 'South'
12
13 dataGeo['region'] = dataGeo.geolocation_state.apply(phanloai)

```

Kết quả:

Data columns (total 4 columns):			
#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	geolocation_zip_code_prefix	19023 non-null	int64
1	geolocation_lat	19023 non-null	float64
2	geolocation_lng	19023 non-null	float64
3	geolocation_state	19023 non-null	object

Hình 4.27: Before

Data columns (total 5 columns):				
#	Column	Non-Null Count		Dtype
0	geolocation_zip_code_prefix	19023	non-null	int64
1	geolocation_lat	19023	non-null	float64
2	geolocation_lng	19023	non-null	float64
3	geolocation_state	19023	non-null	object
4	region	19023	non-null	object

Hình 4.28: After

Bảng products

Loại bỏ trường không cần thiết, xóa null, xóa trùng:

product_id	product_category_name	product_name_length	product_description_length	product_photos_qty	product_weight_g
1e9e8ef04dbcf4541ed26657ea517e5	perfumaria	40	287	1	
3aa071139cb16b67ca9e5dea641aaa...	artes	44	276	1	
96bd76ec8810374ed1b65e2919757...	esporte_lazer	46	250	1	
cef67bce19066a932b7673e239eb23d	bebes	27	261	1	
9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	37	402	4	
41d3672d4792049fa1779bb35283e...	instrumentos_musicais	60	745	1	
732bd381ad09e530fe0a5f57d81be...	cool_stuff	56	1272	4	
2548af3e6e77a690cf3eb6368e9ab61e	moveis_decoracao	56	184	2	
37cc742be07708b53a98702e77a21a...	eletrodomesticos	57	163	1	
8c92109888e8cdf9d66dc7e4630255...	brinquedos	36	1156	1	
14aa47b7fe5c25522b47b4b29c98dc...	cama_mesa_banho	54	630	1	
03b63c5fc16691530586ae020c3455...	bebes	49	728	4	
cf55509ea8edaac1d28fdb16e48fc22	instrumentos_musicais	43	1827	3	
7bb6f29c2be57716194f96496660c7c2	moveis_decoracao	51	2083	2	
eb31436580a610f202c859463d8c74...	construcao_ferramentas_seguranca	59	1602	4	

Hình 4.29: Before

product_id	product_category_name	product_weight_g	product_length_cm	product_height_cm	product_width_cm
1e9e8ef04dbcf4541ed26657ea517e5	perfumaria	225	16	10	14
3aa071139cb16b67ca9e5dea641aaa...	artes	1000	30	18	20
96bd76ec8810374ed1b65e2919757...	esporte_lazer	154	18	9	15
cef67bce19066a932b7673e239eb23d	bebes	371	26	4	26
9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	625	20	17	13
41d3672d4792049fa1779bb35283e...	instrumentos_musicais	200	38	5	11
732bd381ad09e530fe0a5f57d81be...	cool_stuff	18350	70	24	44
2548af3e6e77a690cf3eb6368e9ab61e	moveis_decoracao	900	40	8	40
37cc742be07708b53a98702e77a21a...	eletrodomesticos	400	27	13	17
8c92109888e8cdf9d66dc7e4630255...	brinquedos	600	17	10	12
14aa47b7fe5c25522b47b4b29c98dc...	cama_mesa_banho	1100	16	10	16
03b63c5fc16691530586ae020c3455...	bebes	7150	50	19	45
cf55509ea8edaac1d28fdb16e48fc22	instrumentos_musicais	250	17	7	17
7bb6f29c2be57716194f96496660c7c2	moveis_decoracao	600	68	11	13
eb31436580a610f202c859463d8c74...	construcao_ferramentas_seguranca	200	17	7	17

Hình 4.30: After

Tính cột mới volume = $product_length_cm * product_height_cm * product_width_cm$.
Sau đó xóa các cột $product_length_cm, product_height_cm, product_width_cm$.

A ^B _C product_id	A ^B _C product_category_name	I ² ₃ product_weight_g	I ² ₃ product_length_cm	I ² ₃ product_height_cm	I ² ₃ product_width_cm
1e9e8ef04dbcf4541ed26657ea517e5	perfumaria	225	16	10	14
3aa071139cb16b67ca9e5dea641aaa...	artes	1000	30	18	20
96bd76ec8810374ed1b65e2919757...	esporte_lazer	154	18	9	15
cef67bcfe19066a932b7673e239eb23d	bebes	371	26	4	26
9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	625	20	17	13
41d3672d4792049fa1779bb35283e...	instrumentos_musicais	200	38	5	11
732bd381ad09e530fe0a5f457d81be...	cool_stuff	18350	70	24	44
2548af3e6e77a690cf3eb6368e9ab61e	moveis_decoracao	900	40	8	40
37cc742be07708b53a98702e77a21a...	eletrodomesticos	400	27	13	17
8c9210988e8cdf9d66dc7e4630255...	brinquedos	600	17	10	12
14aa47b7fe5c25522b47b4b29c98dc...	cama_mesa_banho	1100	16	10	16
03b63c5fc16691530586ae020c3455...	bebes	7150	50	19	45
cf55509ea8edaac1d28db16e48fc22	instrumentos_musicais	250	17	7	17
7bb6f29c2be57716194f9649660c7c2	moveis_decoracao	600	68	11	13
eb31436580a610f202c859463d8c74...	construcao_ferramentas_seguranca	200	17	7	17

Hình 4.31: Before

A ^B _C product_id	A ^B _C product_category_name	I ² ₃ product_weight_g	ABC ₁₂₃ volume
1e9e8ef04dbcf4541ed26657ea517e5	perfumaria	225	2240
3aa071139cb16b67ca9e5dea641aaa...	artes	1000	10800
96bd76ec8810374ed1b65e2919757...	esporte_lazer	154	2430
cef67bcfe19066a932b7673e239eb23d	bebes	371	2704
9dc1a7de274444849c219cff195d0b71	utilidades_domesticas	625	4420
41d3672d4792049fa1779bb35283e...	instrumentos_musicais	200	2090
732bd381ad09e530fe0a5f457d81be...	cool_stuff	18350	73920
2548af3e6e77a690cf3eb6368e9ab61e	moveis_decoracao	900	12800
37cc742be07708b53a98702e77a21a...	eletrodomesticos	400	5967
8c9210988e8cdf9d66dc7e4630255...	brinquedos	600	2040
14aa47b7fe5c25522b47b4b29c98dc...	cama_mesa_banho	1100	2560
03b63c5fc16691530586ae020c3455...	bebes	7150	42750

Hình 4.32: After

Thêm cột `review_score`:

```

1 # Merge dataPro and dataOrderItem based on 'product_id'
2 merged_df = pd.merge(dataPro, dataOrderItem, on='product_id')
3
4 # Merge dataOrderItem and dataReview (selecting 'order_id' and '
  review_score') based on 'order_id'
5 merged_order_df = pd.merge(dataOrderItem, dataReview[['order_id', '
  review_score']],
6                             on='order_id', how='left')
7
8 # Merge merged_order_df and dataPro based on 'product_id'
9 final_merged_df = pd.merge(merged_order_df, dataPro, on='product_id',
10                             how='left')
11
12 # Calculate average review score per product
13 average_review_score_per_product = final_merged_df.groupby('product_id')
14     ['review_score'].mean()
15
16 # Merge the average review scores back into dataPro
17 dataPro = pd.merge(dataPro, average_review_score_per_product, on='
  product_id', how='left')

```

Kết quả:

Data columns (total 4 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	product_id	32341	non-null	object
1	product_category_name	32341	non-null	object
2	product_weight_g	32340	non-null	float64
3	volume	32340	non-null	float64

Hình 4.33: Before

Data columns (total 5 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	product_id	32341	non-null	object
1	product_category_name	32341	non-null	object
2	product_weight_g	32340	non-null	float64
3	volume	32340	non-null	float64
4	review_score	32184	non-null	float64

Hình 4.34: After

Thêm cột *product_quality*:

```

1 def phanloai(score):
2     if score >= 4:
3         return 'Good'
4     elif score >= 3:
5         return 'Average'
6     elif score.isna():
7         return 'No Review'
8     else:
9         return 'Poor'
10
11 dataPro['product_quality'] = dataPro['review_score'].apply(phanloai)

```

Kết quả:

Data columns (total 5 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	product_id	32341	non-null	object
1	product_category_name	32341	non-null	object
2	product_weight_g	32340	non-null	float64
3	volume	32340	non-null	float64
4	review_score	32184	non-null	float64

Hình 4.35: Before

Data columns (total 6 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	product_id	32341	non-null	object
1	product_category_name	32341	non-null	object
2	product_weight_g	32340	non-null	float64
3	volume	32340	non-null	float64
4	review_score	32184	non-null	float64
5	product_quality	32341	non-null	object

Hình 4.36: After

Bảng reviews

Xóa cột không cần thiết:

```

1 column_to_drop = ['review_comment_title',
2                   'review_comment_message',
3                   'review_creation_date',
4                   'review_answer_timestamp']
5
6 dataReview.drop(column_to_drop, axis=1, inplace=True)

```

Kết quả:

Data columns (total 7 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	review_id	99224	non-null	object
1	order_id	99224	non-null	object
2	review_score	99224	non-null	int64
3	review_comment_title	11568	non-null	object
4	review_comment_message	40977	non-null	object
5	review_creation_date	99224	non-null	object
6	review_answer_timestamp	99224	non-null	object

Hình 4.37: Before

Data columns (total 3 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----	-----	-----
0	review_id	99224	non-null	object
1	order_id	99224	non-null	object
2	review score	99224	non-null	int64

Hình 4.38: After

Bảng payments

Xóa cột không cần thiết:

```

1 column_to_drop = ['payment_sequential']
2 dataPayment.drop(column_to_drop, axis=1, inplace=True)

```

Kết quả:

Data columns (total 5 columns):			
#	Column	Non-Null Count	Dtype
0	order_id	103886 non-null	object
1	payment_sequential	103886 non-null	int64
2	payment_type	103886 non-null	object
3	payment_installments	103886 non-null	int64
4	payment_value	103886 non-null	float64

Hình 4.39: Before

Data columns (total 4 columns):			
#	Column	Non-Null Count	Dtype
0	order_id	103886 non-null	object
1	payment_type	103886 non-null	object
2	payment_installments	103886 non-null	int64
3	payment_value	103886 non-null	float64

Hình 4.40: After

Thêm cột xác định *payment_method*:

```

1 def std(x):
2     if x == 'voucher':
3         return 0
4     else:
5         return 1
6
7 dataPayment['payment_count_sum'] = dataPayment.payment_type.apply(std)
8
9 def method(x):
10     if x > 1:
11         return 1
12     else:
13         return 0
14
15 dataPayment['payment_method'] = dataPayment.payment_count_sum.apply(
    method)

```

Data columns (total 4 columns):			
#	Column	Non-Null Count	Dtype

0	order_id	103886 non-null	object
1	payment_type	103886 non-null	object
2	payment_installments	103886 non-null	int64
3	payment_value	103886 non-null	float64

Data columns (total 6 columns):			
#	Column	Non-Null Count	Dtype

0	order_id	103886 non-null	object
1	payment_type	103886 non-null	object
2	payment_installments	103886 non-null	int64
3	payment_value	103886 non-null	float64
4	payment_count_sum	103886 non-null	int64
5	payment_method	103886 non-null	int64

Hình 4.41: Before và After

Bảng sellers

```

1 column_to_drop = ['seller_city']
2 dataSeller.drop(column_to_drop, axis=1, inplace=True)

```

Data columns (total 4 columns):			
#	Column	Non-Null Count	Dtype

0	seller_id	3095 non-null	object
1	seller_zip_code_prefix	3095 non-null	int64
2	seller_city	3095 non-null	object
3	seller_state	3095 non-null	object

Data columns (total 3 columns):			
#	Column	Non-Null Count	Dtype

0	seller_id	3095 non-null	object
1	seller_zip_code_prefix	3095 non-null	int64
2	seller_state	3095 non-null	object

Hình 4.42: Before và After

Bảng orders

Bỏ null:

```

1 dataOrders = dataOrders.dropna()
2

```

Data columns (total 8 columns):			
#	Column	Non-Null Count	Dtype
0	order_id	99441 non-null	object
1	customer_id	99441 non-null	object
2	order_status	99441 non-null	object
3	order_purchase_timestamp	99441 non-null	object
4	order_approved_at	99281 non-null	object
5	order_delivered_carrier_date	97658 non-null	object
6	order_delivered_customer_date	96476 non-null	object
7	order_estimated_delivery_date	99441 non-null	object

Data columns (total 8 columns):			
#	Column	Non-Null Count	Dtype
0	order_id	96461 non-null	object
1	customer_id	96461 non-null	object
2	order_status	96461 non-null	object
3	order_purchase_timestamp	96461 non-null	object
4	order_approved_at	96461 non-null	object
5	order_delivered_carrier_date	96461 non-null	object
6	order_delivered_customer_date	96461 non-null	object
7	order_estimated_delivery_date	96461 non-null	object

Hình 4.43: Before và After

Chuyển định dạng ngày tháng, thêm cột *order_shipping_days*:

```

1
2 dataOrders['order_purchase_timestamp'] = pd.to_datetime(dataOrders['
   order_purchase_timestamp'])
3 dataOrders['order_approved_at'] = pd.to_datetime(dataOrders['
   order_approved_at'])
4 dataOrders['order_delivered_carrier_date'] = pd.to_datetime(dataOrders['
   order_delivered_carrier_date'])
5 dataOrders['order_delivered_customer_date'] = pd.to_datetime(dataOrders[
   'order_delivered_customer_date'])
6 dataOrders['order_estimated_delivery_date'] = pd.to_datetime(dataOrders[
   'order_estimated_delivery_date'])
7
8
9 dataOrders['order_shipping_days'] = (
10     dataOrders['order_delivered_customer_date'].dt.date -
11     dataOrders['order_delivered_carrier_date'].dt.date
12 )

```

Data columns (total 8 columns):			
#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	order_id	96461 non-null	object
1	customer_id	96461 non-null	object
2	order_status	96461 non-null	object
3	order_purchase_timestamp	96461 non-null	object
4	order_approved_at	96461 non-null	object
5	order_delivered_carrier_date	96461 non-null	object
6	order_delivered_customer_date	96461 non-null	object
7	order_estimated_delivery_date	96461 non-null	object

Data columns (total 9 columns):			
#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	order_id	96461 non-null	object
1	customer_id	96461 non-null	object
2	order_status	96461 non-null	object
3	order_purchase_timestamp	96461 non-null	datetime64[ns]
4	order_approved_at	96461 non-null	datetime64[ns]
5	order_delivered_carrier_date	96461 non-null	datetime64[ns]
6	order_delivered_customer_date	96461 non-null	datetime64[ns]
7	order_estimated_delivery_date	96461 non-null	datetime64[ns]
8	order_shipping_days	96461 non-null	object

Hình 4.44: Before và After

Chuyển định dạng của ordershippingdays và lọc bỏ dữ liệu không hợp lệ:

```

1 dataOrders['order_shipping_days'] = dataOrders['order_shipping_days'].
  apply(lambda x: x.days)
2
3 filtered_dataOrders = dataOrders[
4     ~(
5         (dataOrders['order_shipping_days'] < 0) & pd.Timedelta(days=0)
6         dataOrders['order_delivered_carrier_date'].notnull() &
7         dataOrders['order_delivered_customer_date'].notnull()
8     )
9 ]

```


Data columns (total 9 columns):			
#	Column	Non-Null Count	Dtype
0	order_id	96461 non-null	object
1	customer_id	96461 non-null	object
2	order_status	96461 non-null	object
3	order_purchase_timestamp	96461 non-null	datetime64[ns]
4	order_approved_at	96461 non-null	datetime64[ns]
5	order_delivered_carrier_date	96461 non-null	datetime64[ns]
6	order_delivered_customer_date	96461 non-null	datetime64[ns]
7	order_estimated_delivery_date	96461 non-null	datetime64[ns]
8	order_shipping_days	96461 non-null	object

Data columns (total 9 columns):			
#	Column	Non-Null Count	Dtype
0	order_id	96441 non-null	object
1	customer_id	96441 non-null	object
2	order_status	96441 non-null	object
3	order_purchase_timestamp	96441 non-null	datetime64[ns]
4	order_approved_at	96441 non-null	datetime64[ns]
5	order_delivered_carrier_date	96441 non-null	datetime64[ns]
6	order_delivered_customer_date	96441 non-null	datetime64[ns]
7	order_estimated_delivery_date	96441 non-null	datetime64[ns]
8	order_shipping_days	96441 non-null	int64

Hình 4.45: Before và After

Tạo cột *arrival_status* đánh giá tình trạng vận chuyển

```

1
2 dataOrders['arrival_status'] = dataOrders['order_delivered_customer_date'] - dataOrders['order_estimated_delivery_date']
3
4
5 dataOrders['arrival_status'] = dataOrders['arrival_status'].apply(
6     lambda x: 'Early' if x < pd.Timedelta(days=0) else ('OnTime' if x ==
7         pd.Timedelta(days=0) else 'Late')
8 )

```

Data columns (total 9 columns):			
#	Column	Non-Null Count	Dtype
----	-----	-----	-----
0	order_id	96441 non-null	object
1	customer_id	96441 non-null	object
2	order_status	96441 non-null	object
3	order_purchase_timestamp	96441 non-null	datetime64[ns]
4	order_approved_at	96441 non-null	datetime64[ns]
5	order_delivered_carrier_date	96441 non-null	datetime64[ns]
6	order_delivered_customer_date	96441 non-null	datetime64[ns]
7	order_estimated_delivery_date	96441 non-null	datetime64[ns]
8	order_shipping_days	96441 non-null	int64

Data columns (total 10 columns):			
#	Column	Non-Null Count	Dtype
----	-----	-----	-----
0	order_id	96461 non-null	object
1	customer_id	96461 non-null	object
2	order_status	96461 non-null	object
3	order_purchase_timestamp	96461 non-null	datetime64[ns]
4	order_approved_at	96461 non-null	datetime64[ns]
5	order_delivered_carrier_date	96461 non-null	datetime64[ns]
6	order_delivered_customer_date	96461 non-null	datetime64[ns]
7	order_estimated_delivery_date	96461 non-null	datetime64[ns]
8	order_shipping_days	96461 non-null	int64
9	arrival_status	96461 non-null	object

Hình 4.46: Before và After

Bảng translations

Dùng Chatgpt giúp phân cụm danh mục:

```

1
2 def phanloai(x):
3     if x in ['office_furniture', 'furniture_decor', '
4         furniture_living_room', 'bed_bath_table',
5         'kitchen_dining_laundry_garden_furniture', 'garden_tools',
6         'home_comfort',
7         'home_comfort_2', 'home_construction', 'furniture_bedroom',
8         'furniture_mattress_and_upholstery']:
9         return 'Furniture'
10    elif x in ['auto', 'computers_accessories', 'musical_instruments', '
11        consoles_games',
12        'watches_gifts', 'air_conditioning', 'telephony', '
13        electronics',
14        'fixed_telephony', 'tablets_printing_image', '
15        small_appliances_home_oven_and_coffee',
16        'small_appliances', 'audio', 'signaling_and_security']:
17        return 'Electronics'
18    elif x in ['fashion_female_clothing', 'fashion_male_clothing', '
19        fashion_bags_accessories',
20        'fashion_shoes', 'fashion_underwear_beach', '
21        fashion_childrens_clothes', 'baby',
22        'cool_stuff']:
23        return 'Fashion'
24    elif x in ['housewares', 'home_confort', 'home_appliances', '
25        home_appliances_2', 'flowers',
26        'construction_tools', 'construction_tools_lights', '
27        construction_tools_tools',

```

```

19         'luggage_accessories', 'la_cuisine', 'pet_shop', '
20         market_place']]:
21     return 'Home & Garden'
22 elif x in ['sports_leisure', 'toys', 'cds_dvds_musicals', 'music', '
23     dvds_blu_ray',
24     'cine_photo', 'party_supplies', 'christmas_supplies', '
25     arts_and_craftmanship', 'art']]:
26     return 'Entertainment'
27 elif x in ['health_beauty', 'perfumery', 'diapers_and_hygiene']:
28     return 'Beauty & Health'
29 elif x in ['food_drink', 'drinks', 'food']:
30     return 'Food & Drinks'
31 elif x in ['books_general_interest', 'books_technical', '
32     books_imported', 'stationery']:
33     return 'Books & Stationery'
34 elif x in ['construction_tools_construction', '
35     construction_tools_safety',
36     'industry_commerce_and_business', '
37     agro_industry_and_commerce']:
38     return 'Industry & Construction'

```

Data columns (total 2 columns):			
#	Column	Non-Null Count	Dtype
0	product_category_name	71 non-null	object
1	product_category_name_english	71 non-null	object

Data columns (total 3 columns):			
#	Column	Non-Null Count	Dtype
0	product_category_name	71 non-null	object
1	product_category_name_english	71 non-null	object
2	product_category	70 non-null	object


dtypes: object(3)
memory usage: 1.8+ KB
None

	product_category_name	product_category_name_english	product_category
0	beleza_saude	health_beauty	Beauty & Health
1	informatica_acessorios	computers_accessories	Electronics
2	automotivo	auto	Electronics
3	cama_mesa_banho	bed_bath_table	Furniture
4	moveis_decoracao	furniture_decor	Furniture


Hình 4.47: Before và After

4.3.3 Mở rộng: Sử dụng Apache Airflow để ETL dữ liệu

Sử dụng Apache Airflow để tự động hóa quá trình ETL dữ liệu ta được kết quả như bên dưới



Hình 4.48: Sơ đồ ETL dữ liệu




Hình 4.49: Kết quả thực thi các task

4.4 Mô hình dữ liệu OLTP

4.4.1 OLTP sau ETL

Với kết quả ETL ở trên, báo cáo sẽ tiếp tục thể hiện dữ liệu dưới dạng các mô hình thực thể quan hệ (ERD) hệ thống OLTP:




Hình 4.50: ERD hệ thống OLTP sau ETL

Dữ liệu sau ETL được thống kê dưới 9 bảng và có các liên kết với nhau như trên biểu đồ 4.50


4.4.2 Thống kê các trường dữ liệu để xây dựng data model đa chiều OLAP

Nhóm em nổi các trường với dim tương ứng như sau:



Hình 4.51: Nối dimension sau ETL

Các trường sử dụng cho Fact:



Hình 4.52: Fact sau ETL

4.5 Mô hình dữ liệu OLAP

4.5.1 Chuyển đổi mô hình OLTP sang OLAP

3.5.1.1. Tạo các bảng dim, fact

```
CREATE TABLE [dbo].[dim_Địa_điểm](
    [location_id] [int] IDENTITY(1,1) NOT NULL,
    [zip_code_prefix] [nvarchar](50) NULL,
    [state] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Địa_điểm] PRIMARY KEY CLUSTERED
(
    [location_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]

CREATE TABLE [dbo].[dim_Hình_thức_thanh_toán](
    [payment_type_id] [int] IDENTITY(1,1) NOT NULL,
    [payment_type] [nvarchar](50) NULL,
    [payment_instalments] [int] NULL,
    CONSTRAINT [PK_dim_Hình_thức_thanh_toán] PRIMARY KEY CLUSTERED
(
    [payment_type_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

Hình 4.53: Tạo các bảng dim Địa điểm và Hình thức thanh toán

```
CREATE TABLE [dbo].[dim_Khu_vực](
    [region_id] [int] IDENTITY(1,1) NOT NULL,
    [region] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Khu_vực] PRIMARY KEY CLUSTERED
(
    [region_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]

CREATE TABLE [dbo].[dim_Kích_thước_sản_phẩm](
    [product_id] [nvarchar](50) NOT NULL,
    [volumn] [float] NULL,
    [product_weight] [float] NULL,
    CONSTRAINT [PK_dim_Kích_thước_sản_phẩm] PRIMARY KEY CLUSTERED
(
    [product_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

Hình 4.54: Tạo các bảng dim Khu vực và Kích thước sản phẩm


```

CREATE TABLE [dbo].[dim_Ngành_hàng](
    [product_category_id] [int] IDENTITY(1,1) NOT NULL,
    [product_category_name] [nvarchar](50) NULL,
    [product_category] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Ngành_hàng] PRIMARY KEY CLUSTERED
(
    [product_category_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]

CREATE TABLE [dbo].[dim_Nhà_cung_cấp](
    [seller_state_id] [int] IDENTITY(1,1) NOT NULL,
    [seller_state] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Nhà_cung_cấp] PRIMARY KEY CLUSTERED
(
    [seller_state_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]

```

Hình 4.55: Tạo các bảng dim Ngành hàng và Nhà cung cấp

```

CREATE TABLE [dbo].[dim_Phân_khúc_khách_hàng](
    [segment_id] [int] IDENTITY(1,1) NOT NULL,
    [segment_name] [nvarchar](50) NULL,
    CONSTRAINT [PK_dim_Phân_khúc_khách_hàng] PRIMARY KEY CLUSTERED
(
    [segment_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]

CREATE TABLE [dbo].[dim_Thời_gian](
    [date] [date] NULL,
    [year] [int] NULL,
    [quarter] [int] NULL,
    [month] [int] NULL,
    [day] [int] NULL
) ON [PRIMARY]

CREATE TABLE [dbo].[dim_Trạng_thái_giao_hàng](
    [status_id] [int] IDENTITY(1,1) NOT NULL,
    [status_] [nvarchar](50) NULL,
    [arrival_status] [nvarchar](50) NULL,
    CONSTRAINT [PK_staus] PRIMARY KEY CLUSTERED
(
    [status_id] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF, IGNORE_DUP_KEY = OFF,
ALLOW_ROW_LOCKS = ON, ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]

```

Hình 4.56: Tạo các bảng dim Phân khúc khách hàng, Thời gian và Trạng thái giao hàng

```
CREATE TABLE [dbo].[fact_Đơn_hàng](
    [order_id] [nvarchar](50) NULL,
    [customer_id] [nvarchar](50) NULL,
    [product_id] [nvarchar](50) NULL,
    [order_date] [date] NULL,
    [payment_type] [nvarchar](50) NULL,
    [payment_value] [float] NULL,
    [zip_code] [nvarchar](50) NULL,
    [order_status] [nvarchar](50) NULL,
    [segment] [nvarchar](50) NULL,
    [product_category_name] [nvarchar](50) NULL
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[fact_Khách_hàng](
    [customer_id] [nvarchar](50) NULL,
    [location_id] [nvarchar](10) NULL,
    [total_orders] [int](10) NULL,
    [total_spent] [float](10) NULL,
    [first_order_date] [date] NULL,
    [recent_order_date] [date] NULL,
    [customer_segment] [nvarchar](50) NULL,
    [customer_region] [nvarchar](50) NULL
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[fact_Giao_hàng](
    [order_id] [nvarchar](50) NULL,
    [order_shipping_days] [nvarchar](50) NULL,
    [arrival_status] [nvarchar](50) NULL,
    [order_status_id] [nvarchar](50) NULL,
    [product_id] [nvarchar](50) NULL,
    [volume] [float] NULL,
    [product_weight_g] [float] NULL,
    [freight_value] [float] NULL,
    [payment_type] [nvarchar](50) NULL,
    [product_category] [nvarchar](50) NULL,
    [state] [nvarchar](50) NULL
) ON [PRIMARY]
```

```
CREATE TABLE [dbo].[fact_Sản_phẩm](
    [product_id] [nvarchar](50) NULL,
    [product_category] [nvarchar](50) NULL,
    [seller] [nvarchar](50) NULL,
    [seller_state] [nvarchar](50) NULL,
    [total_sale] [int] NULL,
    [total_revenue] [float] NULL,
    [average_rating] [float] NULL,
    [is_Cancelled] [int] NULL
) ON [PRIMARY]
```

Hình 4.57: Tạo các bảng Fact

3.5.1.2. Insert dữ liệu vào các bảng Fact

```
INSERT INTO fact_Giao_hàng (
    order_id,
    order_shipping_days,
    product_id,
    arrival_status,
    order_status_id,
    volume,
    product_weight_g,
    freight_value,
    payment_type,
    product_category,
    state
)
SELECT
    o.order_id,
    o.order_shipping_days,
    oi.product_id,
    o.arrival_status,
    dt.status_,
    dk.volume,
    dk.product_weight,
    oi.freight_value,
    py.payment_type,
    dn.product_category,
    dd.state
FROM
    orders o
LEFT JOIN
    order_items oi ON o.order_id = oi.order_id
LEFT JOIN
    dim_Trạng_thái_giao_hàng dt ON o.order_status = dt.status_
LEFT JOIN
    [dim_Kích_thuộc_sản_phẩm] dk ON oi.product_id = dk.product_id
LEFT JOIN
    payments py ON py.order_id = o.order_id
LEFT JOIN
    product po ON po.product_id = oi.product_id
LEFT JOIN
    dim_Ngành_hàng dn ON dn.product_category_name = po.product_category_name
LEFT JOIN
    customers c ON c.customer_id = o.customer_id
LEFT JOIN
    dim_Địa_điểm dd ON dd.zip_code_prefix = c.customer_zip_code_prefix
```

```
INSERT INTO fact_Đơn_hàng(
    order_id,
    customer_id,
    product_id,
    order_date,
    payment_type,
    payment_value,
    zip_code,
    order_status,
    segment,
    product_category_name
)
SELECT
    o.order_id,
    c.customer_id,
    oi.product_id,
    o.order_purchase_timestamp,
    py.payment_type,
    py.payment_value,
    dd.zip_code_prefix,
    dt.status_,
    dp.segment_name,
    dn.product_category
FROM
    orders o
LEFT JOIN
    customers c ON c.customer_id = o.customer_id
LEFT JOIN
    order_items oi ON o.order_id = oi.order_id
LEFT JOIN
    payments py ON py.order_id = o.order_id
LEFT JOIN
    product po ON po.product_id = oi.product_id
LEFT JOIN
    dim_Trạng_thái_giao_hàng dt ON o.order_status = dt.status_
LEFT JOIN
    dim_Phân_khúc_khách_hàng dp ON dp.segment_name = c.Segment
LEFT JOIN
    dim_Ngành_hàng dn ON dn.product_category_name = po.product_category_name
LEFT JOIN
    dim_Địa_điểm dd ON dd.zip_code_prefix = c.customer_zip_code_prefix
```

Hình 4.58: Ghi dữ liệu vào fact Đơn hàng và Giao hàng

```

INSERT INTO fact_Sản_phẩm(
  product_id,
  product_category,
  seller,
  seller_state,
  total_sale,
  total_revenue,
  average_rating,
  is_cancelled
)
SELECT
  p.product_id,
  dn.product_category,
  s.seller_id,
  dncc.seller_state,
  COUNT(oi.order_id) AS total_sales,      -- Đếm số lần sản phẩm được bán
  SUM(oi.price) AS total_revenue,        -- Tổng doanh thu
  AVG(CAST(r.review_score AS FLOAT)) AS average_rating, -- Điểm đánh giá trung bình
  CASE
    WHEN COUNT(CASE WHEN o.order_status = 'canceled' THEN 1 END) > 0 THEN 1
    ELSE 0
  END AS is_cancelled
FROM
  product p
LEFT JOIN
  order_items oi ON oi.product_id = p.product_id
LEFT JOIN
  sellers s ON s.seller_id = oi.seller_id
LEFT JOIN
  dim_Ngành_hàng dn ON p.product_category_name = dn.product_category_name
LEFT JOIN
  dim_Nhà_cung_cấp dncc ON dncc.seller_state = s.seller_state
LEFT JOIN
  orders o ON oi.order_id = o.order_id
LEFT JOIN
  reviews r ON o.order_id = r.order_id
GROUP BY
  p.product_id,
  dn.product_category,
  s.seller_id,
  dncc.seller_state

INSERT INTO fact_Khách_hàng(
  customer_id,
  location_id,
  total_orders,
  total_spent,
  first_order_date,
  recent_order_date,
  customer_segment,
  customer_region
)
SELECT
  c.customer_id,
  dd.state,
  COUNT(o.order_id) AS total_orders,
  SUM(p.payment_value) AS total_spent,
  MIN(o.order_purchase_timestamp) AS first_order_date,
  MAX(o.order_purchase_timestamp) AS last_order_date,
  dp.segment_name,
  dk.region
FROM
  customers c
LEFT JOIN
  orders o ON c.customer_id = o.customer_id
LEFT JOIN
  payments p ON p.order_id = o.order_id
LEFT JOIN
  geolocations geo ON geo.geolocation_zip_code_prefix = c.customer_zip_code_prefix
LEFT JOIN
  dim_Phân_khúc_khách_hàng dp ON dp.segment_name = c.Segment
LEFT JOIN
  dim_Địa_điểm dd ON dd.zip_code_prefix = c.customer_zip_code_prefix
LEFT JOIN
  dim_Khu_vực dk ON dk.region = geo.region
GROUP BY
  c.customer_id,
  c.customer_unique_id,
  dd.state,
  dp.segment_name,
  dk.region

```

Hình 4.59: Ghi dữ liệu vào fact Sản phẩm và Khách hàng

4.5.2 Hệ thống chiều khái niệm

12 values	31 values	3 values	73 values	9 values	27 values	5 values
Tháng	Ngày	Năm	product_category_name	product_category	geolocation_state	region
1	1	2016	beleza_saude	Beauty & Health	SP	Southeast
2	1	2017	informatica_acessorios	Electronics	RJ	South
3	2	2018	automotivo	Furniture	ES	Midwest
4	3		cama_mesa_banho	Entertainment	MG	North
5	4		moveis_decoracao	Home & Garden	BA	Northeast
6	5		esporte_lazer	Food & Drinks	SE	
7	6		perfumaria	Fashion	PE	
8	7		utilidades_domesticas	Books & Stationery	RN	
9	8		telefonica	Industry & Construction	AL	
10	9		relogios_presentes		...	
11	10		alimentos_bebidas			
12	11		bebidas			
	12		papelaria			
	13		tablets_impressao_imagem			
	14		brinquedos			
	15		...			
	...					
2 values	2 values	3 values			5 values	24 values
order_status	arrival_status	product_quality			payment_type	payment_installments
delivered	Early	Good			credit_card	0
canceled	Late	Poor			boleto	1
		Average			voucher	2
					debit_card	3
					not_defined	4
						5
						6
						7
						8
						9
						10
						...


Hình 4.60: Các chiều khái niệm

Sau quá trình tiền xử lý, nhóm bọn em thu được hệ thống chiều khái niệm như trên hình vẽ:

- **Tháng:** chứa thông tin tháng, có 12 giá trị.
- **Ngày:** chứa thông tin ngày, có 31 giá trị.
- **Năm:** chứa thông tin năm, có 3 giá trị.
- **product_category_name:** chứa thông tin tên các phân loại mặt hàng, có 73 giá trị.
- **product_category:** chứa thông tin tên các phân loại ngành hàng, có 9 giá trị.
- **region:** chứa thông tin các khu vực, có 5 giá trị.
- **geolocation_state:** chứa thông tin tên viết tắt của các bang, có 27 giá trị.
- **product_quality:** chứa thông tin chất lượng của sản phẩm, có 3 giá trị.
- **payment_type:** chứa thông tin các hình thức thanh toán. có 5 giá trị.
- **payment_installments:** chứa thông tin các tháng trả góp, có 24 giá trị.
- **order_status:** chứa thông tin các trạng thái giao hàng, có 2 giá trị
- **arrival_status:** chứa thông tin tình trạng giao hàng đến nói, có 2 giá trị.

4.6 Data Mart


4.6.1 Mô hình dữ liệu Logic




Hình 4.61: Mô hình dữ liệu Logic

4.6.2 Thiết kế cơ sở dữ liệu cho DataMart


4.6.3 Mô hình dữ liệu vật lý




Hình 4.62: Star Schema của bảng fact_Đơn_hàng



Hình 4.63: Star Schema của bảng fact_Giao_hàng



Hình 4.64: Star Schema của bảng fact_Khách_hàng




Hình 4.65: Star Schema của bảng fact_Sản_phẩm

Xây Dựng hệ thống

Trong phần này sẽ phân tích 4 Dashboard được tạo đó là:

- Dashboard phân tích khách hàng
- Dashboard phân tích Doanh thu
- Dashboard phân tích Sản phẩm
- Dashboard phân tích Đơn hàng

5.1 Dashboard phân tích khách hàng



Hình 5.1: Dashboard phân tích khách hàng

Dựa vào bộ dữ liệu Olist, số lượng khách hàng được tính dựa trên các giao dịch được ghi nhận trong hệ thống, và dữ liệu này được phân tích theo thời gian, khu vực, và phân khúc sản phẩm. Trong báo cáo này, các yếu tố như số lượng khách hàng, phân bổ khách hàng theo khu vực, và xu hướng khách hàng theo phân khúc sẽ được đánh giá kỹ lưỡng.

Nhìn chung, tổng số lượng khách hàng có xu hướng tăng trưởng theo thời gian. Biểu đồ theo năm cho thấy lượng khách hàng tăng đều từ các năm trước, với tốc độ tăng trưởng YoY đạt +21.58%. Số lượng khách hàng tập trung nhiều vào các tháng giữa năm, đặc biệt trong quý II và III (tháng 4–9), trước khi giảm nhẹ vào cuối năm.


Về mặt địa lý, bản đồ phân bổ khách hàng cho thấy sự tập trung chủ yếu ở khu vực Đông Nam Brazil, đặc biệt là các bang như São Paulo, Rio de Janeiro, và Minas Gerais. Đây là các khu vực kinh tế trọng điểm, có mật độ dân số cao và cơ sở hạ tầng giao thương phát triển. Trong khi đó, các bang phía Bắc như Acre và Roraima có lượng khách hàng thấp hơn đáng kể, do hạn chế về mật độ dân cư và điều kiện kinh tế.

Khi phân tích theo từng loại danh mục, danh mục **Electronics** chiếm tỷ trọng lớn nhất với 15,311 khách hàng, tăng trưởng +26.5% YoY. Các danh mục **Furniture** (10,860 khách, +8.7%) và **Beauty & Health** (6,778 khách, +36.0%) cũng có lượng khách hàng ổn định và tăng trưởng tích cực. Đáng chú ý, danh mục **Home & Garden** tuy có số lượng khách hàng thấp hơn (6,167) nhưng có tốc độ tăng trưởng cao nhất, đạt +63.5% YoY, cho thấy sự thay đổi trong nhu cầu tiêu dùng. Trong khi đó, danh mục **Entertainment** ghi nhận sự sụt giảm -4.3% YoY, có thể phản ánh xu hướng giảm trong chi tiêu cho giải trí.

Về giá trị trung bình của khách hàng, các khu vực Đông Nam với số lượng khách hàng cao khả năng cao cũng có giá trị giao dịch trung bình lớn hơn. Tuy nhiên, do thiếu dữ liệu cụ thể về giá trị giao dịch, xu hướng chi tiết về giá trị trung bình theo khu vực và danh mục chưa thể hiện rõ trong dashboard. Dựa trên sự tăng trưởng của các danh mục như **Home & Garden** và **Beauty & Health**, có thể dự đoán rằng giá trị trung bình của khách hàng trong các danh mục này đang tăng dần theo thời gian.

Tóm lại, báo cáo này chỉ ra rằng khu vực Đông Nam Brazil và các danh mục như **Electronics** và **Beauty & Health** đóng vai trò chủ lực trong sự phát triển của nền tảng thương mại điện tử. Các xu hướng về khách hàng, đặc biệt là sự tăng trưởng mạnh mẽ trong danh mục **Home & Garden**, thể hiện tiềm năng mở rộng trong các danh mục mới nổi. Việc tập trung đầu tư vào khu vực trọng điểm và tối ưu hóa trải nghiệm khách hàng trong các danh mục đang tăng trưởng có thể mang lại hiệu quả lớn cho chiến lược kinh doanh trong tương lai.

5.2 Dashboard phân tích Doanh thu



Hình 5.2: Dashboard phân tích Doanh thu

Dựa vào bộ dữ liệu hiển thị trên dashboard, doanh thu được tính dựa trên giá trị các đơn hàng trong bảng thanh toán và trạng thái đơn hàng trong hệ thống. Chỉ những đơn hàng có trạng thái đã được giao đến khách hàng mới được tính vào tổng doanh thu. Trong báo cáo này, doanh thu sẽ được phân tích theo các tiêu chí thời gian, khu vực, danh mục sản phẩm, và hình thức thanh toán.

Nhìn chung, tổng doanh thu đạt \$7,217K, tăng trưởng 21.08% so với năm trước (YoY). Số lượng đơn hàng đạt 52,778 với mức tăng trưởng tương ứng 21.58% YoY, trong khi giá trị vận chuyển (*Freight Value*) tăng mạnh nhất, đạt \$1,233K, tăng 28.70% YoY. Số lượng sản phẩm bán ra là 60,319, tăng 21.76% YoY, cho thấy nhu cầu mua sắm ngày càng tăng cao.

Doanh thu theo thời gian có xu hướng tăng đều qua các tháng. Từ tháng 3 đến tháng 9, doanh thu đạt mức tăng trưởng mạnh, trùng với các mùa cao điểm mua sắm. Cuối năm doanh thu có xu hướng chững lại nhưng vẫn duy trì ở mức cao. Đây là thời điểm cần tập trung đẩy mạnh các chương trình khuyến mãi để thúc đẩy nhu cầu tiêu dùng.

Về khu vực địa lý, doanh thu chủ yếu tập trung tại các bang phát triển như Rio de Janeiro (\$696K) và Minas Gerais (\$677K), đây là các khu vực có dân số đông và kinh tế phát triển, đồng thời cũng là trung tâm của các hoạt động vận tải và phân phối hàng hóa. Các khu vực như Paraná và Rio Grande do Sul đóng góp doanh thu ở mức trung bình (\$294K và \$309K). Trong khi đó, các khu vực phía Bắc và Đông Bắc có doanh thu thấp hơn, nguyên nhân chủ yếu là do mật độ dân số thấp và hạn chế về cơ sở hạ tầng vận chuyển.


Phân tích theo danh mục sản phẩm, các danh mục mang lại doanh thu cao nhất là:

- **Health & Beauty:** \$756K, tăng 59.5% YoY, dẫn đầu các danh mục.
- **Watches & Gifts:** \$688K, tăng 44.5% YoY.
- **Housewares** tăng trưởng cao nhất với 76.0% YoY, cho thấy đây là danh mục có tiềm năng phát triển lớn.
- Các danh mục như **Computers & Accessories** (\$496K) và **Bed, Bath, Table** (\$532K) cũng duy trì mức tăng trưởng ổn định.

Về hình thức thanh toán, phần lớn giao dịch được thực hiện qua **Credit Card** (chiếm 77.6%), tiếp theo là **Boleto** (18.9%) và **Debit Card** (2.0%). Điều này cho thấy thói quen sử dụng thẻ tín dụng là phổ biến nhất, đặc biệt ở các khu vực có mức thu nhập cao.

Kết luận, doanh thu của nền tảng thương mại điện tử có xu hướng tăng trưởng mạnh nhờ sự đóng góp lớn từ các khu vực kinh tế phát triển và các danh mục sản phẩm trọng điểm. Việc tập trung mở rộng các danh mục như **Health & Beauty**, **Housewares** và khai thác tiềm năng từ các khu vực còn lại sẽ là chiến lược cần thiết để thúc đẩy tăng trưởng trong tương lai.

5.3 Dashboard phân tích Sản phẩm



Hình 5.3: Dashboard phân tích Doanh thu

Dựa vào bộ dữ liệu, thông tin sản phẩm được phân tích từ các yếu tố bao gồm số lượng sản phẩm bán, điểm đánh giá sản phẩm, phân loại theo ngành hàng, và chi phí giao vận. Trong báo

cáo này, chúng ta sẽ tập trung vào các khía cạnh như số lượng sản phẩm bán theo thời gian, ngành hàng bán chạy nhất, chất lượng sản phẩm, tỷ lệ hoàn trả, và tác động của kích thước sản phẩm.

Nhìn chung, số lượng sản phẩm bán ra có xu hướng tăng theo thời gian. Cụ thể, từ tháng 3 đến tháng 8 là khoảng thời gian cao điểm với doanh số ổn định, trong khi các tháng cuối năm (tháng 11 và 12) có sự giảm nhẹ. Điều này cho thấy có thể có sự ảnh hưởng từ yếu tố thời vụ và chiến lược bán hàng của từng thời điểm.

Dựa trên biểu đồ doanh số theo ngành hàng, ta thấy rằng ngành hàng *health_beauty* dẫn đầu với 5,842 sản phẩm bán ra, chiếm tỷ trọng lớn và tăng trưởng mạnh mẽ 63.1% so với năm trước. Tiếp theo là ngành *bed_bath_table* với 5,810 sản phẩm, tăng trưởng 13.1%. Điều này cho thấy nhu cầu cao đối với các sản phẩm làm đẹp và gia dụng.

Về đánh giá chất lượng sản phẩm, có **64.6%** sản phẩm được đánh giá tốt (*Good*), phản ánh sự hài lòng của khách hàng với các ngành hàng dẫn đầu như *health_beauty* và *computers_accessories*. Tuy nhiên, vẫn có **7.5%** sản phẩm bị đánh giá thấp (*Poor*), cần cải thiện để nâng cao trải nghiệm khách hàng.


Ngành hàng *auto* và *housewares* có tỷ lệ hoàn trả cao hơn so với các ngành hàng khác. Phân tích cho thấy các sản phẩm kích thước lớn thường có tỷ lệ hoàn trả cao, chủ yếu do chi phí giao hàng và các khó khăn trong lắp đặt hoặc sử dụng.

Cuối cùng, các sản phẩm kích thước nhỏ và trung bình thường có tỷ lệ hoàn trả thấp hơn, nhờ vào sự tiện lợi trong vận chuyển và sử dụng. Việc tối ưu hóa quy trình giao vận và quản lý chất lượng nhà cung cấp là cần thiết để giảm tỷ lệ hoàn trả và duy trì sự hài lòng của khách hàng.

Kết luận

Dashboard sản phẩm cho thấy hiệu suất tích cực trong các ngành hàng chủ lực như *health_beauty* và *bed_bath_table*. Tuy nhiên, cần cải thiện chất lượng sản phẩm ở các ngành hàng có tỷ lệ hoàn trả cao như *auto* và *housewares*. Ngoài ra, việc quản lý kích thước sản phẩm và chi phí vận chuyển sẽ giúp giảm tỷ lệ hoàn trả và nâng cao doanh thu tổng thể.

5.4 Dashboard phân tích Giao hàng



Hình 5.4: Dashboard phân tích Giao hàng

Dựa trên bộ dữ liệu đã xử lý, nhóm chúng em xây dựng 6 biểu đồ: Chi phí vận chuyển theo ngành hàng, Tỷ lệ giao hàng đúng hạn, Thời gian giao hàng trung bình theo tháng, Số lượng đơn hàng theo tháng, Phân phối thời gian giao hàng, Chi phí vận chuyển trung bình theo từng bang và 1 thể dữ liệu tỷ lệ giao hàng thành công.

Trước hết về tỷ lệ giao hàng thành công trung bình giữa các khu vực là trên 90% trong cả 2 năm thu thập dữ liệu cho thấy chỉ rất ít các đơn hàng bị sót chưa giao. Tuy nhiên khi nhìn xuống biểu đồ tỷ lệ giao hàng đúng hạn, ta thấy có đến 66.1% đơn được giao trễ gần gấp đôi số đơn giao đúng hạn 33.9%. Cho thấy mặc dù đơn được giao thành công nhưng Olist lại không đảm bảo được đơn giao đến cho khách đúng hạn. Nguyên do có thể do số lượng đơn hàng quá nhiều, Olist mới thành lập nên chưa có kế hoạch phân bổ nguồn lực hiệu quả cho việc quản lý giao hàng đến tay khách hàng, cũng có thể là do khách quan việc vận chuyển khó khăn hơn dự tính và mất nhiều thời gian hơn từ khâu đóng gói sản phẩm.

Nhìn sang biểu đồ phân phối thời gian giao hàng, ta thấy các đơn hàng đa phần được trong khoảng từ 0 đến 20 ngày, nhiều nhất là trong 5 ngày. Đây là một thống kê khá tốt cho thấy Olist đã cố gắng trong việc giao đơn hàng đến tay khách nhanh nhất có thể. Biểu đồ thời gian giao hàng trung bình theo tháng cao ở phía rìa đầu năm và cuối năm, trũng về phía giữa. Điều này có thể lý giải vì đây là những tháng thường có nhiều dịp kích cầu tiêu dùng như Black Friday,

nhu cầu mua hàng của khách vào thời điểm này cũng cao hơn do cần chuẩn bị cho năm mới,...

Biểu đồ Chi phí vận chuyển theo ngành hàng và theo bang, ta thấy các ngành hàng như đồ điện tử và đồ nội thất có chi phí cao vượt trội so với các ngành hàng còn lại. Điều này được lý giải vì đây là các mặt hàng hoặc là lớn, cồng kềnh hoặc là phải cẩn thận trong khâu vận chuyển nên các chi phí cũng cao theo so với các ngành hàng khác như thực phẩm(food&drink) , quần áo (fashion) nhỏ nhẹ và dễ vận chuyển hơn nên chi phí nhỏ hơn đáng kể. Biểu đồ chi phí vận chuyển theo bang cho thấy Olist phân phối bán hàng của mình tập trung ở khu vực Nam Mỹ và có mở rộng ra 1 số điểm tại Bắc Mỹ. Chi phí vận chuyển khá đồng đều khi các kích thước ô tròn khá tương đồng nhau. Điều này cho thấy Olist đã tối ưu khá tốt các chi phí vận chuyển cho các địa điểm mà doanh nghiệp này có thị trường.

Kết luận: Tuy Olist mới thành lập không lâu nhưng những con số thống kê lại về việc Giao hàng đều khá khả quan, tuy nhiên về mặt giao hàng đúng hạn thì Olist cần có chính sách để cải thiện thời gian giao sao cho đúng với thỏa thuận với khách hàng. Ví dụ như cải thiện quy trình đóng gói, phân phối hàng, liên kết với các đơn vị vận chuyển để có thể tăng tốc thời gian vận chuyển cho đúng thỏa thuận.

Khai phá luật kết hợp

6.1 Tổng quan khai phá luật kết hợp

- **Luật kết hợp** là một khái niệm trong lĩnh vực dữ liệu lớn (big data) và khai phá dữ liệu (data mining).
- Được sử dụng để tìm ra các mối quan hệ hoặc mẫu xuất hiện đồng thời trong một tập dữ liệu.
- Cụ thể, luật kết hợp được áp dụng trong việc khai phá dữ liệu mua sắm, dữ liệu truy xuất web, dữ liệu y tế, và nhiều lĩnh vực khác.

6.2 Tập phổ biến

Tập phổ biến là tập hợp các mục (item) xuất hiện cùng nhau trong một tập dữ liệu với một tần suất đủ lớn.

Ví dụ: {Milk, Bread}: Tập phổ biến nếu xuất hiện trong nhiều giao dịch. Nói dễ hiểu hơn là người dùng thường mua sữa và bánh mì cùng lúc.

6.3 Luật kết hợp

Luật kết hợp là các quy tắc mô tả mối quan hệ giữa các tập phổ biến. Mỗi luật kết hợp có dạng "IF-THEN", trong đó antecedent là một tập phổ biến dẫn đến consequent.

Ví dụ:

- IF Milk, Bread THEN Butter: Luật kết hợp này nói rằng khi một khách hàng mua Milk và Bread, họ có xu hướng mua cả Butter.

6.4 Các khái niệm

- **Support (Độ hỗ trợ):** Tỷ lệ giao dịch chứa cả A và B trên tổng số giao dịch.

$$\text{Supp}(X) = \frac{\text{Freq}(X)}{T}$$

- **Confidence (Độ tin cậy):** Xác suất B xảy ra khi A đã xảy ra.

$$\text{Confidence} = \frac{\text{Freq}(X, Y)}{\text{Freq}(X)}$$

- **Lift :** Đo lường mức độ phụ thuộc giữa A và B so với sự độc lập

$$\text{Lift} = \frac{\text{Supp}(X, Y)}{\text{Supp}(X) \times \text{Supp}(Y)}$$

- Lift > 1: A và B có quan hệ tích cực.
- Lift = 1: A và B độc lập.
- Lift < 1: A và B có quan hệ tiêu cực.

6.5 Các thuật toán

Dưới đây là 2 thuật toán phổ biến nhất được sử dụng trong khai phá luật kết hợp.

- **Apriori Algorithm:** Dựa trên nguyên lý loại bỏ tập con không phổ biến, sinh dần các tập phổ biến từ 1 mục trở lên, nhưng chậm với dữ liệu lớn.
- **FP-Growth Algorithm:** Sử dụng cây tần số (FP-Tree) để tìm tập phổ biến nhanh mà không cần sinh tập hợp, nhưng tốn nhiều bộ nhớ.

Thuật toán	Ưu điểm	Hạn chế
Apriori	Dễ triển khai	Chậm với dữ liệu lớn
FP-Growth	Hiệu quả với dữ liệu lớn	Tốn bộ nhớ hơn

Bảng 6.1: So sánh ưu điểm và hạn chế của các thuật toán khai phá luật kết hợp.

Dựa vào ưu điểm và nhược điểm của các thuật toán, chúng em dùng FP-Growth để áp dụng vào bài toán của mình.

6.6 Dữ liệu đầu vào

Bài toán đặt ra là phân tích hành vi mua hàng của mỗi khách hàng. Đầu vào của thuật toán là dữ liệu dạng one-hot với cột bên trái là mã khách hàng và hàng ngang đầu tiên là danh mục sản phẩm.

	customer unique id	agro industry and commerce	air conditioning	art	arts and craftmanship	audio	auto	baby	bed bath table	books general interest	...
0	0000366f3b9a7992bf8c76cdf3221e2	0	0	0	0	0	0	0	1	0	...
1	0000b849f77a49e4a4ce2b2a4ca5be3f	0	0	0	0	0	0	0	0	0	...
2	0000f46a3911fa3c0805444483337064	0	0	0	0	0	0	0	0	0	...
3	0000f6ccb0745a6a4b88665a16c9f078	0	0	0	0	0	0	0	0	0	...
4	0004aac84e0df4da2b147fca70cf8255	0	0	0	0	0	0	0	0	0	...

Hình 6.1: Mã hóa one-hot.

6.7 Kết quả sau khi áp dụng mô hình

	support	itemsets
0	0.095839	(bed bath table)
1	0.090945	(health beauty)
5	0.078757	(sports leisure)
8	0.068717	(computers accessories)
22	0.066202	(furniture decor)
14	0.061004	(housewares)
16	0.058132	(watches gifts)
3	0.043513	(telephony)
21	0.040369	(auto)
11	0.040285	(toys)

Hình 6.2: Kết quả những danh mục phổ biến nhất

Các mẫu được trả về dưới dạng một dataframe. 10 danh mục sản phẩm phổ biến nhất được hiển thị ở trên.

Lưu ý: "Support" không hiển thị số lượng sản phẩm được bán mà là số lượng đơn hàng duy nhất chứa sản phẩm đó.

Dựa trên các mẫu này, các quy tắc được tạo ra. Do các giao dịch rất thưa thớt và có khoảng 70 danh mục, ngưỡng được xem xét cho "confidence" cũng được đặt ở mức thấp - 0,10. Điều này có nghĩa là tất cả các quy tắc liên kết được hình thành sẽ chỉ ra rằng các sản phẩm từ tập phổ biến có xác suất 10% hoặc cao hơn để được mua cùng nhau.

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift
0	(bed bath table, garden tools)	(housewares)	0.000168	0.061004	0.000031	0.187500	3.073570
1	(garden tools, housewares)	(bed bath table)	0.000252	0.095839	0.000031	0.125000	1.304265
2	(fashion bags accessories, bed bath table)	(housewares)	0.000115	0.061004	0.000021	0.181818	2.980431
3	(fashion bags accessories, housewares)	(bed bath table)	0.000115	0.095839	0.000021	0.181818	1.897112
4	(home confort)	(bed bath table)	0.004150	0.095839	0.000566	0.136364	1.422834
5	(home confort, furniture decor)	(bed bath table)	0.000094	0.095839	0.000021	0.222222	2.318693

Hình 6.3: Kết quả sự kết hợp các danh mục.

Các quy tắc chỉ ra sản phẩm nào có khả năng được mua (consequents) nếu khách hàng đã mua một tập hợp sản phẩm (antecedents) với xác suất ít nhất 10

Những quy tắc này có thể được sử dụng để hiểu các mô hình mua sắm và đưa ra gợi ý phù hợp cho khách hàng. Đồng thời, chúng cũng giúp người bán và nhân viên kinh doanh hiểu được nhu cầu trên thị trường và mối quan hệ giữa các sản phẩm được bán ra.

1 kết quả trên bảng này chỉ ra là: Khi người dùng mua 2 mặt hàng bed bath table và garden tools sẽ có xu hướng mua housewares với xác suất xảy ra đồng thời support là 0.000031 với thực tế số lượng người từng mua hàng như thế là $0.000031 * 100k$ (bộ dữ liệu 100k bản ghi). Đây là một con số vô cùng tốt cho nền tảng có thể xem xét các chiến dịch liên quan đến các mặt hàng này. Đồng thời mối quan hệ tích cực giữa hai bên cũng thể hiện qua chỉ số lift = 3 > 1.

Tổng kết

Kết quả đạt được

Qua nội dung học phần và báo cáo, tập thể nhóm 18 đã đạt được các kết quả sau:

1. Hiểu được những kiến thức nền tảng cơ bản về Kho dữ liệu, Kinh doanh thông minh, phân tích dữ liệu và phân tích kinh doanh. Bên cạnh đó xây dựng được kiến trúc của kho dữ liệu
2. Khảo sát quy trình nghiệp vụ, trình bày các yêu cầu phân tích, quy mô hệ thống dữ liệu, sơ đồ ER, luồng dữ liệu, OLTP, yêu cầu phân tích.
3. Thiết kế được Mind map nhu cầu phân tích, hệ thống lại bộ dữ liệu bằng data taxonomy.
4. Khám phá dữ liệu, kiến trúc DWH, ETL dữ liệu bằng đa dạng công cụ, thiết kế được data pipeline.
5. Sử dụng đa dạng công cụ như Power Query, Python, SQL.
6. Trình bày về data model logic, vật lý.
7. Hệ thống chiều khái niệm.
8. Cây phân tích dashboard.
9. Dashboard đa dạng biểu đồ, có slicer, định dạng có điều kiện, thống kê số lượng dashboard, public lên website để mọi người tiện theo dõi.
10. Phân tích được Dashboard theo các chủ điểm đã đưa ra. Nội dung phân tích chi tiết
11. Sử dụng luật kết hợp để đưa ra các danh mục sản phẩm nên kết hợp giúp tôi ưu lợi nhuận. Sử dụng Apache Airflow để giám sát quá trình thực hiện ETL.

Bài học rút ra

1. Cần tìm hiểu, khảo sát kỹ càng yêu cầu, nghiệp vụ chuyên môn trước khi thực hiện xử lý dữ liệu, phân tích và thiết kế Data Warehouse.
2. Cần nghiên cứu kỹ càng bộ dữ liệu trước khi ETL để tránh sai sót và mất mát dữ liệu.
3. Cần kết hợp nhiều công cụ để phân tích, xử lý dữ liệu sao cho tổng quan hơn.
4. Các dashboard cần trực quan, sinh động và bám sát nghiệp vụ phân tích; thông tin cần được biểu diễn rõ ràng được sắp xếp khoa học

5. Không nên quá tập trung vào thống kê đơn thuần mà phải phục vụ nhu cầu đưa ra phân tích, dự báo, hỗ trợ ra quyết định.

Tài liệu tham khảo

- [1] Wikipedia contributors. *Business intelligence*. **june** 2024. URL: https://en.wikipedia.org/wiki/Business_intelligence.
- [2] Marco Ferrari Alberto; Russo. *Introducing Microsoft Power BI*. Redmond: Microsoft Press, 2016.
- [3] K. D. Foote. *A Brief History of Business intelligence - DATAVERSITY*. **april** 2023. URL: <https://www.dataversity.net/brief-history-business-intelligence/>.
- [4] W.H. Inmon. *Building The Data Warehouse*. Fourth Edition. New York, NY United States: John Wiley Sons, Inc., 2002.
- [5] S. Negash **and** P. Gray. *Business Intelligence?* in *Springer eBooks*: Springer, 2008, **pages** 175–193.
- [6] Sonny Rivera. *The fundamentals of data warehouse architecture*. 2023. URL: <https://www.thoughtspot.com/data-trends/data-modeling/data-warehouse-architecture>.
- [7] Swain Scheps. *Business Intelligence For Dummies*. Indianapolis: Wiley Publishing, Inc., 2008.
- [8] Charles D. Tupper. *Data Architecture*. Elsevier, Inc., 2011.
- [9] *What is Data Modeling? | Microsoft Power BI*. 2024. URL: <https://powerbi.microsoft.com/en-us/what-is-data-modeling/>.